

18.065 Matrix Methods in Data Analysis, Signal Processing, and Machine Learning (数据分析、信号处理与机器学习中的矩阵方法)

原文来源: MIT OCW 18.065 S18 *Problem Sets Related to Lectures and Readings* (Problems for Lecture 4) · 教材出处: Linear Algebra and Learning from Data (Strang 2019) §1.6 · 答案核验: 教材官方 Instructor's Manual, Manual, Problem Set I.6 题 2, 11, 15

第四课 · Problems for Lecture 4 (第 4 讲讲题)

本讲主题是本课程的两块基石: **Eigenvalues and Eigenvectors (特征值与特征向量)**。把它读成一个设计问题会更清楚: **一个矩阵里有哪些方向, 被它作用之后只是被拉伸, 方向不变?**

答案是三个层次。第一层是哪些方向不变、拉伸多少: $Ax = \lambda x$ 把矩阵的作用简化为一个标量因子, 于是 A 与 A^{-1} 的差别只剩 λ 与 $1/\lambda$ (题 2)。第二层是哪些量只由特征值决定: $n = 2$ 时 $\lambda_1 + \lambda_2 = \text{tr}(A)$ 、 $\lambda_1 \lambda_2 = \det A$ 给出两个可以独立验算的锚点; 另一条是 $\det(A - \lambda I) = \det(A^T - \lambda I)$, 它对任意 n 成立, 说明 A 与 A^T 共享特征值、却一般不共享特征向量 (题 11)。第三层是把整台机器拆开装回: 只要能找到 n 个线性无关的特征向量, 就能写 $A = X\Lambda X^{-1}$, 从此 $A^3 = X\Lambda^3 X^{-1}$ 、 $A^{-1} = X\Lambda^{-1} X^{-1}$, X 与 X^{-1} 原地不动, 矩阵的幂与逆全部变成对角矩阵上的标量运算 (题 15)。

三层合起来是本课程反复使用的一条纪律: **遇到矩阵运算, 先问它作用在特征向量上会怎样**。这也是后面 SVD、马尔可夫链、差分方程 (A^k) 的共同起点。

术语口径 (本讲五个词, 后文严格按此使用)

- eigenvalue / eigenvector (特征值 / 特征向量): 满足 $Ax = \lambda x$ 的 λ 与非零向量 x 。特征向量张成 eigenspace (特征空间); **特征向量不能是零向量**, 这是定义的一部分, 而特征值可以是 0。
- characteristic polynomial (特征多项式): $\det(A - \lambda I)$, 它的根就是特征值; 对应题 2 的矩阵 A , 它是 $\lambda^2 - \lambda - 2 = (\lambda - 2)(\lambda + 1)$, 可由 $\text{tr}(A) = 1$ 、 $\det A = -2$ 独立验算。
- trace-determinant check (迹—行列式校验): $\lambda_1 + \dots + \lambda_n = \text{tr}(A)$, $\lambda_1 \lambda_2 \dots \lambda_n = \det A$ 。它是**校验工具**, 不是求解工具: 两个数都能独立算出来, 所以能抓出算错的特征值。
- diagonalization (对角化): $A = X\Lambda X^{-1}$, 其中 X 的列是特征向量、 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$; 它要求这 n 个特征向量线性无关 (linearly independent), 否则矩阵不可对角化 (如 $\begin{bmatrix} \lambda & 1 \\ 0 & \lambda \end{bmatrix}$)。

- spectral mapping (谱映射) : $A^k = X\Lambda^k X^{-1}$, $A^{-1} = X\Lambda^{-1} X^{-1}$ (后者要求所有 $\lambda_i \neq 0$) ; 矩阵运算作用在 Λ 上, X 原地不动, 这是本讲最重要的操作原则。

必须挡住的三处混淆: ① 把特征值相同当成矩阵相同 (教材题 13 的结论正相反: 还要特征向量一致才推出 $A = B$) ; ② 把 A 与 A^T 特征值相同顺手推广成特征向量也相同 (题 11 用具体矩阵堵死这一步) ; ③ 在 $A = X\Lambda X^{-1}$ 里把 Λ 的次序与 X 的列次序配错——第 k 列特征向量必须配第 k 个特征值, 这是幂运算与差分方程里最常见的错位。

[problem] Problem 2 (问题 2)

教材 §1.6, p.37-41 | Manual, Problem Set 1.6 题 2

请计算 A 与 A^{-1} 的 eigenvalues (特征值) 和 eigenvectors (特征向量), 并校验 trace (迹) ! 其中

$$A = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix} \quad \text{and} \quad A^{-1} = \begin{bmatrix} -1/2 & 1 \\ 1/2 & 0 \end{bmatrix}$$

矩阵 A^{-1} 与 A 具有 ____ 的 eigenvectors; 当 A 的特征值为 λ_1 与 λ_2 时, 它的 inverse (逆矩阵) 的特征值为 ____。

Original (英文原题) : Compute the eigenvalues and eigenvectors of A and A^{-1} . Check the trace !

$$A = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix} \quad \text{and} \quad A^{-1} = \begin{bmatrix} -1/2 & 1 \\ 1/2 & 0 \end{bmatrix}$$

A^{-1} has the ____ eigenvectors as A . When A has eigenvalues λ_1 and λ_2 , its inverse has eigenvalues ____ .

[solution] 一、结论

先给答案, 再给推导与校验。两个空依次填 **same (相同)** 与 $\lambda_1^{-1}, \lambda_2^{-1}$ (**取倒数**) 。

矩阵 A 的两个特征值: $\lambda_1 = 2$ 对应 eigenvector (特征向量) 方向 $\text{span}\{(1, 1)\}$; $\lambda_2 = -1$ 对应方向 $\text{span}\{(2, -1)\}$ 。

矩阵 A^{-1} 的两个特征值: $\mu_1 = 1/2$ 对应同一个方向 $\text{span}\{(1, 1)\}$; $\mu_2 = -1$ 对应同一个方向 $\text{span}\{(2, -1)\}$ 。注意 $\mu_2 = \lambda_2^{-1} = -1$ 与 λ_2 数值相同, 这不是笔误, 而是因为 -1 是「取倒数」这个映射的 fixed point (不动点) 。

另一个必须先说清的问题: 题面给的 A^{-1} 是否确实等于 A 的逆? **验算通过**。因为 $\det A = 0 \cdot 1 - 2 \cdot 1 = -2 \neq 0$, 矩阵可逆, 由 2×2 逆矩阵公式 (伴随矩阵除以行列式) 得

$$> A^{-1} = \frac{1}{\det A} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{-2} \begin{bmatrix} 1 & -2 \\ -1 & 0 \end{bmatrix} = \begin{bmatrix} -1/2 & 1 \\ 1/2 & 0 \end{bmatrix}$$

与题面逐元素一致。这一步不可跳过：后面所有关于 A^{-1} 的谱的断言，都建立在「题面矩阵确实是 A^{-1} 」之上。

二、方法一：特征多项式法（定义直推，机械但普适）

这一步看到的是「特征值是多项式方程的根」这一代数事实，对任何阶数、任何元素类型都成立。写出

$$> \det(A - \lambda I) = \begin{vmatrix} -\lambda & 2 \\ 1 & 1-\lambda \end{vmatrix} = (-\lambda)(1-\lambda) - 2 = \lambda^2 - \lambda - 2 = (\lambda - 2)(\lambda + 1)$$

所以 $\lambda_1 = 2, \lambda_2 = -1$ 。对应齐次方程组 $(A - \lambda I)x = 0$ 的 null space（零空间）就是 eigenspace（特征空间）：

$$> \lambda = 2: A - 2I = \begin{bmatrix} -2 & 2 \\ 1 & -1 \end{bmatrix} \sim \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix} \Rightarrow x_1 = x_2 \Rightarrow v_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$> \lambda = -1: A + I = \begin{bmatrix} 1 & 2 \\ 1 & 2 \end{bmatrix} \sim \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix} \Rightarrow x_1 = -2x_2 \Rightarrow v_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$$

适用条件：只需会算行列式与解线性方程组，无任何附加假设。劣势： n 阶时要展开 n 次行列式，计算量随阶数爆炸，且高阶展开容易错符号。

同样的机械流程对 A^{-1} 做一遍，得到**独立的第二组数据**：

$$> \det(A^{-1} - \mu I) = \begin{vmatrix} -1/2 - \mu & 1 \\ 1/2 & -\mu \end{vmatrix} = \mu^2 + \frac{1}{2}\mu - \frac{1}{2} = \left(\mu - \frac{1}{2}\right)(\mu + 1)$$

所以 A^{-1} 的特征值为 $\mu_1 = 1/2, \mu_2 = -1$ 。对应的零空间分别是 $\text{span}\{(1, 1)\}$ ($\mu = 1/2$ 时 $A^{-1} - \frac{1}{2}I = \begin{bmatrix} -1 & 1 \\ 1/2 & -1/2 \end{bmatrix}$ ，由第 1 行 $-x_1 + x_2 = 0$ 得 $x_1 = x_2$) 与 $\text{span}\{(2, -1)\}$ ($\mu = -1$ 时 $A^{-1} + I = \begin{bmatrix} 1/2 & 1 \\ 1/2 & 1 \end{bmatrix}$ ，由第 1 行 $\frac{1}{2}x_1 + x_2 = 0$ 得 $x_1 = -2x_2$)。与 A 的两条方向**逐条相同**，第一个空由此得到直接证据，而不是从教材结论照抄。

三、方法二：trace-det 双锁 + 特征向量不动性（利用题目给的校验提示）

这一步看到的是「 2×2 矩阵的谱被两个标量完全锁定」这一低维特权。对 2×2 矩阵，特征多项式必形如 $\lambda^2 - (\text{trace } A)\lambda + \det A$ ，因为它是首一二次式，而两个系数恰好就是初等对称多项式。本题 $\text{trace } A = 0 + 1 = 1, \det A = -2$ ，于是

$$> \lambda^2 - \lambda - 2 = 0 \Rightarrow \lambda_1 + \lambda_2 = 1, \lambda_1 \lambda_2 = -2 \Rightarrow \{\lambda_1, \lambda_2\} = \{2, -1\}$$

与题面末尾那句「校验 trace」的提示对应： $2 + (-1) = 1$ 正是 $0 + 1$ ，两个独立的校验量（和与积）同时吻合，特征值基本不可能有误。适用条件：**仅限** 2×2 （更一般地，只有当手头独立不变量的个数达到特征多项式的次数时才能锁定谱，见第六节错误 5 与译者注（其六））。优势：不算行列式展开、不解方程组，两秒钟完成，且天然自带自检。

特征向量的不动性则从定义一行推出：设 $Ax = \lambda x$ 且 $x \neq 0$ 。若 A 可逆，两边左乘 A^{-1} 得 $x = \lambda A^{-1}x$ ，即

$$> A^{-1}x = \lambda^{-1}x$$

这里必须 $\lambda \neq 0$ 才能除以 λ ；而 $\lambda \neq 0$ 恰好由 A 可逆自动保证 ($\det A = \prod \lambda_i \neq 0$)。等式两边的 x 是同一个向量，所以**特征向量没变，只是被改乘了一个新标量**。这正是第二个空填「取倒数」而不是「取相反数」或「平方」的全部理由。反过来，若 $\lambda = 0$ ， A 不可逆， A^{-1} 根本不存在，这个替换无从谈起。

四、方法三：对角化 $A = X\Lambda X^{-1}$ 与谱映射（结构性视角）

这一步看到的是「 A^{-1} 与 A 共用同一组特征向量矩阵 X 」这一整体事实，它比逐个特征对更强。把两个特征向量按列排成

$$> X = \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 2 & 0 \\ 0 & -1 \end{bmatrix}$$

因为两个特征向量线性无关 ($\det X = 1 \cdot (-1) - 2 \cdot 1 = -3 \neq 0$)， X 可逆，于是 $A = X\Lambda X^{-1}$ 。取逆得

$$> A^{-1} = (X\Lambda X^{-1})^{-1} = X\Lambda^{-1}X^{-1}, \quad \Lambda^{-1} = \begin{bmatrix} 1/2 & 0 \\ 0 & -1 \end{bmatrix}$$

中间那句等式是理解的要点： X 与 X^{-1} 在取逆时**互相交换位置而不被求逆**，只有对角因子 Λ 被求逆。所以「特征向量不变、特征值取倒数」不是巧合，而是 A 与 A^{-1} 共享同一个 X 的直接后果。

这个视角还指出适用条件：若 A 有重特征值且特征向量不够 (defective, 亏损矩阵)， X 不可逆， A^{-1} 存在时也未必能这样写。本题两个特征值互异，故 X 自动可逆。

五、三种方法的分工与优劣对照

方法一给出特征向量，但每次都要重解方程组，且不解释两矩阵为何共享特征向量；方法二最快且自带校验，但只在 2×2 生效，且**给不出特征向量**；方法三给出最强的结构断言（共用同一个 X ，对角因子互为逆矩阵 Λ 与 Λ^{-1} ），并且能直接推广到 $A^k = X\Lambda^k X^{-1}$ ，但需要先知道 A 可对角化。三种方法都用同一个矩阵，三条路径互相印证，比任何单独一条更有说服力。

六、常见错误判定

✗ 错误 1：把 A^{-1} 的特征值写成 $\lambda_1^{-1} = 1/2$ 与 $\lambda_2^{-1} = 1$ （即把 $(-1)^{-1} = -1$ 误写成 1）。错在倒数运算不熟练； -1 的乘法逆元就是它自己。核对办法： A^{-1} 的 trace 是 $-1/2 + 0 = -1/2$ ，而 $1/2 + (-1) = -1/2$ ，若写成 $1/2 + 1 = 3/2$ 立刻与 trace 冲突。

✗ 错误 2：把特征向量抄成 A 的特征向量的**逆序配对**，即写成「 A^{-1} 的特征值 $1/2$ 对应 $(2, -1)$ 、特征值 -1 对应 $(1, 1)$ 」。错在丢掉了配对关系：两个特征对不能拆开重配。反证只需一行：算 $A^{-1}(2, -1)^T = (-1/2 \cdot 2 + 1 \cdot (-1), 1/2 \cdot 2 + 0 \cdot (-1))^T = (-2, 1)^T$ ，它等于 $-1 \cdot (2, -1)^T$ ，是特征值 -1 的方向，而不是特征值 $1/2$ 的方向（ $1/2$ 要求输出 $\frac{1}{2}(2, -1)^T = (1, -1/2)^T$ ）。**特征值与特征向量必须成对书写**。

✗ 错误 3：把第一个空写成「same eigenvalues（相同特征值）」。错在空格后紧跟的名词是 eigenvectors，而两个矩阵的特征值恰恰不同（互为倒数），相同的只是特征向量方向。

✗ 错误 4: 把 $\lambda_1 \lambda_2 = \det A$ 误记成 $\lambda_1 \lambda_2 = \det A^{-1}$ 。本题 $2 \times (-1) = -2 = \det A$, 而 $\det A^{-1} = -1/2$ 。判据是按缩放规律推理: $\det(cA) = c^2 \det A$, 若特征值整体乘 c , 积按 c^2 变; 取逆使特征值取倒数, 积也取倒数, 故 $\det A^{-1} = 1/\det A$, 两条恒等式各自自治, 不能互换。

✗ 错误 5: 用 trace-det 反推特征值后, 顺手把它写成「确定了矩阵 A 」。错在把谱与矩阵混为一谈: A 与 $X \Lambda X^{-1}$ 对任意可逆 X 都有同一组特征值, 只有 X 把它固定下来。本题中 $\begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix}$ 与它的转置 $\begin{bmatrix} 0 & 1 \\ 2 & 1 \end{bmatrix}$ 特征值相同 (trace、det 均相同), 但两者不是同一个矩阵, 特征向量也不同 (前者是 $(1, 1)$, 后者是 $(1, 2)$)。相关地, 也不能把这个技巧原样搬到 3×3 : 三次多项式有三个自由系数 (trace A 、二阶主子式之和、 $\det A$), 必须三条信息齐备才能确定谱, 少一条只能否定错误答案; 而且光谱确定之后, 特征向量仍要回到 $(A - \lambda I)x = 0$ 的零空间里解出来, 谱本身不含方向信息。

✗ 错误 6: 认定「特征向量唯一」。正确的表述是: λ 的 eigenvector 是 $\text{span}\{v\}$ 中任一非零向量, v 与 $2v$ 同样合法; 本题 $\lambda = 2$ 写成 $(1, 1)$ 、 $(2, 2)$ 或 $(-1, -1)$ 都对, 写成 $(0, 0)$ 则完全错 (定义要求 $x \neq 0$)。再进一步: 若 λ 是重根, 特征空间维数可能大于一, 此时「特征向量」是一整个子空间而非一条直线。

✗ 错误 7: 对本题之外的矩阵无条件套用「特征值取倒数」。若 $\det A = 0$, A 没有逆, 题目本身不成立; 此时至少一个特征值为 0, $[0^{-1}]$ 无意义。这是一个有前提的定理。本题之所以安全, 因为 $\det A = -2 \neq 0$; 这也顺带说明: **可逆性与「零不是特征值」是同一件事的两种说法。**

七、自检 (四重校验, 全部通过)

第 1 步, 代入验算原始定义式 $Av = \lambda v$:

$$\begin{aligned} &> A \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \cdot 1 + 2 \cdot 1 \\ 1 \cdot 1 + 1 \cdot 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \checkmark \\ &> A \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \cdot 2 + 2 \cdot (-1) \\ 1 \cdot 2 + 1 \cdot (-1) \end{bmatrix} = \begin{bmatrix} -2 \\ 1 \end{bmatrix} = (-1) \begin{bmatrix} 2 \\ -1 \end{bmatrix} \checkmark \end{aligned}$$

第 2 步, 对 A^{-1} 重复同一动作。这是回答「题面矩阵是否为真逆」的最直接证据, 而且它的元素与 A 完全不同, 任何元素级抄写错误都会在这一步暴露:

$$\begin{aligned} &> A^{-1} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} -\frac{1}{2} \cdot 1 + 1 \cdot 1 \\ \frac{1}{2} \cdot 1 + 0 \cdot 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \checkmark \\ &> A^{-1} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} -\frac{1}{2} \cdot 2 + 1 \cdot (-1) \\ \frac{1}{2} \cdot 2 + 0 \cdot (-1) \end{bmatrix} = \begin{bmatrix} -2 \\ 1 \end{bmatrix} = (-1) \begin{bmatrix} 2 \\ -1 \end{bmatrix} \checkmark \end{aligned}$$

两条都与「同一方向、特征值取倒数」逐位吻合。这里补一个负例检验: 若在解 $(A - 2I)x = 0$ 时把 $-2x_1 + 2x_2 = 0$ 的比例关系抄反、得到候选 $v = (2, 1)$, 则 $A^{-1}v = (0, 1)^T$, 而按理论应得 $\frac{1}{2}v = (1, 1/2)^T$, 第一分量一个 0 一个 1, 候选立刻被淘汰。这条负例的完整剖析见译者注 (其五)。

第 3 步, trace / det 双锁: $\text{trace } A = 0 + 1 = 1 = 2 + (-1) \checkmark$; $\det A = 0 \cdot 1 - 2 \cdot 1 = -2 = 2 \cdot (-1) \checkmark$; $\text{trace } A^{-1} = -1/2 + 0 = -1/2 = 1/2 + (-1) \checkmark$; $\det A^{-1} = (-1/2) \cdot 0 - 1 \cdot (1/2) = -1/2 = (1/2) \cdot (-1) \checkmark$ 。

第 4 步, 维数与形状记账: 特征向量矩阵 $X = \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix}$ 的行列式为 $\det X = 1 \cdot (-1) - 2 \cdot 1 = -3 \neq 0$, 两特征向量线性无关, A 可对角化。又因 0 不是特征值, A 可逆, $N(A) = \{0\}$, 零空间维数为 0, 秩为 2 (秩加零空间维数等于列数 2, 即秩-零化度定理)。形状记账: A 是 2×2 , 故特征多项式次数为 2、特征值 (计代数重

数) 恰有 2 个; X 是 2×2 且两列是特征向量, Λ 与 Λ^{-1} 都是 2×2 对角阵, 全部对齐。

八、一句话: 这道题真正训练的是「谱映射 (spectral mapping) 的边界条件」——同一个线性变换的逆, 只按 $t \mapsto t^{-1}$ 改动了那 n 个标量 (特征值), 而把整套方向 (特征向量) 原封不动地保留, 前提是 A 可逆 (等价于 0 不是特征值); trace-det 双锁则给了你不依赖任何教材结论的独立校验通道。

[note] Note (译者注) ——特征向量是方向: 特征子空间把非零特征向量分成等价类, 而谱映射只改标签

把 A 看成作用在 $\mathbb{R}^2$ 上的线性映射。对给定的实数 λ , 满足 $Av = \lambda v$ 的非零向量 v , 再加上零向量, 构成 eigenspace (特征空间) $E_\lambda = N(A - \lambda I)$; 它是齐次方程组的解集, 因此一定是子空间 (对加法与数乘封闭)。

第一件要确认的事是: 不同特征值的特征空间几乎不相交。若 $v \neq 0$ 同时满足 $Av = \lambda v$ 与 $Av = \mu v$, 则 $(\lambda - \mu)v = 0$; 因为 $v \neq 0$, 只能 $\lambda = \mu$ 。所以 $\lambda \neq \mu$ 时 $E_\lambda \cap E_\mu = \{0\}$, 两个特征空间只在原点碰面。

有了这条, 就可以给全体特征向量 (即落在某个 E_λ 里的非零向量) 分类: 两个特征向量同类, 当且仅当它们落在同一个 E_λ 里。这是一条等价关系——自反、对称、传递都直接来自「属于同一个集合」; 而上一段的结论保证「所属的 λ 」唯一, 不会出现一个向量同时属于两个类。

这里与 6.042J 的关系值得说清。6.042J 里的等价关系会自动给出划分 (partition): 全体对象被切成互不相交的块; 这里结构相同——每个非零特征向量恰好落在一个块里。区别在于结论强度: 集合论上的划分只要求「不重不漏」, 对角化要求的更强, 是「特征子空间的直和必须填满整个空间」, 即

$$\mathbb{R}^n = E_{\lambda_1} \oplus E_{\lambda_2} \oplus \cdots \oplus E_{\lambda_k}, \quad \sum_i \dim E_{\lambda_i} = n$$

本题两个特征值互异, 两条特征方向各给一维, $1 + 1 = 2$, 划分刚好盖满平面, 这正是 $\det X \neq 0$ (两特征向量线性无关) 的几何含义, 也解释了为什么 X 能充当基变换矩阵。

例子的反面同样重要。若某个 λ 的几何重数 ($\dim E_\lambda$) 小于它的代数重数 (它作为特征多项式根的重数), 那么 $\sum \dim E_\lambda < n$, 划分漏掉了一部分向量, X 不可逆, 这样的矩阵叫 defective (亏损矩阵), 不能对角化。于是「数一数各特征空间的维数、看加起来是否等于 n 」成为判断能否对角化最快的通道。

可以复用的模板叫「**方向清单**」: 解出全部特征值后, 逐个算 $\dim E_\lambda = N(A - \lambda I)$ 的维数并把清单相加; 等于 n 就可以用 $X\Lambda X^{-1}$ 这套语言, 小于 n 就必须换工具。清单只依赖维数记账, 不依赖具体数值, 所以对 2×2 与 $n \times n$ 一样好用: **特征向量是方向, 方向由子空间的维数记账来清点。**

把 A 的全部特征值收集成一个集合, 记作 $\sigma(A)$, 中文叫 spectrum (谱)。本题 $\sigma(A) = \{2, -1\}$, $\sigma(A^{-1}) = \{1/2, -1\}$ 。谱映射 (spectral mapping) 说的就是这两组数之间的关系: 把同一个函数分别施加到每个特征值上。

机制只有一句话: 在 E_λ 上, A 的作用就是乘 λ 。若 $x \in E_\lambda$, 则

$$Ax = \lambda x \implies A^2x = \lambda^2x \implies A^kx = \lambda^kx$$

对任意多项式 $p(t) = a_0 + a_1t + \cdots + a_mt^m$, 把上面几行分别乘以系数再相加, 立得

$$p(A)x = p(\lambda)x$$

也就是说：任何多项式作用在 A 上，特征子空间一个都不动，特征值被逐个替换成 $p(\lambda_i)$ 。这就是为什么 A^k 、 $A + cI$ 与 A 共享全部特征向量。

取逆走的是同一套逻辑，只是证明方式不同。设 $Ax = \lambda x$ 、 $x \neq 0$ 且 A 可逆，两边左乘 A^{-1} 得 $x = \lambda A^{-1}x$ ，再除以 λ （这一步需要 $\lambda \neq 0$ ）得 $A^{-1}x = \lambda^{-1}x$ 。所以 A^{-1} 同样保持每个 E_λ 不变，只是把标签 λ 换成 λ^{-1} 。注意这里施加的「函数」 t^{-1} 并不是多项式，但只要 A 可逆，结论与多项式情形完全一致：**逐个特征子空间上的作用都退化成一个标量乘法**。

唯一的前提是：函数在谱上的每一点都有定义。 t^{-1} 在 $t = 0$ 处没有定义，而 $\lambda = 0$ 恰好等价于 $Ax = 0$ 有非零解，也就是 A 奇异。于是这条规则在可逆性的边界上断开——这不是技术性瑕疵，而是本质： $0 \in \sigma(A)$ 与「 A 不可逆」是同一件事的两种说法。

用本题核对一遍。 $E_2 = \text{span}\{(1, 1)\}$ 、 $E_{-1} = \text{span}\{(2, -1)\}$ ；施加 t^{-1} 后标签变成 $1/2$ 与 -1 ，方向不动，与正文第 2 步的代入结果逐条吻合。施加 t^2 后标签变成 4 与 1 ，方向仍不动；用 $A^2 = \begin{bmatrix} 2 & 2 \\ 1 & 3 \end{bmatrix}$ 验证： $A^2(1, 1)^T = (4, 4)^T = 4(1, 1)^T$ ，吻合。

再施加 $p(t) = t^2 - 5t + 6 = (t - 2)(t - 3)$ ： $p(2) = 0$ ， $p(-1) = 12$ 。于是 $p(A)$ 有一个零特征值，它奇异，零空间恰好是 $E_2 = \text{span}\{(1, 1)\}$ （直接算 $p(A) = A^2 - 5A + 6I = \begin{bmatrix} 8 & -8 \\ -4 & 4 \end{bmatrix}$ 也能得到同一结论）。这个例子说明谱映射会改变可逆性： $p(A)$ 可逆当且仅当所有 $p(\lambda_i) \neq 0$ 。本题的 t^{-1} 只是恰好把「非零」映成「非零」，所以可逆性与特征向量都保住了。

可复用的模板叫「**谱函数替换模板**」：把 A 在特征基下看成一组标量，对每个标量施加同一个函数，再换回来；函数在谱上处处有定义是唯一的前提，替换后要重新检查可逆性（是否出现 0）。这个模板对 A^{-1} 、 A^k 、 $A + cI$ 以及后续的矩阵指数 e^{At} 一视同仁。

[note] Note (译者注) —— (其三) trace-det 双锁校验：两条独立等式能锁住什么，锁不住什么

命名一条可复用的校验规则：「**trace-det 双锁校验**」——用「特征值之和等于 trace」与「特征值之积等于 det」两条恒等式同时锁住谱，任意一条不成立，就说明求根或代数化简有误。

它为什么在本题特别有效？因为 2×2 的特征多项式（取 $\det(\lambda I - A)$ 的约定）是首一二次式 $\lambda^2 - (\text{trace } A)\lambda + \det A$ ，两个系数恰好就是两条锁；首一二次式由两个系数唯一确定，所以两条锁同时成立时谱被钉死，不是「可能对」而是「只能是这样」。在这个意义上，双锁在 2×2 时同时承担了校验与求解两项职能。

校验要有效，两条锁必须独立：它们的值必须来自矩阵的不同元素组合，而不是同一次化简的两个中间产物。若两条锁都由同一步推导出来，一个错误会同时污染两条，校验就退化成自我复述。本题的和锁用 0 与 1，积锁要用 0, 1, 2 的交叉相乘，来源不同，所以一条响、另一条不响时能立刻分出是求根错还是抄写错——第六节的错误 4 就是靠积锁识别的。

判据的严格程度还取决于数域与浮点表示，这一点是 CSAPP 的内容。本题出现的 0, 1, 2, -1, 1/2 在二进制下都能精确表示（1/2 只是把指数域减一），所以「代入后逐位相等」可以当作判据，误差严格为零。若把 $\lambda_1 = 2$ 换成 3、保留 $\lambda_2 = -1$ ，它的倒数 1/3 在 IEEE 754 里是无限循环小数，只能存近似值，此时锁必须放宽为相对误差判据，例如

$$> |\text{trace } \tilde{A}^{-1} - (1/3 - 1)| \leq \varepsilon \cdot |\text{trace } \tilde{A}^{-1}|$$

其中 ε 取机器精度量级。区别很清楚：精确算术里恒等式可以要求「相等」，浮点里只能要求「落在误差模型允许的范围」。

与 6.006 的连接在于「校验和」思想。分治算法在合并阶段会核对子问题规模之和是否等于原问题规模（例如归并排序的递归式 $T(n) = 2T(n/2) + \Theta(n)$ 中，两侧子问题规模必须加起来等于 n ），一旦不符就定位到出错的那一层；双锁扮演同样的角色。区别在于：算法里的规模记账由算法结构保证，是设计出来的人工不变量；而 $\lambda_1 + \lambda_2 = \text{trace } A$ 由线性代数定理保证，对任意方阵无条件成立，不依赖你怎么算——后者更强，因为它连「实现是否正确」都不必假设。

双锁的边界也要写清： $n \geq 3$ 时它只是必要条件，锁不死全部根，必须配合维数记账（ n 阶矩阵计代数重数恰有 n 个特征值）与代回验算才能闭环。原因与替代方案见译者注（其六）。📖 *Strang 在 18.065 第 4 讲 (Eigenvalues and Eigenvectors, 对应 §1.6) 把这两把锁当作 2×2 的快速把握来讲*：“if I add up the 2 eigenvalues for any matrix, and I'm going to do it for this one, I get what answer? Trace.”（翻译：如果我把任意矩阵的两个特征值相加，并且就以这个矩阵为例，我会得到什么答案？迹。）他随即用同一个数组演示第二把锁：you can check by adding the two roots, do you get the same as the trace, 0 plus 0?（翻译：你可以把两个根相加来检验，结果是否与迹相同，即 0 加 0？）

课堂这段话点出了两把锁之所以能叫锁的原因：它们分别来自特征多项式的不同系数，所以互相独立。一个错误若只破坏其中一条（例如把 2 抄成 -2），另一条会立刻报警；只有当错误恰好同时破坏和与积时两把锁才会一起失效，而这种错误在 2×2 里几乎不可能手滑写出来。

[note] Note (译者注) —— (其四) Manual 答案的前提审计：结论无误，但有三处可以写得更严

先复述 Manual 的推理链： $\det(A - \lambda I) = \lambda^2 - \lambda - 2 = (\lambda - 2)(\lambda + 1) = 0$ ，得 $\lambda_1 = 2$ 、 $\lambda_2 = -1$ ；和 $2 + (-1) = 1$ 与 $\text{trace } A = 0 + 1$ 相符； A^{-1} 与 A 有相同特征向量，特征值为 $\lambda_1^{-1} = 1/2$ 与 $\lambda_2^{-1} = -1$ 。这条链的每一步都能独立验证，数值也经正文四重校验确认，**结论无误**。

第一处：它直接断言「 A^{-1} 有相同特征向量」，却没有写出前提 $\det A \neq 0$ 。本题 $\det A = -2 \neq 0$ 恰好满足；若换成 $B = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$ ，同一句话就变成「 B^{-1} 与 B 有相同特征向量」，而 B 不可逆， B^{-1} 根本不存在。严谨版本应当写成条件命题：**若 A 可逆，则对 A 的每个特征对 (λ, x) 都有 $A^{-1}x = \lambda^{-1}x$ ；反之 A 可逆当且仅当 0 不是 A 的特征值**。证明只需两行（两边左乘 A^{-1} ，再除以 $\lambda \neq 0$ ），但「 $\lambda \neq 0$ 」这个除法许可必须显式来自可逆性，不能默认。

第二处：「相同」指的是**特征空间的分解相同**，而不是「特征向量与特征值的配对相同」。Manual 的后半句其实正确给出了配对（ λ_1^{-1} 对 λ_1 的方向），但前半句若被读成「集合相同」而不追问配对，就容易写出交换后的错误配对（第六节的错误 2）。严谨版本是： **A^{-1} 与 A 有相同的特征空间分解，且 $\lambda \mapsto \lambda^{-1}$ 给出两个矩阵特征值集合之间的双射**。用等价类的语言说：划分本身不变，只是每个类换了新标签。这也解释了为什么 -1 在两个矩阵里都出现——它是不动点，换标签后仍落在自己身上，此时特征值相同而矩阵不同，两者并不矛盾。📖 *Strang 在 18.065 第 4 讲中讲到 A 与 A^{-1} 的特征值关系时，正是用这句极短的话把两者并置*：“They have the same eigenvalues.”（翻译：它们具有相同的特征值。）紧接着他又引出「相同」一词所要修饰的对象：of eigenvalues and eigenvectors.（翻译：关于特征值和特征向量。）

这两句课堂原话点出了本处要审的那一步：老师口中的「相同」是在特征值与特征向量这一对的层面上说的，而不是说两个矩阵本身相同。正因为口语里只剩「相同」两个字，才更需要补上特征空间分解这个限定，否则读者会把「集合相同」误当成「配对相同」，从而写出交换后的错误配对。

第三处：只做了和锁，没做积锁。积锁 $\det A = -2 = 2 \cdot (-1)$ 同样成立，补上才是完整的双锁；积锁在本题还额外承担一个任务——它保证 $\lambda_1 \lambda_2 \neq 0$ ，从而两个特征值都可取倒数，把「 A^{-1} 存在」与「两个空可填」连成一条链。正文自检第 3 步已补齐两条，并用 $AA^{-1} = I$ 的逐元素乘法做了第三条独立证据。

可复用的模板叫「**前提审计三步法**」：拿到任何形如「 A 的某性质在 $f(A)$ 上如何变化」的断言，先问三件事——(i) f 在哪些点没有定义（此处是 $t = 0$ ，对应 A 奇异）；(ii) 断言里的「相同」是在哪个层面上的相同（此处是子空间层面，不是向量个体层面）；(iii) 结论是否需要独立校验（此处需要，且要两条）。三步不增加计算量，却能挡掉大多数「记对了结论、用错了条件」的错误。把这次审计提炼成可复用的三步，今后遇到任何某性质在 $f(A)$ 上如何变化的断言都照走。第一步问 f 在哪些点上没有定义——本题是 $t = 0$ ，对应 A 奇异，Manual 的取倒数结论在 $\det A = 0$ 时整句作废；第二步问结论是否暗中要求方阵或可逆—— A^{-1} 只对方阵存在，题面给的 A 恰好是 2×2 ，这一步被掩盖了；第三步拿边界情形试一次——把 $\lambda = 0$ （即 $\det A = 0$ ）代进去，看断言是否仍在说人话。三步走完，结论无误但前提未写这类问题会当场暴露。这与 CSAPP 里读汇编先确认函数在哪些输入上是未定义行为是同一种纪律：先划出定义域，再谈结论。

[note] Note (译者注) —— (其五) 交叉方向代回法：用一条不同的路径去验第一条路径

这道题最容易踩的一个坑，是在解 $(A - 2I)x = 0$ 时把第一行的比例关系抄反。第一行是 $-2x_1 + 2x_2 = 0$ ，正确读法是 $x_1 = x_2$ ；若读成 $x_1 = 2x_2$ ，就会得到候选向量 $v = (2, 1)$ 。这个候选满足「看起来像特征向量」的一切表面特征——分量是整数、与矩阵元素同源——却是错的。

用 A 自己代回，本来能逮住它： $A(2, 1)^T = (0 \cdot 2 + 2 \cdot 1, 1 \cdot 2 + 1 \cdot 1)^T = (2, 3)^T$ ，与 v 不平行。但如果代回时又发生一次独立的加法失误（把 $1 \cdot 2 + 1 \cdot 1$ 写成 2 而不是 3），就会得到 $(2, 2)^T = 2(2, 1)^T$ 这个假通过——两次错误互相掩护。换一条路径就不一样：用题面给的 A^{-1} 代回，得 $A^{-1}(2, 1)^T = (-1/2 \cdot 2 + 1 \cdot 1, 1/2 \cdot 2 + 0 \cdot 1)^T = (0, 1)^T$ ，而按理论它应当是 $\frac{1}{2}(2, 1)^T = (1, 1/2)^T$ ；第一分量一个是 0、一个是 1，量级都不同，错误无处可藏。

由此得到一条可操作的规则，命名为「**交叉方向代回法**」：算完 A 的特征向量后，不要只用 A 去验，改用 A^{-1} 、 A^2 、 $A + cI$ 中的任意一个代回，并事先知道它应该输出什么。原理是这些矩阵与 A 共享全部特征子空间（见译者注（其二）），但它们的元素与 A 不同，因此不会重复 A 的元素级错误。**两条验算路径若共享同一份输入数据，就只算一条路径；独立性来自「元素不同」，不来自「算了两遍」。**

适用条件与代价要说清：目标矩阵必须已知，且它与 A 的谱之间有明确的映射关系（本题是 t^{-1} ，也可以是 t^k 、 $t + c$ ）；代价是多一次矩阵乘法， n 很大时不便宜。对 2×2 的题，代价几乎为零，收益却是直接拦下一次错答——本题的错误候选 $(2, 1)$ 若被写进答案，第一个空与第二个空会同时出错，而双锁校验对特征向量是瞎的，只有代回能发现它。

浮点情形下这条判据要改写，这是 CSAPP 的内容。特征向量的敏感度由特征向量矩阵的条件数 $\kappa(X) = \|X\| \|X^{-1}\|$ 与特征值之间的间距共同决定：间距越小、 $\kappa(X)$ 越大，输入误差被放大得越厉害。本题的两个特征值是 2 与 -1 ，间距为 3， $\kappa(X)$ 也有限，而且涉及的数 $0, 1, 2, -1, 1/2$ 在二进制下全部精确，所以「严格平行」可以作为判据；一旦元素换成不能精确表示的值，判据必须退化成「 $A^{-1}v$ 与 v 的夹角余弦与 ± 1 的相对偏差小于若干 ϵ 」。

这条方法有三条边界。第一， A 必须可逆才能用 A^{-1} 代回；若 A 奇异，改用它仍然成立的 A^2 或 $A + cI$ 。第二，必须事先知道「应当输出什么」，也就是候选向量对应的 λ 必须已知；若 λ 是重根，特征空间是一整个子空间而不是一条直线，答案不能再写成单个方向的 span，需要给出子空间的一组基。第三，浮点情形下判据要换成不等式。把这三条当成检查清单，就能判断一次代回是否真的构成独立证据。代回验算之所以比“重算一遍”更能抓错，是因为它换了一条**独立的计算路径**：重算走的是同一条推理链，同一个误解会被重复一遍，于是错误被复制而不是被发现；代回则把结论当成输入去检验原始等式 $A = X \Lambda X^{-1}$ ，走的是乘法与比较，路径不同，误差无处藏身。这也是数值线性代数里“后验误差”（backward error）的思路：不问“我算得对不对”，而问“我算出的东西满足原方程到什么程度”。

[note] Note (译者注) —— (其六) $n = 2$ 读得出、 $n \geq 3$ 要迭代：一条不能外推的捷径

本注处理方法二留下的一个陷阱：既然 trace 与 det 能两秒钟读出特征值，为什么 3×3 不照做？先把「信息量够不够」与「能不能稳定求解」分成两件事。

对任意 n 阶方阵，取约定 $\det(\lambda I - A) = \lambda^n - c_1 \lambda^{n-1} + c_2 \lambda^{n-2} - \cdots + (-1)^n c_n$ ，其中 c_k 等于全部 k 阶 principal minor（主子式）之和。于是 $c_1 = \text{trace } A$ 、 $c_n = \det A$ 。在 2×2 时，多项式只有两个自由系数，我们手头恰好有两个独立不变量，所以 trace 与 det 不只是校验，而是能直接求解。到了 $n = 3$ ，自由系数变成三个（trace A 、二阶主子式之和、 $\det A$ ），信息量仍然足够——但「够」不等于「好用」。

下一步才是真正的分界。三次方程有 Cardano 公式，可它在三个根都是实数时反而必须绕道复数立方根（casus irreducibilis），而且判别式接近零时根对系数扰动的敏感度急剧上升。到 $n \geq 5$ ，Abel–Ruffini 定理告诉我们：一般五次及以上多项式没有根式解，意思是「不存在用四则运算与开方写出的统一公式」，而不是「根不存在」。所以工程上从 $n = 3$ 起就放弃闭式路线，改用迭代：幂法求主特征值、反幂法求最小特征值、QR 迭代同时求全谱。分界线正好落在 $n = 2$ 与 $n = 3$ 之间，本题处在幸运的一侧。

用本题做一个具体对照。在 2×2 的情形， $\text{trace} = 1$ 、 $\det = -2$ ，解 $\lambda^2 - \lambda - 2 = 0$ 得 $\{2, -1\}$ ，全程有理数运算，零误差。若在右下角补一个 1、并把 (1, 3) 位置设为 1，得到

$$A_3 = \begin{bmatrix} 0 & 2 & 1 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \det(\lambda I - A_3) = (\lambda - 1)(\lambda^2 - \lambda - 2) = \lambda^3 - 2\lambda^2 - \lambda + 2$$

沿第三行展开即可验证（ $\lambda I - A_3$ 的第三行只有 $(\lambda - 1)$ 一个非零元）。三个根是 1, 2, -1，和与积分别是 2 与 -2。此时若只知道 trace 与 det，你能确定的只是「三根之和为 2、之积为 -2」，满足这两个条件的数组有无穷多组——例如数组 $\{-2, 2 + \sqrt{3}, 2 - \sqrt{3}\}$ 的和也是 2、积也是 -2，但它与 $\{2, -1, 1\}$ 不是同一组数。区分它们要靠第三把锁： A_3 的二阶主子式之和是 $-2 + 0 + 1 = -1$ ，而替代数组的两两乘积之和是 -7。所以 n 阶需要 n 个独立不变量才能钉死特征多项式，2 阶恰好只有两把锁，两把就够。

与 6.006 的连接落在「输入规模决定算法可行性」： $n = 2$ 时求特征值是 $O(1)$ 的直接读取，与二分搜索「每步砍半、对数深度」形成对照——二分搜索依赖数据已排序这一结构前提， 2×2 的闭式读取依赖「多项式次数等于手头不变量个数」这一代数前提，两者都是结构换速度，结构一撤，捷径立刻失效；而且 n 阶时连特征多项式的 n 个系数本身就要 $O(n^3)$ 级别的运算，更不必说后面还要解高次方程。与 100B 实分析的连接落在「根对系数的连续依赖」：特征多项式的系数是根的对称多项式（ $\det(\lambda I - A) = \prod_i (\lambda - \lambda_i)$ ），反过来根也是系数的连续函数；若某个根重数为 m ，系数上 ε 量级的扰动可以让根移动 $\varepsilon^{1/m}$ 量级，所以重根比互异根难算得多。本题两根互异、间距为 3，根位移与系数扰动同量级，闭式路线既快又准。

可复用的模板叫「**低维闭式—高维迭代的分界线检查**」：遇到任何「用少量标量不变量确定整体谱」的想法，先数自由系数个数 n ，再数手头**互相独立**的不变量个数 k ； $k < n$ 时只能当必要条件（用来否定错误答案）， $k = n$ 时才可能当充要条件（用来确定答案）。本题 $n = k = 2$ ，落在充要一侧。这条界线也解释了第六节错误 5 的后半句： 2×2 时双锁锁定了谱，却不锁定矩阵——谱与矩阵之间还差一个可逆的 X ，那是 $n^2 - n$ 个自由参数的去处。

九、这道题的设计意图（把小题折叠成一个设计问题）

本题只做了一道题，但它的结构比「求特征值」四个字复杂得多。把它折叠起来，它其实在问一个设计问题：**当我对一个线性变换做某种操作时，哪些信息是不变量，哪些信息会被替换？**这个问题的答案决定了你能不能少算一半步骤，也决定了你什么时候会因为少算一半而答错。这道题用最少的元素把这个问题压成了四层。

第一层是「方向与标量」的分离。等式 $Av = \lambda v$ 把矩阵对向量的作用拆成两半：方向由 v 承担，缩放倍数由 λ 承担。这个拆分之所以可能，是因为存在一些方向， A 在上面不旋转、不混合，只放大或反向。找到这些方向，矩阵作用就从「二维的线性组合」退化成「两个独立的标量乘法」。本题的特征方向是 $\text{span}\{(1, 1)\}$ 与 $\text{span}\{(2, -1)\}$ ， A 在这两个方向上的作用分别等价于乘 2 与乘 -1 。这一层回答的是「什么被保留了」。

第二层是「哪些操作只改标量、不动方向」。一旦按方向分解完成，任何只依赖 A 的代数操作都会逐方向作用：取逆把 λ 换成 λ^{-1} ，取幂把 λ 换成 λ^k ，加 cI 把 λ 换成 $\lambda + c$ 。这三条规则共享同一个前提——函数在该特征值处有定义。三条里取逆是唯一一条会在定义域边界上失效的： t^{-1} 在 $t = 0$ 处无定义，所以「取倒数」这条规则**必须**附带 A 可逆这个条件，而可逆性又恰好等价于「零不是特征值」。这一层回答的是「什么被替换了，替换的许可从哪来」。

第三层是「用什么独立证据确认替换正确」。trace 锁与 det 锁给出两条互相独立的等式：和与积。两条同时成立， 2×2 的谱就被唯一钉死；只有一条成立则只能排除错误答案。这一层的设计要点在于独立性：如果两条锁都由同一个计算步骤推出，那么同一个错误会同时污染两条锁，校验就退化成自我复述。真正有用的校验必须走与主计算不同的路径——这就是为什么「用 A^{-1} 检验 A 的特征向量」比「用 A 检验 A 的特征向量」更有价值。

第四层是「这种便利能推到多高」。在 2×2 的情形，之所以能两秒钟读出全部谱，是因为首一二次式的自由系数个数恰好等于我们掌握的不变量个数（都是二）。升到 $n \geq 3$ ，锁的数量要跟着涨，而且即使锁齐了，高次求根也未必有稳定的闭式公式。于是同一道题的解法在 $n = 2$ 与 $n = 3$ 之间发生质变：前者是读取，后者是迭代。这一层的意义在于划出适用边界：**任何捷径都必须报出自己的维数条件**，否则它就是一条会被无意识外推到失效区域的规则。

把四层叠起来看，这道题的设计意图就清楚了：它不要求你会算行列式展开（那是手段），它要求你建立一条可复用的判断链——先分离方向与标量，再确认操作的适用前提，再用独立证据闭环，最后标注这条链在哪个维数上断裂。四个环节里，任何一环缺失都会导致一种典型错误：缺第一层会把特征值与特征向量分家（第六节错误 2）；缺第二层会对奇异矩阵套用取倒数（第六节错误 7）；缺第三层会漏掉积锁、放走错答案；缺第四层会把 trace-det 技巧搬到 3×3 并误以为已经确定全部根（第六节错误 5）。教材把这道题排在 §1.6 的前几题，正是因为它用最小的规模承载了最完整的判断链：这条链一旦在 2×2 上走通，就可以直接迁移到 A^k 、 $A + cI$ 、矩阵指数 e^{At} （线性微分方程组 $\dot{x} = Ax$ 的解）这些后续主题上，因为那些情形共享同一个骨架——**在特征方向上，矩阵就是一个数**。

[problem] Problem 11 (问题 11)

教材 §1.6, p.37-41 | Manual, Problem Set 1.6 题 11 (原书 p.41)

矩阵 A 的 eigenvalues (特征值) 等于它的 transpose (转置) A^T 的 eigenvalues。理由是 $\det(A - \lambda I)$ 等于 $\det(A^T - \lambda I)$ 。而后者的成立是因为 ____。请用一个例子说明： A 与 A^T 的 eigenvectors (特征向量) 并不相同。

Original (英文原题) : The eigenvalues of A equal the eigenvalues of A^T . This is because $\det(A - \lambda I)$ equals $\det(A^T - \lambda I)$. That is true because ____ . Show by an example that the eigenvectors of A and A^T are not the same.

[solution] 一、结论 (含填空答案)

填空应写：任何一个方阵 M 都满足 $\det M = \det M^T$ (转置不改变行列式)，取 $M = A - \lambda I$ ，于是 $\det(A - \lambda I) = \det((A - \lambda I)^T) = \det(A^T - \lambda I)$ 。

由此， A 与 A^T 的 characteristic polynomial (特征多项式) 逐项相同，故特征值连同 algebraic multiplicity (代数重数) 完全一致；但特征向量集合一般不同。反例取

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}, \quad A^T = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$$

两者的特征值都是 $\lambda = 1$ 与 $\lambda = 0$ (完整计算见第五节)，而 $\lambda = 1$ 的特征空间分别为 $N(A - I) = \text{span}\{(1, 1)^T\}$ 与 $N(A^T - I) = \text{span}\{(1, 0)^T\}$ ，是两个不同的子空间。

二、方法一：行列式恒等式直接对照 (Manual 的思路，最快)

关键是 $\det M = \det M^T$ 对任意 $n \times n$ 的 M 都成立，因此对每个标量 λ 都有

$$p_A(\lambda) = \det(A - \lambda I) = \det((A - \lambda I)^T) = \det(A^T - \lambda I) = p_{A^T}(\lambda)$$

中间一步用了 $(A - \lambda I)^T = A^T - \lambda I$ (转置对减法与标量乘法都线性)。两个多项式作为 λ 的函数处处相等，所以特征值集合与每个特征值的重数都相同。

这个视角看到的是：**证明只用到一次行列式的性质，不需要知道任何特征向量的信息**；适用条件是 A 为方阵 (非方阵谈不上 $\det$ ，也谈不上特征值)，且 λ 取遍标量域；代价是它只给出“特征值”这一层的信息，对特征向量一字未提——这恰好是本题两问的分工。

三、方法二：只比较特征多项式的系数 (trace (迹) —det (行列式) 层面)

把 $p_A(\lambda) = \det(\lambda I - A) = \lambda^n - c_1\lambda^{n-1} + c_2\lambda^{n-2} - \cdots + (-1)^n c_n$ 展开，则 $c_1 = \text{tr } A$ 、 $c_n = \det A$ ，中间系数 c_k 是全部 k 阶 principal minor (主子式) 之和。(这里用的是 $\det(\lambda I - A)$ ，与方法一的 $\det(A - \lambda I)$ 相差因子 $(-1)^n$ ，两者的根完全相同，下文只在根与重数层面使用它。) 对 A^T 而言，取同一批下标集合 S 时有 $(A^T)_{SS} = (A_{SS})^T$ ，故 A^T 的每个 k 阶主子式与 A 的对应主子式相等；求和范围又完全一样，所以 A 与 A^T 的每一个 c_k 都相等。

这个视角看到的是：**特征值相同可以退化成一组更初等的等式**，其中最容易手算的是

$$\text{tr } A^T = \text{tr } A, \quad \det A^T = \det A$$

适用条件 is 任何方阵；优点是可以用两个标量快速做粗筛与验算；缺点是它只比较了系数的“对称函数”，**丢掉了方向信息**，所以无法回答第二问，也无法区分“特征值相同但矩阵不同”的矩阵 (对比 §1.6 题 13 的结论：特征值与特征向量同时相同才迫使 $A = B$)。

四、方法三：左特征向量 (left eigenvector) 与秩—零化度视角 (解释“为什么一般不同”)

称 $y \neq 0$ 满足 $A^T y = \mu y$ 为 A 的**左特征向量**，因为转置后即 $y^T A = \mu y^T$ ： y 从左边作用于 A 。于是本题等价于说：右特征向量与左特征向量一般是两组不同的向量。

结构性原因在零空间层面。 λ 是特征值当且仅当 $A - \lambda I$ 奇异，即 $N(A - \lambda I) \neq \{0\}$ ，由 rank-nullity theorem (秩—零化度定理)

$$> \dim N(A - \lambda I) = n - \text{rank}(A - \lambda I)$$

同理 $\dim N(A^T - \lambda I) = n - \text{rank}(A^T - \lambda I)$ 。由方法一（或方法二）可知两者在同一个 λ 处同时奇异，但这并不强迫两个零空间相等；事实上 $N(A^T)$ 是 A 的 left nullspace（左零空间），它一般的身份是 $N(A^T) = C(A)^\perp$ （列空间的正交补），而不是 $N(A)$ 。本题注入材料中" A 与 A^T 的零空间与左零空间互换了角色"，指的正是这一层。

这个视角看到的是：**特征向量不是 A 的"数量不变量"，而是两个不同子空间的元素**；适用条件是什么方阵，并且在讨论 geometric multiplicity（几何重数） $\dim N(A - \lambda I)$ 时是最自然的语言；缺点是它依赖零空间/正交补的语言，比前两个方法重。

五、反例的完整计算（把 Manual 给出的例子算全）

取 $A = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$, $A^T = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$ 。

对 A :

$$> A - \lambda I = \begin{bmatrix} 1-\lambda & 0 \\ 1 & -\lambda \end{bmatrix}, \quad p_A(\lambda) = (1-\lambda)(-\lambda) - 0 = \lambda(\lambda-1)$$

特征值为 $\lambda_1 = 1$, $\lambda_2 = 0$ 。对应特征向量:

$$\begin{aligned} > (A - I)x = \begin{bmatrix} 0 & 0 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Rightarrow x_1 = x_2 \Rightarrow x = t \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\ > Ax = 0 \Rightarrow \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_1 \end{bmatrix} = 0 \Rightarrow x = t \begin{bmatrix} 0 \\ 1 \end{bmatrix} \end{aligned}$$

对 A^T :

$$> A^T - \lambda I = \begin{bmatrix} 1-\lambda & 1 \\ 0 & -\lambda \end{bmatrix}, \quad p_{A^T}(\lambda) = (1-\lambda)(-\lambda) = \lambda(\lambda-1)$$

特征值同样是 1 与 0。对应特征向量:

$$\begin{aligned} > (A^T - I)y = \begin{bmatrix} 0 & 1 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = 0 \Rightarrow y_2 = 0 \Rightarrow y = t \begin{bmatrix} 1 \\ 0 \end{bmatrix} \\ > A^T y = 0 \Rightarrow \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} y_1 + y_2 \\ 0 \end{bmatrix} = 0 \Rightarrow y = t \begin{bmatrix} 1 \\ -1 \end{bmatrix} \end{aligned}$$

汇总成表:

特征值	A 的特征向量	A^T 的特征向量
$\lambda = 1$	$\text{span}\{(1, 1)^T\}$	$\text{span}\{(1, 0)^T\}$

特征值	A 的特征向量	A^T 的特征向量
$\lambda = 0$	$\text{span}\{(0, 1)^T\}$	$\text{span}\{(1, -1)^T\}$

两个特征值对应的特征空间**全部不同**，故" A 与 A^T 的特征向量不相同"得证。（Manual 给出的例子是 $\begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$ 与它的转置 $\begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$ ，两者互为转置、特征值恰为 $\{1, 0\}$ ；这里把两边的特征值与特征向量各自算全。）

六、常见错误判定

✗ 把" A 与 A^T 相似"或" A 与 A^T 有相同的列空间"当成空格的答案——这两句话的错法不同，要分开看。"有相同的列空间"是假命题：转置一般不保持列空间（本题反例中 $C(A) = \text{span}\{(1, 1)^T\}$ ， $C(A^T) = \text{span}\{(1, 0)^T\}$ ），它从来不是特征多项式相同的理由。" A 与 A^T 相似"本身是真命题（任意方阵都与它的转置相似），但答非所问：第一，证明它要用 Jordan 型或有理标准形，本节没有这个工具；第二，它对这一格的帮助是间接的——即便承认它，还要再走一步"相似矩阵有相同的特征多项式"，而那条性质的证明又回到 $\det(S^{-1}MS) = \det M$ 这类行列式乘法性质，绕了一圈，而 $\det M = \det M^T$ 把 $M = A - \lambda I$ 一代就是一步。

✗ 写 $\det(A - \lambda I) = \det(A^T - \lambda I)$ 的依据是"矩阵相等"——错在把标量等式与矩阵等式混为一谈。 $A - \lambda I$ 与 $A^T - \lambda I$ 一般不相等（本题反例中前者为 $\begin{bmatrix} 1-\lambda & 0 \\ 1 & -\lambda \end{bmatrix}$ ，后者为 $\begin{bmatrix} 1-\lambda & 1 \\ 0 & -\lambda \end{bmatrix}$ ），相等的是它们的行列式这一标量。

✗ 写 $(A - \lambda I)^T = A^T + \lambda I$ ——错在符号，转置是线性映射， $(cM)^T = cM^T$ ，常数 λ 与 I 都原样保留，故为 $A^T - \lambda I$ 。

✗ 认为"特征多项式相同 $\Rightarrow$ 特征向量相同"——错在把"数量信息"当成"方向信息"。反例已给出：两边的 $\lambda = 1$ 特征空间分别是 $\text{span}\{(1, 1)^T\}$ 与 $\text{span}\{(1, 0)^T\}$ 。这一错误正是本题第二问的靶子，也与注入材料中题 13 的结论相呼应：只有特征值与特征向量同时相同，才被迫 $A = B$ 。

✗ 举反例时取 $A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 或任何对称矩阵——错在自毁条件。若 $A = A^T$ ，则两边是同一个矩阵，特征向量当然相同（见下方自检中的 $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ ），举这种例子的方向恰好与命题相反。

✗ 举例时说" A 的特征向量是 $(1, 1)^T$ ， A^T 的特征向量是 $(0, 1)^T$ ，二者正交，所以不同"——错在三处：一是把 A^T 在 $\lambda = 1$ 处的特征向量写成了 $(0, 1)^T$ ，正确结果是 $(1, 0)^T$ ；二是 $(1, 1)^T \cdot (1, 0)^T = 1 \neq 0$ ，这两个向量并不正交，而且"正交"与"两边的特征向量不同"没有逻辑联系—— $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 的特征向量 $(1, 1)^T$ 与 $(1, -1)^T$ 互相正交， $S = S^T$ 时两边的特征向量却完全相同；三是只比了一对向量，漏掉了第二个特征值 0 对应的方向，而"不同"要求的是整个特征向量集合（每个特征空间）的不等。

✗ 只算 A 的特征向量，然后断言"由转置显然可得"——错在没有任何计算支撑。转置会改变每个分量方程（例如 $x_1 = x_2$ 变成 $y_2 = 0$ ），必须分别解两个零空间。

✗ 把"特征向量不同"写成"特征向量相反"或"特征值不同"——错在命题本身。特征值恰恰是相同的（这正是第一问的内容），不同的是特征空间这两个子空间。

七、自检（代入验算 / 维数记账 / 迹与行列式校验 / 秩的上界）

代入验算（反例）： $A(1, 1)^T = (1, 1)^T \checkmark$ ； $A(0, 1)^T = (0, 0)^T \checkmark$ ； $A^T(1, 0)^T = (1, 0)^T \checkmark$ ； $A^T(1, -1)^T = (0, 0)^T \checkmark$ 。四个等式逐一成立。

迹与行列式的双锁校验 (trace-det) : 对 A , $\text{tr } A = 1 + 0 = 1$ 等于特征值之和 $1 + 0 = 1$ ✓; $\det A = 1 \cdot 0 - 0 \cdot 1 = 0$ 等于特征值之积 $1 \cdot 0 = 0$ ✓。对 A^T , $\text{tr } A^T = 1$ 、 $\det A^T = 0$, 与同一对特征值一致 ✓。这也顺带印证了方法二的 $\text{tr } A = \text{tr } A^T$ 与 $\det A = \det A^T$ 。

维数记账: $\text{rank } A = 1$ (两列相同且非零), $n - \text{rank } A = 2 - 1 = 1 = \dim N(A)$ ✓; $\text{rank } A^T = 1$ (两行线性相关), $\dim N(A^T) = 1$ ✓。且 $N(A^T) = \text{span}\{(1, -1)^T\}$ 确实垂直于 $C(A) = \text{span}\{(1, 1)^T\}$, 验证了 $N(A^T) = C(A)^\perp$ 这一关系 ✓。

秩的上界: λ 是特征值等价于 $A - \lambda I$ 奇异, 此时 $\text{rank}(A - \lambda I) \leq n - 1$; 本题两个矩阵在 $\lambda = 1$ 处都取到上界 $\text{rank} = 1 = 2 - 1$ ✓。

重数记账: 本题两个特征值 $\lambda = 1$ 与 $\lambda = 0$ 互不相同, 所以两边每个特征值的 algebraic multiplicity (代数重数) 都是 1, 并且 algebraic multiplicity 等于 geometric multiplicity (几何重数), A 与 A^T 都可对角化 (互不相同的特征值自动给出两个线性无关的特征向量), 不存在亏损 (defective) 情形。两类重数都被转置保留, 但理由不同: 代数重数由特征多项式守恒; 几何重数要用 $\text{rank } M = \text{rank } M^T$ 单独补一步, 即 $\dim N(A - \lambda I) = n - \text{rank}(A - \lambda I) = n - \text{rank}(A^T - \lambda I) = \dim N(A^T - \lambda I)$ 。若 $A = V \Lambda V^{-1}$ 可对角化, 则 $A^T = (V^T)^{-1} \Lambda V^T$, 也就是 A^T 的特征向量矩阵可以取成 $(V^{-1})^T$: 本题 $V = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ (两列是 $(1, 1)^T$ 与 $(0, 1)^T$), 而 $(V^{-1})^T = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$ 的两列正是 $(1, 0)^T$ 与 $(1, -1)^T$, 与第五节的计算完全一致——"特征向量为什么会不同"由此落到公式上。

对称情形对照 (说明"不同"是非对称现象): 取 $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, $S = S^T$, $p_S(\lambda) = \lambda^2 - 4\lambda + 3$, 特征值 3, 1 ($\text{tr } S = 4$ ✓, $\det S = 3$ ✓), 特征向量 $(1, 1)^T$ 与 $(1, -1)^T$ 属于同一个矩阵的两个方向; S 对称意味着转置不改变矩阵本身, 特征向量当然一字不变。方向要小心: $A = A^T$ 时两边的特征向量必然相同, 但 $A \neq A^T$ 时特征向量却可能恰好相同——把二维旋转块与标量块拼起来

$$> A_0 = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 2 \end{bmatrix}, \quad A_0^T = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

两个矩阵的实特征向量都只有 $(0, 0, 1)^T$ 这一个方向 (旋转块在实数域上没有特征向量), 而 $A_0 \neq A_0^T$ 。能保证"不同"的一个充分条件是: A 可对角化且 $A \neq A^T$ ——此时特征空间张成整个空间, 若两边的特征向量集合相同, 则 A 与 A^T 在每个特征空间上取值相同, 于是 $A = A^T$, 矛盾。

八、一句话: 这道题真正训练的是把"特征值"和"特征向量"当作两种不同等级的不变量来对待——前者是转置不变的标量清单, 后者是依赖方向、一般不守恒的几何对象。

[note] Note (译者注) —— (其一) 为什么特征值相同而特征向量不同: 信息丢在哪一步

设计问题是: 把 A 换成 A^T 时, 究竟哪一部分信息被守恒定律保护, 哪一部分被丢掉? 答案的位置很精确——丢在"行列式只记录对称函数"这一步。

从第一性原理看, 特征多项式 $p_A(\lambda) = \det(\lambda I - A)$ 是 λ 的一元多项式, 它的系数是 A 的各阶 principal minor (主子式) 之和: k 阶主子式要求"行指标集合与列指标集合取同一批下标", 这个要求对"行"与"列"这两个角色完全对称, 而转置恰好只交换这两个角色, $\det M = \det M^T$ 又保证每个主子式的数值不变。于是 A 与 A^T 的每个系数逐项相同, 特征值作为 p_A 的根, 连同每个根的 algebraic multiplicity (代数重数) 一起被保留下来。两个极端系数就是熟悉的那两条: $c_1 = \text{tr } A$ 是特征值之和, $c_n = \det A$ 是特征值之积 (Vieta (韦达) 定理), 所以"迹与行列式守恒"只是这个系数守恒的两个特例。

拿一个 2×2 的例子把这一步走完： $A_1 = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 的一阶主子式之和是 $1 + 2 = 3$ ，二阶主子式是 2 ，于是 $p_{A_1}(\lambda) = \lambda^2 - 3\lambda + 2$ ，根为 $1, 2$ ； $A_1^T = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}$ 的同一批主子式仍是 3 与 2 ，特征多项式一字不差。但方向已经换了： $\lambda = 1$ 时 A_1 的特征向量由 $x_2 = 0$ 给出，是 $(1, 0)^T$ ， A_1^T 的特征向量由 $y_1 + y_2 = 0$ 给出，是 $(1, -1)^T$ 。同一个根、两个方向，这就是整道题的极小样本。

但根只回答“在哪些 λ 处 $A - \lambda I$ 变奇异”，不回答“奇异的方向”。方向信息藏在 nullspace （零空间）里，而零空间要靠消元去解，消元过程对行与列并不对称——这就是信息丢失的准确位置。

消元也解释了为什么两边的零空间会落在不同位置：求 $N(A - \lambda I)$ 时做的是行消元，主元由行的线性组合决定；换成 $N(A^T - \lambda I)$ 时，等价的运算变成对 $A - \lambda I$ 的列做同样操作。主元个数（也就是秩）两边一样，得到的子空间却不一样。

把它写成可核算的形式： λ_0 的 geometric multiplicity（几何重数）是 $\dim N(A - \lambda_0 I) = n - \text{rank}(A - \lambda_0 I)$ ，左特征向量所在空间 $N(A^T - \lambda_0 I)$ 的维数是 $n - \text{rank}(A^T - \lambda_0 I)$ 。因为 $\text{rank } M = \text{rank } M^T$ ，这两个维数必然相等。这一步不能从“特征多项式相同”推出，它属于维数层的守恒，要单独用秩的转置不变性补证。维数相等也不等于子空间相等：正文反例在 $\lambda = 1$ 时两边秩都是 1 、维数都是 1 ，子空间却分别是 $\text{span}\{(1, 1)^T\}$ 与 $\text{span}\{(1, 0)^T\}$ 。维数相同、子空间不同，是这道题最容易被跳过的一句话。

可对角化的情形能把机制说得更死：若 $A = V\Lambda V^{-1}$ ，则 $A^T = (V^T)^{-1}\Lambda V^T$ ，所以 A^T 的特征向量矩阵可以取成 $(V^T)^{-1} = (V^{-1})^T$ ，即转置把特征向量矩阵换成它的逆转置；正文反例里 $V = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ ， $(V^{-1})^T = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}$ 的两列正是 $(1, 0)^T$ 与 $(1, -1)^T$ ，与第五节的解完全对上。两边特征向量集合相同当且仅当 V 能取成正交矩阵，而实矩阵能取到正交特征向量系恰好等价于 A 对称：在可对角化的前提下，若两边的特征向量集合相同，则每个特征向量 x 都满足 $Ax = A^T x$ ，而它们张成整个空间，于是 $A = A^T$ ；反之 A 对称时 spectral theorem（谱定理）给出正交特征向量系。换句话说，特征向量在转置下改变不是偶然，而是“逆转置一般不还原向量本身”的必然结果； A 对称时这个差别才消失。

[note] Note（译者注）——（其二）左特征向量、投影矩阵与 SVD：方向层为什么不守恒

（其一）的记账停在“维数守恒、子空间不守恒”。这条注把这个现象放进三个具体场景里验证：投影矩阵、等价关系与划分、奇异值分解。

第一个场景是投影矩阵。正文反例 $A = \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$ 本身就是秩一幂等矩阵（ $A^2 = A$ ），即沿 $N(A) = \text{span}\{(0, 1)^T\}$ 到 $C(A) = \text{span}\{(1, 1)^T\}$ 的投影。因为 $(1, 1)^T \cdot (0, 1)^T = 1 \neq 0$ ，投影方向与核不垂直，这是 oblique projection（斜投影），不是正交投影。对任何 projection matrix（投影矩阵） P （ $P^2 = P$ ）都有 $\mathbb{R}^n = C(P) \oplus N(P)$ ，且由 $C(M^T) = N(M)^\perp$ 得 $C(P^T) = N(P)^\perp$ 与 $N(P^T) = C(P)^\perp$ ：转置把两个特征空间各自换成正交补。于是 P^T 与 P 有相同的 1 特征空间，当且仅当 $C(P) \perp N(P)$ ，也就是 P 为正交投影（等价于 $P = P^T$ ）。本题的 $C(A)$ 与 $N(A)$ 不垂直，所以两个子空间在转置后都动了： $\lambda = 1$ 与 $\lambda = 0$ 的特征空间分别从 $\text{span}\{(1, 1)^T\}$ 、 $\text{span}\{(0, 1)^T\}$ 变成 $\text{span}\{(1, 0)^T\}$ 、 $\text{span}\{(1, -1)^T\}$ 。若想让 1 的方向不动，就把 P 换成对称的正交投影，例如 $\frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ ：它的 1 特征空间是 $\text{span}\{(1, 1)^T\}$ 、 0 特征空间是 $\text{span}\{(1, -1)^T\}$ ，两者正交，转置后两个子空间都不动。

第二个场景是 6.042J 的等价关系。任何函数 $f: X \rightarrow Y$ 都诱导出 X 上的等价关系 $x \sim x' \iff f(x) = f(x')$ ，等价类就是纤维。取 $f(x) = Ax$ ，纤维正是核 $N(A)$ 的陪集，于是 A 与 A^T 给出两个划分： $N(A)$ 划分 $\mathbb{R}^n$ ， $N(A^T)$ 划分 $\mathbb{R}^m$ ，只有 $m = n$ 时才是同一个集合上的两种划分，而且一般不同（本题反例中， A 的纤维是平行于

$(0, 1)^T$ 的直线, A^T 的纤维是平行于 $(1, -1)^T$ 的直线)。区别在于: 等价类不带数值标签, 而特征空间带着标签 λ , 并且一般既不覆盖整个空间、也不两两不交 (不同特征空间只在零向量处相交); 只有当 A 有 n 个线性无关的特征向量时, 这些带标签的子空间才拼成 $\mathbb{R}^n$ 的直和。所以"划分"与"特征分解"是两种结构, 不能互相代替。

第三个场景是 18.065 的 SVD (singular value decomposition, 奇异值分解)。 $Av_i = \sigma_i u_i$ 与 $A^T u_i = \sigma_i v_i$ 把两套方向清单用同一个 σ_i 成对绑定, 配对的根据是 $A^T A$ 与 AA^T 的非零特征值完全相同: 若 $A^T Ax = \sigma^2 x$ ($x \neq 0, \sigma > 0$), 左乘 A 得 $AA^T(Ax) = \sigma^2(Ax)$, 即 A 把 $A^T A$ 的特征向量映成 AA^T 的特征向量。这里可以逐个核对左右特征向量配对的强弱: 本题反例中 $\lambda = 1$ 的右特征向量 $x = (1, 1)^T$ 与左特征向量 $y = (1, 0)^T$ 满足 $y^T x = 1 \neq 0$; 而 $\lambda = 0$ 的左特征向量 $(1, -1)^T$ 与 x 的内积为 0, 这正是"特征值不同则左右特征向量必正交" ($y_j^T x_i = 0, \lambda_i \neq \lambda_j$)。缺陷矩阵连同一个特征值的配对也保不住: $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 的右特征向量 $(1, 0)^T$ 与左特征向量 $(0, 1)^T$ 都对应 $\lambda = 1$, 内积却是 0。所以 SVD 的左右两组奇异向量是"一个标量、两套方向"的正向绑定, 而不是"特征向量的转置版本"。

可复用的命名模板: 转置守恒表——标量层守恒、方向层不守恒、维数层需另证。遇到任何关于 A 与 A^T 的断言, 先问它落在哪一层: tr 、 $\det$ 、特征多项式、特征值与代数重数属于标量层, 守恒; 特征向量、列空间、零空间属于方向层, 一般不守恒; 几何重数、可对角化性属于维数层, 数值上守恒, 但要靠秩的转置不变性补证。收束回正文: 本题第一问是标量层的守恒声明, 第二问是方向层的不守恒反例, 自检里的重数记账则是维数层的补证。

[note] Note (译者注) —— (其三) $\det M = \det M^T$ 从哪里来: Leibniz 公式与三层洋葱

设计问题是: 一个看似平凡的恒等式, 凭什么能撑起"特征值相同、行秩等于列秩、 $A^T A$ 的可逆判据"一整族结论?

先看机制本身。行列式的 Leibniz formula (莱布尼茨公式) 写为

$$\det M = \sum_{\sigma \in S_n} \text{sgn}(\sigma) \prod_{i=1}^n M_{i, \sigma(i)}$$

求和跑遍所有 permutation (排列) σ , sgn 是排列的符号。在 $n = 2$ 时它只剩两项: σ 取恒等排列给出 $M_{11}M_{22}$, 取对换给出 $-M_{12}M_{21}$; 转置把两个因子次序对调, 而乘法可交换, 所以两项各自不变。一般情形同样: 转置把 $M_{i, \sigma(i)}$ 换成 $M_{\sigma(i), i}$, 也就是把 σ 换成它的逆 σ^{-1} (因为 $\sigma(i) = j \iff i = \sigma^{-1}(j)$)。关键的第一性原理只有一条: 排列与其逆的符号相同, $\text{sgn}(\sigma^{-1}) = \text{sgn}(\sigma)$; 而"取逆"是全体排列上的双射, 所以求和项被——对应地重排, 总和不变。这就得到 $\det M = \det M^T$ 。另一种等价的看法是 cofactor expansion (代数余子式展开): 按第 i 行展开与按第 i 列展开用的是同一批余子式, 因此给出同一个值——注入材料中"按行展开与按列展开给出同一个值"正指此路。要注意余子式展开本身也要由 Leibniz 公式证明, 它只是同一个事实的另一种读法, 不是第二条独立的公理。

由此可以套一个三层洋葱模型, 逐层剥离 M 的结构。最外层是行列式层: $\det M = \det M^T$ 保证可逆性在转置下不变 (可逆等价于 $\det \neq 0$)。中间层是多项式层: 取 $M = A - \lambda I$, 特征多项式逐项相等, 于是特征值、代数重数、 tr 、 $\det$ 在 A 与 A^T 之间相同; 其中 minimal polynomial (最小多项式) 也相同, 但理由不是"特征多项式相同"——同样的特征多项式可以对应不同的最小多项式 (I_2 与 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 的特征多项式都是 $(\lambda - 1)^2$, 最小多项式却是 $\lambda - 1$ 与 $(\lambda - 1)^2$)。 A^T 与 A 的最小多项式相同有它自己的初等机制: 转置是反自同构, $(MN)^T = N^T M^T$, 因此对任何多项式 q 都有 $q(A)^T = q(A^T)$, 于是 $q(A) = 0 \iff q(A^T) = 0$, 两边被同一批多项式零化。更远的结论是 A 与 A^T 甚至相似 (similar), 它的标准证法要用 Jordan 型或有理标准形, 超出本节范围, 本注只把它记为"结论为真、此处不展开"。最内层是子空间

层：转置把"行"与"列"这两个角色互换，凡是不对称于这两个角色的对象都不守恒—— $C(A)$ 与 $C(A^T)$ 一般不同， $N(A)$ 与 $N(A^T)$ 一般不同；而 $N(A^T) = C(A)^\perp$ 恰好把这种不守恒量化为"换成正交补"。维数类的不变量（rank、dim N ）仍然守恒，那是（其一）里交代过的维数层。三个层次的守恒力度是递减的：越往内，对象携带的信息越具体（从数到多项式到子空间），越经不起转置这一下折腾。

用一个具体例子同时验证三层：取 $M = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ ， $\det M = 1 \cdot 4 - 2 \cdot 3 = -2 = \det M^T$ ✓（外层）； $\text{tr } M = \text{tr } M^T = 5$ ，且 $p_M(\lambda) = \lambda^2 - 5\lambda - 2 = p_{M^T}(\lambda)$ ✓（中层）； $N(M)$ 满足 $x_1 + 2x_2 = 0$ ， $3x_1 + 4x_2 = 0$ ，得 $x = 0$ ， $N(M^T)$ 满足 $x_1 + 3x_2 = 0$ ， $2x_1 + 4x_2 = 0$ ，也得 $x = 0$ ——本例两边零空间都只有零向量，这提醒我们"子空间不同"与"两边都平凡"并不矛盾，真正体现差异要让矩阵奇异（如正文反例 $\det = 0$ ）。另外要记住：两层守恒并不等于矩阵相同， A 与 A^T 的全部差别都藏在最内层，所以任何只用 tr 、 $\det$ 、特征值做的检验都不可能发现这个差别，这正是自检里那套双锁校验只能当粗筛的原因。

[note] Note（译者注）——（其四）转置不变量的跨课程连接与可复用模板

在 18.06 里，"行秩等于列秩"的常用证法是消元：对 A 做行消元得到 row echelon form（行阶梯形），主元个数既数出了独立行也数出了独立列。这道题给出另一条更省力的路径：秩等于"最大非零子式的阶数"，而任意 k 阶子式在转置下变成对应子式的转置，由 $\det M = \det M^T$ 知非零性不变，所以 $\text{rank } A = \text{rank } A^T$ ；又因为"最大非零子式的阶数"可以同时读作行秩与列秩，两者必然相等。这条路径对矩形矩阵同样有效（ $m \times n$ 的子式阶数不超过 $\min(m, n)$ ，转置把子式集合——对应到 $n \times m$ 的情形），所以行秩等于列秩不是方阵的专利。区别在于：消元法给出主元位置这类构造性信息，顺手就能算出秩、行列式与解空间；子式法只给出一个数，不产生算法。

这条路径还顺手把"秩等于最大非零子式阶数"这句话讲清楚了：一个非零的 k 阶子式落在 k 行与 k 列上，这 k 行线性无关、 k 列也线性无关，所以秩至少是 k ；反过来秩为 r 时取 r 个线性无关的行与 r 个线性无关的列，交叉处的 $r \times r$ 子矩阵必可逆，于是存在非零的 r 阶子式。18.065 里反复出现的 $A^T A$ 判据也搭在这条链上：

$N(A^T A) = N(A)$ ，于是 $A^T A$ 可逆当且仅当 A 的列线性无关。

与 6.006 的连接在计算侧。对一个 $n \times n$ 矩阵做 LU 消元需要 $\Theta(n^3)$ 量级的乘加（约 $2n^3/3$ 次）：对 M 做列消元与对 M^T 做行消元是同一批运算的转置版本，算术次数完全相同，区别在循环次序——行消元按行扫，列消元按列扫，这正是 6.006 里"同一算法换个循环嵌套顺序"的操作，渐近代价函数不变。但 6.006 的代价模型只数运算次数，不区分访问顺序，而 C 与 NumPy 的数组按行优先存储，缓存命中率因此不同（CSAPP 存储层次与局部性的直接后果），实际耗时并不相同。舍入次序也不同：浮点加法不满足结合律（CSAPP 浮点表示与舍入的直接后果），两条路径把误差按不同次序累积，结果可能相差若干 ulp（unit in the last place，末位单位）。因此数学上 $\det M = \det M^T$ 严格成立，数值上两条路径的结果不必逐位相同。这也是大矩阵判奇异时通常看最小奇异值 $\sigma_{\min}$ 或 R 的对角元、而不看 $\det$ 的原因之一： $\det$ 还有动态范围问题， 100×100 的矩阵即使每行范数约为 1， $|\det M|$ 仍可以小到 10^{-100} 量级，与 0 直接比较没有意义；而 $\sigma_{\min}$ 是尺度可比的量，阈值容易定。

可复用的命名模板：转置洋葱——行列式层守恒、特征多项式层守恒、子空间层转正交补，配合一句检查口令"先问这一层是标量还是方向"。收束回正文：题目要求填的那一格之所以只能是 $\det M = \det M^T$ ，是因为它是这个洋葱的最外层，也是唯一能直接从 $A - \lambda I$ 推到它的转置的一步；再往里走，得到的就不再是行列式的等式，而是方向层的失效——这正是第二问要你例子确认的事。

[problem] Problem 15 (问题 15)

教材 §1.6, p.37–41 | Manual, Problem Set 1.6 题 15

(a) 把下面两个矩阵因式分解 (factor) 成 $A = X\Lambda X^{-1}$:

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} \quad \text{and} \quad A = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix}$$

(b) 若 $A = X\Lambda X^{-1}$, 则 $A^3 = (\quad)(\quad)(\quad)$ 且 $A^{-1} = (\quad)(\quad)(\quad)$ 。(三个括号里各填一个矩阵; X 与其逆 (inverse) X^{-1} 都不许展开成数值, 只填字母形式的三个因子。)

Original (英文原题): (a) Factor these two matrices into $A = X\Lambda X^{-1}$: $A = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}$ and $A = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix}$. (b) If $A = X\Lambda X^{-1}$ then $A^3 = (\quad)(\quad)(\quad)$ and $A^{-1} = (\quad)(\quad)(\quad)$.

[solution] 一、结论

一、结论 (先说答案, 再验证)

第一个矩阵 (上三角 (upper triangular), 对角元 1, 3) :

$$> A_1 = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}}_{X_1} \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}}_{\Lambda_1} \underbrace{\begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix}}_{X_1^{-1}}$$

第二个矩阵 (秩 (rank) 为 1, 迹 (trace) 为 4) :

$$> A_2 = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 \\ -1 & 3 \end{bmatrix}}_{X_2} \underbrace{\begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}}_{\Lambda_2} \underbrace{\frac{1}{4} \begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix}}_{X_2^{-1}}$$

于是 (b) 的一行通用答案 (对上面两个可对角化矩阵都成立; Λ^{-1} 里的 λ_i^{-1} 是逐项取倒数) :

$$> A^3 = X\Lambda^3 X^{-1}, \quad A^{-1} = X\Lambda^{-1} X^{-1}$$

即 $A^3 = (X)(\Lambda^3)(X^{-1})$, $A^{-1} = (X)(\Lambda^{-1})(X^{-1})$ 。第二式附带一个**前提**: 所有 $\lambda_i \neq 0$ 。本题第二个矩阵 $\lambda = 0$, 是不可逆 (singular) 的, 故对 A_2 只有第一式成立, 第二式不成立。

二、方法一：行列式法 (characteristic polynomial) + 零空间求向量

标准流程是两步：先解 $\det(A - \lambda I) = 0$ 得特征值 (eigenvalue)，再对每个 λ 解 $(A - \lambda I)x = 0$ 的零空间 (nullspace) 得特征向量 (eigenvector)。注意第二步求出的零空间永远含零向量本身，所以“特征向量”严格说是**非零解**。

对 A_1 : $\det(A_1 - \lambda I) = (1 - \lambda)(3 - \lambda)$, 根为 $\lambda = 1, 3$ 。再算两个零空间:

$$> A_1 - I = \begin{bmatrix} 0 & 2 \\ 0 & 2 \end{bmatrix} \Rightarrow x_2 = 0, x_1 \text{ free} \Rightarrow x^{(1)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$> A_1 - 3I = \begin{bmatrix} -2 & 2 \\ 0 & 0 \end{bmatrix} \Rightarrow x_1 = x_2 \Rightarrow x^{(2)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

对 A_2 : $\det(A_2 - \lambda I) = (1 - \lambda)(3 - \lambda) - 3 = \lambda^2 - 4\lambda = \lambda(\lambda - 4)$, 根为 $\lambda = 0, 4$ 。零空间:

$$> A_2 - 0I = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} \Rightarrow x_1 + x_2 = 0 \Rightarrow x^{(0)} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$> A_2 - 4I = \begin{bmatrix} -3 & 1 \\ 3 & -1 \end{bmatrix} \Rightarrow 3x_1 = x_2 \Rightarrow x^{(4)} = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

把特征向量按列排成 X , 特征值按**同一顺序**放到 Λ 的对角线上, 就得到上面两个分解。这一步的关键机制是: $(A - \lambda_i I)x^{(i)} = 0$ 逐列等价于 $AX = X\Lambda$; 只要 X 可逆, 右乘 X^{-1} 即得 $A = X\Lambda X^{-1}$ 。此处 $\det X_1 = 1 \cdot 1 - 1 \cdot 0 = 1 \neq 0$, $\det X_2 = 1 \cdot 3 - 1 \cdot (-1) = 4 \neq 0$, 两个 X 都可逆。

这个视角看到的是**存在性**: 只要 n 个特征向量线性无关, X^{-1} 就存在, 分解就合法。它的代价是要真解两个零空间, 成本高但适用范围最广。

三、方法二：结构法 (上三角与秩一分别走捷径)

第一个矩阵是上三角, 特征值直接读对角元, 不用展开行列式: 1, 3。但**特征向量不能读**, 仍要解零空间——这是本题最容易被偷工减料的地方。

第二个矩阵秩为 1, 于是 $N(A_2)$ 的维数 $= 2 - 1 = 1$, 含非零向量, 故 0 必是特征值; 另一特征值由不变量 $\lambda_1 + \lambda_2 = \text{tr}(A_2) = 1 + 3 = 4$ 定出, 即 4。特征向量也靠结构直接看出: A_2 的两列成比例 (第二列 $= 3 \times$ 第一列), 故行空间 (row space) 由 $\begin{bmatrix} 1 & 1 \end{bmatrix}$ 张成, 与其正交的方向 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 落在零空间里, 正是 $\lambda = 0$ 的特征向量; 而列空间方向 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 被 A_2 放大 4 倍, 正是 $\lambda = 4$ 的特征向量。

这个视角看到的是**为什么**: 秩亏缺 1 就意味着有一条非零方向被压成 0, 特征值 0 是秩亏缺的“谱指纹”; 而上三角性意味着“最后一维只被自身缩放”, 3 是先验确定的。适用条件是矩阵有结构 (三角、秩一、置换、块对角), 无结构时退回方法一。

四、方法三：秩一分解 (outer product) 视角, 直接看出谱

把 A_2 写成外积 (outer product) $A_2 = uv^T$, 取 $u = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$, $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。对任意 x 有 $A_2x = u(v^Tx)$: 结果永远落在 u 张成的一维直线上。于是分两种输入。若 $v^Tx = 0$

(即 $x \perp v$, 一条一维直线), 则 $A_2x = 0$, 这一整条线全是特征值 0 的特征向量方向; 若 $x = u$, 则 $v^Tu = 1 + 3 = 4$, 得 $A_2u = 4u$, 即 $\lambda = 4$ 。两件事合起来把整个平面解释干净了: A_2 先沿垂直于 v 的方向把向量投影掉, 再沿 u 方向放大 4 倍——是“投影 + 缩放”的复合, 不是投影本身。

这个视角看到的是**几何作用**，并且顺带解释了为什么 $\lambda = 0$ 的特征向量是 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ （垂直于 $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ ）而不是别的。它的适用条件是矩阵确实是秩一；代价是必须先把矩阵拆成外积，拆不出来就无从下手。

一个值得留意的事实：本题两个矩阵互为转置。 A_1 是上三角（列不成比例，第一列 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 、第二列 $\begin{bmatrix} 2 \\ 3 \end{bmatrix}$ 独立）， A_2 的两列成比例。转置不改变特征值（ $\det(A^T - \lambda I) = \det(A - \lambda I)$ ），但把行空间与列空间的角色互换，这正是 (a) 把两者并列的用意：同一个机制，两种极端结构。

五、验算（三处独立校验）

校验一，直接做乘法 $X\Lambda X^{-1}$ ，看是否回原矩阵。对 A_1 ，先算 $X_1\Lambda_1 = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 3 \\ 0 & 3 \end{bmatrix}$ ，再右乘 X_1^{-1} ：

$$> \begin{bmatrix} 1 & 3 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 \cdot 1 + 3 \cdot 0 & 1 \cdot (-1) + 3 \cdot 1 \\ 0 \cdot 1 + 3 \cdot 0 & 0 \cdot (-1) + 3 \cdot 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} = A_1$$

对 A_2 ，先算 $X_2\Lambda_2 = \begin{bmatrix} 1 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix} = \begin{bmatrix} 0 & 4 \\ 0 & 12 \end{bmatrix}$ ，再右乘 $\frac{1}{4} \begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix}$ ：

$$> \frac{1}{4} \begin{bmatrix} 0 \cdot 3 + 4 \cdot 1 & 0 \cdot (-1) + 4 \cdot 1 \\ 0 \cdot 3 + 12 \cdot 1 & 0 \cdot (-1) + 12 \cdot 1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 4 & 4 \\ 12 & 12 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = A_2$$

校验二，验 X^{-1} 真的是逆。对 A_1 ： $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 。对 A_2 ：

$$> \begin{bmatrix} 1 & 1 \\ -1 & 3 \end{bmatrix} \cdot \frac{1}{4} \begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 1 \cdot 3 + 1 \cdot 1 & 1 \cdot (-1) + 1 \cdot 1 \\ -1 \cdot 3 + 3 \cdot 1 & -1 \cdot (-1) + 3 \cdot 1 \end{bmatrix} = \frac{1}{4} \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} = I$$

校验三，用矩阵自身的不变量交叉检查谱。 A_1 ： $\text{tr} = 1 + 3 = 4 = \lambda_1 + \lambda_2$ ， $\det = 1 \cdot 3 - 2 \cdot 0 = 3 = 1 \times 3 = \lambda_1 \lambda_2$ 。 A_2 ： $\text{tr} = 4 = 0 + 4$ ， $\det = 1 \cdot 3 - 1 \cdot 3 = 0 = 0 \times 4$ ，且 $\text{rank}(A_2) = 1$ 迫使 $\dim N(A_2) = 2 - \text{rank}(A_2) = 1 \geq 1$ ，与 $\lambda = 0$ 互相印证。最后核对 (b)：把 $A = X\Lambda X^{-1}$ 连乘三次，中间出现 $X^{-1}X = I$ 两次配对消掉，剩 $X\Lambda^3 X^{-1}$ ；取逆则用 $(UVW)^{-1} = W^{-1}V^{-1}U^{-1}$ ，得 $X\Lambda^{-1}X^{-1}$ ，因为 X^{-1} 的逆是 X 、 X 的逆是 X^{-1} ，两头恰好换回原位。对 A_2 还可算 $A_2^3 = X_2\Lambda_2^3 X_2^{-1} = \frac{64}{4} \begin{bmatrix} 0 & 4 \\ 0 & 12 \end{bmatrix} \begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix} = 16 \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} = 16A_2$ ，与 $\lambda = 0, 4$ 给出的 $\lambda^3 = 0, 64$ 一致。

六、常见错误判定（逐条）

✗ 写成 $A = X^{-1}\Lambda X$ 或 $A = X\Lambda X^T$ 。错在把相似变换（similarity transformation）的方向弄反： $AX = X\Lambda$ 是“列对列”的关系，右乘 X^{-1} 才把 A 单独留在左边；随手换成 $X^{-1}\Lambda X$ 会得到另一个矩阵（除非 X 恰好正交），把本题第一个矩阵代进去立刻不成立： $X_1^{-1}A_1X_1 = X_1^{-1}\Lambda_1X_1$ 算出的是 $\begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}$ 被换成 $\begin{bmatrix} 1 & 6 \\ 0 & 3 \end{bmatrix}$ ，与 A_1 不等。

✗ 第一个矩阵取“特征向量”为 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 与 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ ，理由是“对角元 1, 3 所以对角化”。错在把**特征值**读对了、把**特征向量**默认成了标准基。检验： $A_1 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ ，它不是 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 的倍数，故 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 不是特征向量；正确的是 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。

✗ 第二个矩阵写“秩 1 $\Rightarrow$ 特征向量是零向量 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ”。错在把“0 是特征值”与“零向量是特征向量”混为一谈。按定义特征向量必须非零； $\lambda = 0$ 的正确读法是“存在非零向量被 A 送到 0”，也就是 $N(A)$ 非平凡，本题即 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 。

✗ 把 X_2^{-1} 写成 $\begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix}$ ，漏掉因子 $\frac{1}{4}$ 。错在把“伴随矩阵 (adjugate)”当成了逆矩阵。对 2×2 有 $X^{-1} = \frac{1}{\det X} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$ ，分母 $\det X_2 = 4$ 不能省。检验方法： $X_2 \cdot \begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix} = 4I$ ，只做到 $4I$ 就说明还差一个 $\frac{1}{4}$ 。

✗ 把 X_2 两列的顺序与 Λ_2 对角元顺序配错。规则是第 i 列的特征向量只能配对角线上第 i 个特征值。若保留 X_2 的列序 $[x^{(0)}, x^{(4)}]$ 却按 $\Lambda_2 = \text{diag}(4, 0)$ 放特征值，那么 $X_2 \Lambda_2$ 的第一列被 4 乘、第二列被 0 乘，得到 $[4x^{(0)}, 0]$ ，等于 $\begin{bmatrix} 4 & 0 \\ -4 & 0 \end{bmatrix}$ 而不是 $A_2 X_2$ ，回代 $X_2 \Lambda_2 X_2^{-1}$ 也不再是 A_2 。要让配对成立，必须两处同时交换： X_2 换成 $\begin{bmatrix} 1 & 1 \\ 3 & -1 \end{bmatrix}$ 、 Λ_2 换成 $\text{diag}(4, 0)$ ，此时 $A_2[x^{(4)}, x^{(0)}] = [4x^{(4)}, 0]$ 成立，得到的是同一个分解的另一种排列。

✗ 以为 $\det(A - \lambda I) = 0$ 对任何非零矩阵一定给出正特征值、把 $\lambda = 0$ 当成“方程无解”。错在把 A 奇异与 $A - \lambda I$ 奇异混为一谈： $A - \lambda I$ 本来就允许奇异， $\lambda = 0$ 正是秩亏矩阵的合法特征值，本题第二个矩阵就是活例。

✗ 对第二个矩阵照抄 $A^{-1} = X \Lambda^{-1} X^{-1}$ 并算出数值。错在忽略存在条件： Λ_2 含 0，对角线求倒数这一步本身无定义， A_2 也确实不可逆 ($\det A_2 = 0$)。正确答案必须先声明前提再给公式。

✗ 把 (b) 写成四因子 $X \Lambda \Lambda \Lambda X^{-1}$ 或 $X^{-1} \Lambda^3 X$ 。错在不会用 $X^{-1} X = I$ 消去： $(X \Lambda X^{-1})^3$ 展开后中间成对出现 $X^{-1} X$ ，题目要的是三个矩阵因子，正确写法是 $X \Lambda^3 X^{-1}$ 。

✗ 只对 (b) 给出字母公式，不回头说明它对本题第二个矩阵意味着什么。错在漏答：本题第二个矩阵带着 $\lambda = 0$ ，恰好踩在逆矩阵公式的例外上，必须点明“ A_2 不可逆，故 A_2^{-1} 不存在”，否则 (b) 只答了一半。

七、自检小结 (清单式)

维度记账： A 为 2×2 ， X 为 2×2 ， Λ 为 2×2 ， $X \Lambda X^{-1}$ 的形状 (shape) 逐层是 $(2 \times 2)(2 \times 2)(2 \times 2) = (2 \times 2)$ ，与 A 匹配，无隐式广播； $X \Lambda^3 X^{-1}$ 同理。秩的上界：对 $k \geq 1$ 有 $\text{rank}(X \Lambda^k X^{-1}) = \text{rank}(\Lambda^k) \leq \text{rank}(\Lambda)$ ，对 A_2 恒为 1，与 $A_2^k = \lambda_2^{k-1} A_2$ 一致 ($k=0$ 时该式给 $\frac{1}{4} A_2 = I$ ，秩为 2，故两式都只在 $k \geq 1$ 使用)。特征值校验： $\text{tr}(A_1) = 4 = 1 + 3$ 、 $\det(A_1) = 3 = 1 \cdot 3$ ； $\text{tr}(A_2) = 4 = 0 + 4$ 、 $\det(A_2) = 0 = 0 \cdot 4$ 。可逆性校验： $\det X_1 = 1$ 、 $\det X_2 = 4$ ，均非零，故两个分解合法， X 的列线性无关这一前提被坐实。反例校验：若把第二个矩阵换成 $\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ ，它同样秩 1、特征值同为 0,0，但 $N(A)$ 只有一维、凑不出两个独立特征向量， X 不可逆， Λ 也就不存在——这说明“秩为 1”本身并不蕴含可对角化 (diagonalizable)，本题的 A_2 可对角化是因为两个特征值互异。

八、一句话：这道题真正训练的是“把矩阵按不变方向拆解”这一操作的双向能力——既要从 A 造出 X, Λ ，也要相信 X, Λ 造出 A ，并在动手前先用迹、行列式、秩把答案锁死。

九、这道题的设计意图 (把小问折叠成一个设计问题)

这道题只给了一个矩阵恒等式 $A = X\Lambda X^{-1}$ ，却在两个小问里把三件事一次性钉死：怎么造出这组因子、怎么信这组因子、怎么用这组因子。如果把它折叠成一个设计问题，问的是同一件事：**给定一个线性操作，我能不能换一组坐标，使它退化成一堆互不干扰的标量乘法？** 两个小问、三层要求，每一层都自带一个可验证输出。

(a) 的第一层是**结构识别**：矩阵值不值得拆、往哪儿拆。两个矩阵给出的答案方向相反。第一个是上三角，操作对最后一维“封闭”——第三维只被自身缩放，所以 $\lambda = 3$ 不用算就浮出来；但正因如此，第一维被第二维污染 ($A_{12} = 2$)，特征向量必须老老实实解零空间， $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 完全不是基向量。第二个是秩一，操作把所有向量压进一条线： $\lambda = 0$ 的存在性由秩一零化度守恒直接给出，剩下的那个特征值由迹补齐，两个特征向量一个是行空间的正交方向、一个是列空间方向。这一层训练的是“先用不变量把搜索空间缩到最小，再动手算”的习惯——先看秩、看迹、看是否三角，再决定要不要展开 $\det(A - \lambda I)$ 。

(a) 的第二层是**合法的坐标搬运**。看清零空间只是拿到方向，还差一个可逆性闸门： X 的列必须凑够 n 条独立方向，否则 Λ 不存在。本题两个 X 的行列式分别是 1 与 4，闸门通过；而这恰恰是最容易被忽略的一步，因为绝大多数人验证时只回代 Λ 里的数、不回代 $\det X$ 。把 A_2 与 $\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ 并排放就能看出这条闸门不是形式主义：两者秩同为 1、特征值同为含 0，后者却因为只有一条独立特征向量而彻底拆不开。所以“可对角化”这件事的真正判据不是矩阵长得像谁，而是**独立特征向量的条数是否达到 n** ；特征值互异只是保证这一点的充分条件。

(a) 的第三层是**搬运的两个方向都要能用**。这道题特殊在设计者把两个矩阵选成了互为转置：一个列向量独立、一个列向量成比例。转置不改变特征值（特征多项式对转置不变），却把行空间与列空间的角色互换。于是同一个分解公式被放在两种极端结构上测试：只要 X 的列是特征向量、 Λ 的顺序与列——对应，等式就成立，与矩阵“看起来是否规整”无关。这一层传达的是：拆解动作的正确性不依赖矩阵的外观，只依赖“列是否是不变方向、配对顺序是否一致”这两条内因。

(b) 是折叠后的**复利层**：一旦坐标搬运成功，所有“对 A 反复操作”的问题都变成“对 Λ 反复操作”。 A^3 的展开过程就是一次物理演示——中间成对出现的 $X^{-1}X$ 相互湮灭，只剩 $X\Lambda^3 X^{-1}$ ， X 一动不动。这就是为什么差分方程、马尔可夫链这类问题一旦拿到谱就不必再做矩阵乘法： X 与 X^{-1} 是一次性投资， k 只作用在 Λ 上。但这一层同时埋了一个陷阱：取逆需要逐项倒数，于是“所有 $\lambda_i \neq 0$ ”变成硬前提。 A_2 带着 $\lambda = 0$ 上场，正好把这条前提从脚注变成了答案的一部分——如果答题时只写公式不写前提，(b) 就答漏了一半。同理，“幂”与“逆”在公式里长得完全对称，适用条件却不对称，这种**形式对称、条件不对称**的结构在本课程后面反复出现（正交矩阵、最小二乘、伪逆都会再遇到），这里第一次亮相。

把三层合起来看，这道题真正在训练的是一个可复用的**判定—构造—复用**骨架：用不变量（秩、迹、行列式）先框住谱的可能位置；用零空间把方向取出来并通过 $\det X$ 闸门确认坐标合法；再把一切幂次、逆、多项式搬进对角坐标里结算。前两层是“把问题变简单”，第三层是“在简单世界里反复结算”。值得强调的是这个骨架的每一个环节都自带**可验证的输出**——谱可被迹与行列式交叉检查，方向可被逐列判据 $Ax^{(i)} = \lambda_i x^{(i)}$ 机械检出，可逆性可被 $\det X$ 一票否决。也就是说，这套流程不依赖“看懂了没有”的自我感觉，而依赖三次成本极低的算术。这正是本课程把 §1.6 放在这么早的位置的原因：对角化不是终点，它是后面所有“让矩阵变简单”的技术的第一个可运行原型。

最后回到那两个矩阵。它们并排出现并非为了凑数：一个展示了“结构只帮你一半”（三角给特征值、不给特征向量），一个展示了“结构帮你到底但顺手关上一扇门”（秩一给零特征值、但顺手让矩阵不可逆）。同一道题里既出现“公式能用”也出现“公式不能用”，这才是 (b) 那个填空真正要考的东西——不是会不会背 $X\Lambda^3 X^{-1}$ ，而是知不知道该先检查 Λ 的对角线上有没有 0。

[note] Note (译者注) —— $\det(A - \lambda I) = 0$ 为什么真的是“特征值判据”（其一）几何事实与代数改写

本注核心只有一句：行列式判据不是一条独立的公式，而是“零空间非平凡”这个几何事实的等价改写。把这条链拆开看，就知道哪些步骤不能省。

从定义出发。 λ 是特征值，意思是存在**非零** x 使 $Ax = \lambda x$ 。把它整理成 $(A - \lambda I)x = 0$ 。此刻出现一个容易滑过去的岔路：形如 $Mx = 0$ 的方程对**任何** M 都有解 $x = 0$ ，所以“有解”没有任何信息量；真正的信息量在于“**除零向量外还有解**”。用你在 18.065 第 1 讲就建立的语言说：这句话等价于 $\dim N(A - \lambda I) \geq 1$ ，等价于 $\text{rank}(A - \lambda I) \leq n - 1$ ，等价于 $A - \lambda I$ 不可逆，等价于 $\det(A - \lambda I) = 0$ 。这几种说法是同一件事的不同外衣：**零空间非平凡、秩亏缺、不可逆、行列式为零**。任何一个断掉，判据就不成立。

于是流程被固定成两步，且顺序不能反：第一步解 $\det(A - \lambda I) = 0$ 得到**候选** λ ；第二步对每个候选解 $(A - \lambda I)x = 0$ 得到**实际**的方向。为什么不能跳第二步？因为行列式方程只保证“存在非零向量”，不告诉你向量长什么样。用本题第一个矩阵演示这个陷阱：把 $\lambda = 1$ 代进去得 $A_1 - I = \begin{bmatrix} 0 & 2 \\ 0 & 2 \end{bmatrix}$ ，它的秩是 1，零空间维数 $2 - 1 = 1$ ，解只有 $x_2 = 0$ ， x_1 任意，所以方向是 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ ——恰好等于 e_1 ，看起来像“显然”，其实是巧合；把 $\lambda = 3$ 代进去得 $A_1 - 3I = \begin{bmatrix} -2 & 2 \\ 0 & 0 \end{bmatrix}$ ，秩仍是 1，解是 $x_1 = x_2$ ，方向 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ ，**不是** e_2 。同一道题里两个特征向量，一个碰巧等于基向量、一个不等于，正好说明“读对角元”只能读特征值、不能读特征向量。

再补一句计数上的意义，这是本注最该带走的东西：对 $n \times n$ 矩阵， $\det(A - \lambda I)$ 是 λ 的 n 次多项式，在复数范围内恰有 n 个根（按重数计）。所以“ n 个特征值”是算出来的结论，不是假设；但“ n 个**独立的特征向量**”不是自动的，它需要每个特征值的几何重数（geometric multiplicity，即 $\dim N(A - \lambda_i I)$ ）等于它的代数重数（algebraic multiplicity，即该根的重数）。本题 A_1 的两个特征值互异，几何重数各自至少 1、加起来不超过 2，只能各为 1，自动凑齐； A_2 的两个特征值也互异，同理。所以两个分解都成立，而且**不是**因为“秩 1”或“上三角”，而是因为特征值互异。这条推论可以直接复用为判据：**特征值两两不同 $\Rightarrow$ 必可对角化**；反过来不成立（ $\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 特征值重根却已经是对角阵）。

与 6.042J 的连线可以做得非常精确。你在那里学过： $Mx = 0$ 的全部解构成零空间，而“哪些 x 被映到 0”本质上是对定义域做了一次划分——同一陪集（coset）里的向量解出同一个像。这里发生的是同一件事的“反面应用”：我们不再问“给定 M ，谁被映到 0”，而是反过来问“哪个 λ 能让 $M = A - \lambda I$ 第一次出现非平凡核”。也就是说， λ 的取值把参数轴切成了“核平凡”与“核非平凡”两类，后者的那些点就是特征值。区别在于：6.042J 里的划分对象是**向量集合**，这里的划分对象是**参数 λ 的取值集合**，但两处用的是同一个判别动作——看秩是否掉下去。

可复用的命名模板：“**核平凡性四重等价链**”——非零解 $\Leftrightarrow$ 核非平凡 $\Leftrightarrow$ 秩亏缺 $\Leftrightarrow$ 行列式为零。以后凡遇到“某个参数在什么取值下方程有非零解”的问题（差分方程稳定性、最小二乘的正规方程、马尔可夫链的稳态），第一步都先走这条链，把“解方程”换成“算行列式”，再回头解零空间拿方向。

一句话收束： $\det(A - \lambda I) = 0$ 不是新知识，它是你在第 1 讲就学过的“秩—零化度守恒”被反向调用——用它筛出 λ ，再用它求出方向。

[note] Note (译者注) ——对角化就是换一组坐标，为什么 X 的列必须是特征向量

本注要回答一个具体的设计问题：为什么偏偏把特征向量堆成 X 、把特征值摆成 Λ ，就得到 $A = X\Lambda X^{-1}$ ？有没有别的方式“拆开”一个矩阵？

先看等式本身在说什么。把 $A = X\Lambda X^{-1}$ 两边左乘 X^{-1} ，得到 $X^{-1}AX = \Lambda$ 。这个改写把因果说清楚了： X^{-1} 是一个**换坐标**的动作。它把标准坐标系下描述的向量改写成“新基下的坐标”， A 作用一次、再换回来，在新坐标里恰好是对角阵。对角的含义是：新坐标下每个分量**各自缩放、互不串门**，第 i 个分量被乘 λ_i ，完全不碰第 j

个分量。这就是“解耦 (decoupling)” 。所以对角化不是把一个矩阵“化简得好看”，而是找一组坐标，让这个线性操作在该坐标下没有交叉项。

那么新基该取什么？设 X 的第 i 列为 $x^{(i)}$ ， $X^{-1}AX = \Lambda$ 逐列读出来就是 $Ax^{(i)} = \lambda_i x^{(i)}$ 。这就是“列必须是特征向量”的来历——它不是约定，是被等式逼出来的。反过来也立刻看出：如果某一列不是特征向量， $Ax^{(i)}$ 就不会等于 $x^{(i)}$ 的倍数，右端 $X\Lambda$ 的第 i 列（只有第 i 个位置非零）无论如何配不出来。这是检验任何对角化答案的**一列判据**：随手挑一列，算一次 Ax ，看它是不是 x 的倍数；不是，整个分解必错。

还有一个隐藏前提必须摆到台面上： X 要可逆，等价于 n 个特征向量线性无关。为什么“ n 个特征值”不能自动保证这件事？因为特征值可能重根，而重根处零空间可能太窄。举个最小反例： $J = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ ， $\det(J - \lambda I) = \lambda^2$ ，特征值只有 0（重数 2），但 $J - 0I = J$ 的秩为 1， $\dim N(J) = 1$ ，只凑出**一个**独立特征向量 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ ， X 的第二列无处可取。这个 J 就是“不可对角化”的最小样本。把 J 与本题 A_2 对照着看最有价值：两者秩都为 1、都含特征值 0，但 A_2 的另一个特征值是 $4 \neq 0$ ，两个方向互不重合， X_2 可逆； J 的两个特征值挤在同一个 0 上，方向不够用。可见“秩 1”与“可对角化”之间没有蕴含关系，决定因素是**独立特征向量的条数是否够 n** 。

用一个具体例子把这条判据走完。取 $A_2 = \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix}$ ， $x = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ ： $A_2x = \begin{bmatrix} 1 \cdot 1 + 1 \cdot (-1) \\ 3 \cdot 1 + 3 \cdot (-1) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} = 0 \cdot x$ ，是倍数，合格。取 $x = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ ： $A_2x = \begin{bmatrix} 1 + 3 \\ 3 + 9 \end{bmatrix} = \begin{bmatrix} 4 \\ 12 \end{bmatrix} = 4 \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ ，是倍数，合格。两列都过关，且 $\det X_2 = 4 \neq 0$ ，分解合法。再取一个**故意错**的候选：用 $X = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ 配 $\Lambda = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}$ （这是把 A_1 的对角元直接当答案的写法），第二列 $x = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 算出 $A_2x = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ ，不是 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 的倍数，一列判据立刻判死。这就是“读对角元”错误的机械检出方式。

跨课程连线可以接到 6.006。你在 CLRS 里学过分治算法 (divide and conquer)：把一个规模 n 的问题切成互不干扰的子问题分别求解，再合并答案。对角化是同一个设计思想在**矩阵作用**上的实现：换坐标把一次作用切成 n 个一维问题（各自乘 λ_i ），算完再换回来。两处的区别也很精确：分治切的是**输入数据**，子问题共享同一个算法；对角化切的是**坐标方向**， X 与 X^{-1} 是两次真实的坐标搬运，且并非所有矩阵都能这样切（ J 就切不开）。这个区别带来一个实用后果：分治的代价主要在递归层数，对角化的代价主要在求 X^{-1} ，而一旦 X, Λ 到手， $A^k = X\Lambda^kX^{-1}$ 里只有 Λ 在变， X 与 X^{-1} 是“一次投资、长期复用”的固定成本——这正是差分方程与马尔可夫链能高效计算 A^k 的原因。

可复用的命名模板：“**换坐标三步账**”——第一步， X 的列是目标基（必须是特征向量）；第二步， X^{-1} 是读坐标的动作（必须存在，即 $\det X \neq 0$ ）；第三步， Λ 在新坐标下作用（对角，分量互不干扰）。任何声称“把矩阵拆成简单块”的做法，都可以用这三步账核对一遍。

一句话收束： $A = X\Lambda X^{-1}$ 的价值不在形式对称，而在于它把“ A 反复作用”这件事从矩阵乘法降级成了 n 个标量乘方。

[note] Note (译者注) ——迹—行列式双锁校验：两项检查如何拦住三类错误（其一）两条等式的来历与三层用法

本注给出一套动手即可执行的自检流程，核心是把 $\text{tr}(A) = \sum \lambda_i$ 与 $\det(A) = \prod \lambda_i$ 当成锁答案的两把锁；这一半讲它们从哪来、怎么用，另一半讲它们锁不住什么。

先看这两条等式从哪来，不要当口诀背。把特征多项式按两种方式展开。方式一，按根写： $\det(A - \lambda I) = (\lambda_1 - \lambda)(\lambda_2 - \lambda) \cdots (\lambda_n - \lambda)$ 。比较 λ^{n-1} 的系数，右端是 $(-1)^{n-1} \sum_i \lambda_i$ ，左端由行列式展开中只有对角乘积项 $\prod_i (a_{ii} - \lambda)$ 能贡献 λ^{n-1} （其他排列至少缺两个对角元， λ 的次数至多 $n-2$ ），其系数是 $(-1)^{n-1} \sum_i a_{ii}$ ，于是 $\text{tr}(A) = \sum \lambda_i$ 。方式二，令 $\lambda = 0$ ： $\det(A) = \lambda_1 \lambda_2 \cdots \lambda_n$ 。两条都只是“同一个多项式写两遍、比较系数”的产物。你在 100B 实分析里正在练的“同一对象两种表示 $\Rightarrow$ 系数对应相等”，在这里就是它的有限维线性代数版本。

这两把锁在本题的用法有三层。第一层，**在算特征向量之前**先用它们定特征值，省去展开行列式的功夫。 A_1 是上三角， $\text{tr} = 4$ 、 $\det = 3$ ，两个根之和 4、积 3，立刻得 1 与 3； A_2 已由秩判断出含 0，再借 $\text{tr} = 4$ 得另一个是 4，连行列式都不用展开。

第二层，**在算完之后**用它反查有没有抄错数。典型场景是 A_2 ：如果有人把 X_2^{-1} 漏掉因子 $\frac{1}{4}$ 写成 $\begin{bmatrix} 3 & -1 \\ 1 & 1 \end{bmatrix}$ ，他回代 $X\Lambda X^{-1}$ 会得到 $\begin{bmatrix} 4 & 4 \\ 12 & 12 \end{bmatrix} = 4A_2$ 。此时迹变成 16、与 $\text{tr } A_2 = 4$ 对不上；行列式这一项却仍然通过，因为 $\det(4A_2) = 4^2 \det A_2 = 16 \times 0 = 0 = \det A_2$ ——零行列式把缩放倍数整个吞掉了。这正说明**两把锁要一起用**：只在行列式上对得齐却忽略迹，就会放过这个错误。这就是“双锁”两个字的实际含义。

第三层，判断可逆性并拦截“ $\lambda = 0$ ”这类特例。 $\det(A) = \prod \lambda_i$ 直接说明： $\lambda = 0$ 是特征值 $\Leftrightarrow \det A = 0 \Leftrightarrow A$ 不可逆。(b) 里 $A^{-1} = X\Lambda^{-1}X^{-1}$ 要求对 Λ 逐项取倒数，只要有一个 $\lambda_i = 0$ 就整条公式作废。本题 A_2 恰好踩线，因此 (b) 对它只有 A^3 那一半成立。这不是文字游戏：硬算会得到“除以零”的非法步骤，正确的补充说明是“ A_2 不可逆，故 A_2^{-1} 不存在”。

跨课程连接可以精确落到 6.006 的二分查找 (binary search)。二分查找的可用性依赖一个**不变量**：目标若存在，必落在当前区间内；每轮比较后区间减半而该不变量保持。迹与行列式在这里扮演的是同一角色的“代数不变量”：计算过程中无论中间矩阵怎么变、 X 怎么选、特征向量怎么缩放， $\sum \lambda_i$ 与 $\prod \lambda_i$ 必须始终等于 $\text{tr } A$ 与 $\det A$ 。区别要讲清：二分查找的不变量约束的是**搜索区间**，一旦破坏就说明查找逻辑错了；这里的双锁约束的是**答案的对称函数**，破坏它说明答案错了，但满足它**不保证答案对**——不变量是必要条件而非充分条件。这正是下一半“拦不住三类错误”的代数根源，也解释了为什么工程上不能只靠一条不变量做验证。

可复用的命名模板：“**trace-det 双锁**”。以后凡是手算特征分解、对角化、幂次计算，先用它把谱框住或反查，成本是两次二阶行列式与两次加法，收益是把“抄错数”这类错误拦在门外。

一句话收束：迹与行列式是特征值多项式的两个免费系数，不花额外力气就能替你审一遍谱。

[note] Note (译者注) ——迹—行列式双锁校验：两项检查如何拦住三类错误 (其二) 双锁漏掉的三类错误与三件套

现在说清两把锁**拦不住**什么，这比知道它们能拦什么更重要。它们都是关于特征值**多重集合**的对称函数，对特征向量的信息一无所知。所以它们拦不住三类错误。

其一，**特征值全对而特征向量取错**： X 的某一行根本不是特征向量，例如拿 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 去配 A_1 的 $\lambda = 3$ ；此时 $A_1 X$ 与 $X\Lambda$ 在那一行上不相等，但 tr 与 $\det$ 只读 Λ 的对角线，照样通过。

其二，**列与特征值的配对错**：仍取 A_2 ，把 X 的两列交换成 $\begin{bmatrix} 1 & 1 \\ 3 & -1 \end{bmatrix}$ 、 Λ 却仍写 $\text{diag}(0, 4)$ 。 X 的行列式变成 -4 ，迹与行列式检查的对象是 A_2 而不是 X ，谱集合也没变，于是两把锁全部通过；可这对 (X, Λ) 已经把 $\lambda = 0$ 与方向 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 绑在一起，逐列判据立刻失败。换言之，**配对信息被对称函数整体丢弃了**。

其三， **X 不可逆导致的假分解**：任何 $\det X = 0$ 的候选（例如两列取成同一个特征向量，或取成 $\begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ 这种重复列矩阵）都使 X^{-1} 不存在， $X\Lambda X^{-1}$ 这个写法本身失效；而迹与行列式检查的是 A ，看不出候选基的塌陷。

因此完整的自检清单必须是**三项**：迹—行列式（锁谱）+ 逐列判据 $Ax^{(i)} = \lambda_i x^{(i)}$ （锁向量）+ $\det X \neq 0$ （锁可逆性，相当于一道闸门）。三把锁各管一段，缺一就有缺口。这也解释了一个常见现象：验算全过、答案仍错——因为验算只覆盖了最容易算的那一部分输出。

把这条经验推广成可复用的命名模板：“**trace-det 双锁 + 逐列判据 + $\det X$ 闸门**” **三件套**。凡是手算特征分解、对角化、幂次计算，都按这三件依次过一遍，成本是三次两阶行列式与两次矩阵乘法，收益是把“算错却以为对”的概率压到很低。若要再往上加一层，就在这三件之后补一次“ k 的小值试算”（例如 $A_2^2 = 4A_2$ 、 $A_2^0 = I$ ），用小指数把大结论的边界也钉住。

一句话收束：迹与行列式只能锁住“有哪些特征值”，锁不住“它们对应哪些方向”；验证永远要覆盖问题的全部输出，而不是只覆盖最容易算的那一部分。🔒
Strang 在 18.065 第 4 讲中把这条捷径的适用范围一次说清：“With 2 by 2, there are 2 quick checks”（翻译：对于 2×2 的情形，有 2 个快速检验），随后他点明为什么这份把握只在小尺寸上成立：Well, there's one other check equally quick for 2 by 2. So 2 by 2s, you really get them right.（翻译：嗯，还有一个同样快速的检验方法适用于 2×2 矩阵。所以对于 2×2 矩阵，你确实能精准把握。）

这两句话把本讲的边界画清楚了：两把锁是**必要条件**， 2×2 时恰好构成充要条件， $n \geq 3$ 时缺的正是第 3 到第 n 个不变量（各阶主子式之和），所以课堂上他用 for 2 by 2 限定，而不笼统地说特征值总能快速读出。这也解释了为什么教材在 §1.6 之后立刻转向 SVD：当闭式路线在一般尺寸上失效，就需要一个对任意尺寸都稳定工作的替代方案，而那个方案正是用两组合适的正交方向把矩阵拆开。🔒 同一讲里他随后交代了尺寸一旦变大，这份把握会打多少折扣：“Add the eigenvalues for any size, 3 by 3, 4 by 4. But it's only two checks.”（翻译：特征值相加对任意尺寸都成立，3×3、4×4 也一样。但这只是两项检查。）

这句话正好补上了三件套里最容易被省略的一步：两项检查只锁住了两个标量条件，尺寸到 3×3 以上仍可能出错，所以必须再补逐列判据 $Ax^{(i)} = \lambda_i x^{(i)}$ 与 $\det X \neq 0$ 两道闸门，清单才能从两项扩成三项。他还用一句更直白的话给这个边界收尾：3 by 3, 4 by 4, you could still have made an error, and the two checks could potentially（翻译：3×3、4×4 的情形，你仍然可能已经犯了错误，而这两项检查可能……）——它说明双锁在 $n \geq 3$ 时只是必要条件： n 阶矩阵的特征多项式有 n 个系数，双锁只抓住了首项与常数项这两个，中间缺少的 $n - 2$ 个不变量（各阶主子式之和）正是课堂上要用 for 2 by 2 限定范围的原因。

附：三题合观——把三道题折叠成一个设计问题

这三道题在回答同一个设计问题：**矩阵的哪些信息可以降维成几个数，而哪些信息必须保留完整的向量？**

题 2 处理可降维的那一半。 $A = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix}$ 的特征值是 2 与 -1，它们由 $\det(A - \lambda I) = \lambda^2 - \lambda - 2$ 一次算出，再用 $\lambda_1 + \lambda_2 = 1 = \text{tr}(A)$ 独立校验；而 A^{-1} 的谱只是把每个 λ 取倒数，特征向量一动不动。这题第一次把矩阵的幂与逆翻译成标量的乘法与除法。

题 11 划出不可降维的边界。 $\det(A - \lambda I) = \det(A^T - \lambda I)$ 由 $\det M = \det M^T$ 得到，所以**特征值**这一半信息记在行列式里、被转置完整保留；但**特征向量**这一半记在 $(A - \lambda I)x = 0$ 的解空间里，转置把行操作换成列操作， $N(A)$ 与 $N(A^T)$ 就分道扬镳了。题面要你用例子打掉特征值相同 $\Rightarrow$ 特征向量相同这个想法，本质上是在提醒：**谱只记录拉伸倍数，不记录被拉伸的方向。**

题 15 把两半重新装配。 $A = X\Lambda X^{-1}$ 中, Λ 收下可降维的所有信息 (n 个数), X 收下不可降维的全部剩余 (n 个方向); 能这样装配的前提是这 n 个特征向量线性无关。装配成功之后, $A^3 = X\Lambda^3 X^{-1}$ 、 $A^{-1} = X\Lambda^{-1} X^{-1}$ ——计算复杂度从矩阵乘法降为对角元上的标量运算, 代价是多出一条前提: Λ 的对角线上不能有 0。

三题合起来是本讲的操作纪律: **先把矩阵作用在特征向量上, 看它是否只是被拉伸。** 若是, 整台机器就能拆成方向 + 倍数两半; 若特征值有重复而独立特征向量凑不够 n 条 (如 $J = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$: 秩为 1、特征值只有重根 0、零空间只有一维), 或矩阵秩为 1 却不可对角化, 就要单独处理——这也预告了后面为什么需要 SVD: 它用两组合适的正交方向, 把拆不动的矩阵也拆开。