

18.065 Matrix Methods in Data Analysis, Signal Processing, and Machine Learning (数据分析、信号处理与机器学习中的矩阵方法)

课程来源：MIT OpenCourseWare · Spring 2018 · Gilbert Strang · 第六课 (Lecture 6) 配套 Problem Set 1.8

教材 §1.8, p.56-61 | Manual, Problem Set 1.8 题 1、6

第六课 · Problems for Lecture 6 (第 6 讲题目)

本讲标题是 **Singular Value Decomposition (奇异值分解)**。把它当成一个设计问题来读会更清楚：**面对一个连方阵都不一定的矩阵 A ，能不能说清它把哪些输入方向送到哪些输出方向、每个方向又被放大了多少倍？**特征值那套语言在这里已经失效—— $Ax = \lambda x$ 要求等号左右是同一种向量，而 A 把 $\mathbb{R}^n$ 里的向量搬到 $\mathbb{R}^m$ 里， $m \neq n$ 时这个方程连写都写不出来；即便 $m = n$ ，特征值也可能是复数，特征向量也可能不正交。

设计问题的答案由三个对象组成。第一是进入的方向： $\mathbb{R}^n$ 中一组 orthonormal basis (标准正交基) $v_1, \dots, v_n$ ，它们张成 row space (行空间) 与 nullspace (零空间)。第二是离开的方向： $\mathbb{R}^m$ 中一组标准正交基 $u_1, \dots, u_m$ ，它们张成 column space (列空间) 与 left nullspace (左零空间)。第三是每一次搬运的放大倍数 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 。三者由一条方程锁死，每列读出来就是 $Av_i = \sigma_i u_i$ ，合起来即

$$AV = U\Sigma$$

这条方程是本讲的枢纽，而它的三种等价读法构成同一个答案的不同侧面： $AV = U\Sigma$ 强调的是「映射」—— V 的列被逐个送到 U 的列上；两边同乘 $V^{-1} = V^T$ 得到的 $A = U\Sigma V^T$ 强调的是「装配」——把整台机器分解成三个动作；把 $U\Sigma V^T$ 按列乘行展开得到的 $A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$ 强调的是「零件」—— A 是 r 个 rank-one matrices (秩一矩阵) 的叠加，且零件按 σ 的大小排序。

本讲的两道题分层压住这套结构。题 1 压住坐标系这一层：把一个向量写成基向量的组合之后，长度与二次型这类与坐标系无关的量如何用坐标算出来——这与 U 、 V 的正交性是同一层的内容。题 6 压住计算这一层：把一次具体的奇异值分解算到手，实打实地走完「 $A^T A$ 的特征向量给出 v ，开方给出 σ ， Av_i/σ_i 给出 u 」这条构造路径，并看清 A 与 A^T 的分解之间只互换 u 与 v 。两题合起来说明：分解存在只是起点，能算出来、能验算回去，才叫掌握。

收束到本课程主线：这套结构是 Part I 的枢纽。把「找方向」推广成「留几项」，前 k 个奇异值对应的 rank-one 项之和就是 A 的最优 low-rank approximation (低秩近似)，教材在讨论低秩逼近时用 Eckart-Young theorem (埃卡特-扬定理) 以严格的误差陈述回答「留几项」这个优化问题；把 A 换成一张样本记录排列成列的数据矩阵，同一个分解给出的 u_j 与 σ_j^2 就是主成分方向与方差——这正是 PCA (主成分分析) 的矩阵版本；把 v_j 看成坐标轴， $Av_j = \sigma_j u_j$ 就是「主方向被放大 σ_j 倍」的记账方式。低秩近似、压缩、去噪、降维，在本课程里共享同一套词汇：singular values (奇异值)、singular vectors (奇异向量)、four fundamental subspaces (四个基本子空间)。

术语口径（本讲五个词，后文严格按此使用）

- singular values（奇异值）： σ_i 只取实数值且 $\sigma_i \geq 0$ ，按降序排列 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ ，其中 $r = \text{rank}(A)$ ；下标超过 r 的 σ 全为零。**奇异值不是特征值**：它由 $A^T A$ 的特征值开平方得到， $\sigma_i^2 = \lambda_i(A^T A)$ ，所以它必然非负，而特征值可以是负数或复数。等价地 $\|A\| = \sigma_1$ 是 spectral norm（谱范数），它度量 A 对向量长度的最大放大倍数。
- singular vectors（奇异向量）：满足 $Av_i = \sigma_i u_i$ 的两组向量。right singular vectors（右奇异向量） $v_1, \dots, v_n$ 在 $\mathbb{R}^n$ 中相互正交， V 的前 r 列张成行空间、后 $n - r$ 列张成零空间；left singular vectors（左奇异向量） $u_1, \dots, u_m$ 在 $\mathbb{R}^m$ 中相互正交， U 的前 r 列张成列空间、后 $m - r$ 列张成 A^T 的零空间。反向配对同样成立： $A^T u_i = \sigma_i v_i$ 。
- $A = U \Sigma V^T$ ： U 是 $m \times m$ 正交矩阵、 V 是 $n \times n$ 正交矩阵、 Σ 是 $m \times n$ 对角矩阵，主对角线上依次为 $\sigma_1, \dots, \sigma_r$ 与零。要注意的是： Σ 的主对角线只有 $\min(m, n)$ 个位置，而 $A^T A$ 是 $n \times n$ 的，由它出发会得到 n 个奇异值，前 r 个为正、其余为零；只保留正奇异值的写法 $A = \sum_{i=1}^r \sigma_i u_i v_i^T$ 是同一条分解的紧凑形式，两者不可混用同一套尺寸记账。
- rank-one pieces（秩一分量）： $A = \sigma_1 u_1 v_1^T + \dots + \sigma_r u_r v_r^T$ 。每一件 $\sigma_i u_i v_i^T$ 都是秩一矩阵，且按 σ_i **由大到小排列**； σ_1 那一件是 A 中分量最大的方向。这是教材讨论最优低秩近似的起手式——「留几项」就是把这条和式在哪里截断。
- $A^T A$ 与 AA^T ：两者都是对称半正定矩阵，阶数分别是 $n \times n$ 与 $m \times m$ ，它们有同一组非零特征值 $\sigma_1^2, \dots, \sigma_r^2$ ，且 $\sum_{i=1}^r \sigma_i^2 = \text{trace}(A^T A) = \text{trace}(AA^T)$ ； $A^T A$ 的单位特征向量即 v_i ， AA^T 的单位特征向量即 u_i 。它给出最直接的构造路径，但要留意：矩形矩阵的两个 Gram matrix（格拉姆矩阵）阶数不同，只有非零谱是共享的。

🚫 必须挡住的三处混淆：① 把奇异值当成特征值—— $\sigma_i^2 = \lambda_i(A^T A)$ 这条关系只对 $A^T A$ （或 AA^T ）成立，不是对 A 成立； $\text{diag}(1, -2)$ 的特征值是 1 与 -2 ，奇异值却是 2 与 1，负号被左右奇异向量的符号选择吸收了。② 把 U 与 V 随手交换——两者尺寸本就未必相同（ U 是 $m \times m$ 、 V 是 $n \times n$ ），且 V 活在输入端、 U 活在输出端，位置由 $Av_i = \sigma_i u_i$ 规定；交换它们所得的是 $A^T = V \Sigma^T U^T$ ，那是另一个矩阵的分解。③ 把 $\sigma_1 \sigma_2 = |\det A|$ 用到矩形矩阵上——行列式对矩形矩阵根本没有定义，这条只在 A 为方阵时成立；即便是方阵，若秩亏则 $\det(A^T A) = 0$ ，而只要 A 非零就有 $\text{trace}(A^T A) = \sum_i \sigma_i^2 > 0$ ，两个校验式给出的信息量并不相同。

[note] Note（译者注）——（其一）奇异值分解要解决的是什么：把方向不变换成两端各配一组正交基

本注的核心：奇异值分解要解决的问题不是「找出让 A 不变的向量」，而是「为输入端和输出端各选一组标准正交基，使 A 在这两组基之间只表现为逐个方向的伸缩」。

机制要从失效的那一边展开。特征值方程 $Ax = \lambda x$ 的含义是「 x 被 A 作用之后方向不变、只改长度」，这是一个有方向不变性才谈得上的问题。可是当 A 不是方阵时，左侧 $Ax \in \mathbb{R}^m$ 、右侧 $\lambda x \in \mathbb{R}^n$ ，等号两边根本不是同一空间里的对象，方程无法书写；这不只是求解困难，而是问题本身没有指派清楚。于是换设计：放弃「原方向不变」，改成「输入一组方向、输出一组方向，两两配对，输出那一条必须是单位长度且互相垂直」。这一改动带来两个后果。第一，把原本要求的「保持在同一

空间里」降级成「配对两个空间」，条件放宽后，对任何矩阵都存在解。第二，把原本允许的负号抹掉——伸缩倍数不再能取负值，因为方向颠倒可以用「把这一对 u_i, v_i 同时反号」来实现，伸缩本身只承担大小。奇异值非负这条性质就来自这里，它与特征值可以为负是两套不同的设计取舍。

改写后的方程是 $Av_i = \sigma_i u_i$ ($i = 1, \dots, n$)，把所有列并排即 $AV = U\Sigma$ 。这个形式必须写成 $AV = U\Sigma$ 而不是 $A = U\Sigma V^T$ 才能暴露机制：右端每一列恰好对应左端的一列，「 v_i 被送到 $\sigma_i u_i$ 」逐条可见。这里 V 有 n 列、 U 有 m 列， Σ 是 $m \times n$ 的矩形对角阵，正的 σ 只有 r 个： $i \leq r$ 时两边是真搬运， $i > r$ 时 v_i 落在零空间、 u_i 落在左零空间，配对结果都是零向量。把 $V^T = V^{-1}$ 乘过去得到的 $A = U\Sigma V^T$ 适合装配与展开， $A = \sum \sigma_i u_i v_i^T$ 适合截断，但若追问「哪个方向进入、哪个方向出去、放大多少倍」， $AV = U\Sigma$ 是最贴近问题本身的一种写法。

一个最小例子：取旋转 90° 的矩阵 $A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ ，它的特征多项式是 $\lambda^2 + 1$ ，在实数里没有根，特征值语言在这里完全失效；但 $A^T A = I$ 给出 $\sigma_1 = \sigma_2 = 1$ ， U 的两列取 A 的两列本身、 V 的两列取标准基，就有 $A = u_1 v_1^T + u_2 v_2^T$ ，即 $Ae_1 = u_1$ 、 $Ae_2 = u_2$ 。旋转保持一切长度不变，于是每个方向的放大倍数都是 1，这个结论既不需要复数也不神秘。

与课程主线的关系：在已学过的 Strang 线性代数里，标准正交基、 $Q^T Q = I$ 与投影已经把「用坐标算长度」这套语言建立起来——若 $x = \sum c_i v_i$ 而 v_i 标准正交，则 $\|x\|^2 = \sum c_i^2$ ，本讲题 1 压的就是这一层；区别在于这里要额外要求两组基分别落在行空间与列空间上，把四个基本子空间一并定住。

用一句话概括这个设计：任何一个线性映射，在输入与输出各选一组好基之后，都变成若干条互不干扰的单向通道——第 i 条通道把第 i 个输入方向按 σ_i 倍送到第 i 个输出方向，通道之间不串音；这就是「对角化」在矩形矩阵上的正确版本。可复用的命名模板：「**两端配基—逐向伸缩**」，遇到任何「把算子化简成对角」的问题，都先问输入端与输出端各是哪一空间、伸缩是否允许取负值。

一句话收束：奇异值分解的贡献不是给特征值理论打补丁，而是把「方向不变」这个过强的要求换成「两端各配一组正交方向」这个可满足的要求，代价是要同时准备两组基。

[note] Note (译者注) —— (其二) 符号归谁： $\text{diag}(1, -2)$ 这个例子，以及换一套表示这条习惯在别处的位置

本注的核心：把 σ 定为非负不是一条无关紧要的约定，它决定了负号往哪里去；一旦接受这个约定， σ 的排列次序也必须固定为降序，否则「 σ_1 配哪一对 u_1, v_1 」这句话就没有定义。

机制可以用一个二阶例子看穿。取 $A = \text{diag}(1, -2)$ ：它的特征值可以直接读出来，是 1 与 -2 ；但 $A^T A = \text{diag}(1, 4)$ ，特征值是 4 与 1，开方得 $\sigma_1 = 2$ 、 $\sigma_2 = 1$ 。按降序约定， $\sigma_1 = 2$ 必须配 $A^T A$ 的较大特征值 4 的那个单位特征向量，即 $v_1 = (0, 1)^T$ ；于是 $Av_1 = (0, -2)^T$ ，模长为 2，单位化得 $u_1 = (0, -1)^T$ 。剩下的一对是 $\sigma_2 = 1$ 、 $v_2 = (1, 0)^T$ 、 $u_2 = (1, 0)^T$ 。写成秩一和式 $A = 2u_1 v_1^T + 1u_2 v_2^T$ ，逐项算得 $2 \begin{bmatrix} 0 \\ -1 \end{bmatrix} \begin{bmatrix} 0 & 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & -2 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$ ，正好复原 A 。

负号并没有消失，而是被吸收进 u_1 与 v_1 的整体符号选择里： A 把 $v_1 = (0, 1)^T$ 送到 $(0, -2)^T$ ，方向上下颠倒，这个颠倒记在 $u_1 = (0, -1)^T$ 的负号上， σ_1 只记大小 2。这也说明为什么「同一对 u_i, v_i 同时反号」不改变任何东西： $A(-v_i) = -\sigma_i u_i = \sigma_i(-u_i)$ ，非负性与正交归一性都保住了。更一般地， $A^T A$ 只记录 A 把长度放大了多少，记不下方向是否被翻转，所以由它出发得到的 σ 一律非负； A 有几个负特征值、哪些方向被翻过，这些信息只能从 u_i, v_i 的符号里读回来。

顺手把这个例子验算一遍：四条向量长度都是 1, $u_1 \cdot u_2 = 0$ 、 $v_1 \cdot v_2 = 0$, $\text{trace}(A^T A) = 5 = 2^2 + 1^2$, $\sigma_1 \sigma_2 = 2 = |\det A|$, 两套账都对得上。

还要注意写法并不唯一：任取 $s_i = \pm 1$, 把 u_i 与 v_i 同时乘以 s_i , 得到的仍是同一个 A , 所以奇异向量只在相差一个符号的意义下唯一；只有某个 σ_i 是重根时才会出现更大的自由度（对应的 v 可以在该特征子空间里任取一组标准正交基）。这也是自检时不能拿「 u_1 是否恰好等于 $(0, -1)^T$ 」判对错的原因，能判对错的是 Av_i 是否等于 $\sigma_i u_i$ 。至于次序：只有当 $\sigma_1 \geq \sigma_2 \geq \dots$ 固定下来，「前 k 项」才是一个确定的截断位置，低秩近似、压缩、去噪才有统一的记账方式；次序一旦漂移，同一句「保留前三个方向」在不同实现下保留的会是不同的东西。降序还有一个数值后果： σ 衰减得越快，前 k 项抓住的能量比例 $(\sigma_1^2 + \dots + \sigma_k^2)/(\sigma_1^2 + \dots + \sigma_r^2)$ 就越高，这正是压缩与去噪可以共用同一套公式的原因。

与课程主线的关系可以放在「换一套表示」这条习惯上。6.042J 里反复使用的 bijection（双射）手法就是这件事的离散版本：把不会数的对象换成一类已经会数的对象，结论与换法无关；这里做的是同一件事的线性版本，把 A 换成 Σ 之后， A 的全部信息变成 n 个数与两组方向，而 $\|A\| = \sigma_1$ 、方阵时的 $|\det A| = \prod_i \sigma_i$ 这些量必须在换法下保持不变——这正是检验分解算没算对的依据。区别在于：双射要求一一对应、结论精确；奇异值分解允许不完整保留，把小的 σ 丢掉，于是从恒等变形变成近似。可复用的命名模板：「**两端配基—逐向伸缩—符号归向量**」，遇到任何「把算子化简成对角」的问题，都先问三件事：输入端与输出端各是哪一空间、伸缩是否允许取负值、负号由谁承担。

一句话收束：把 σ 定为恒为非负，是把「方向」与「大小」分开记账的结果；负号没有消失，只是搬到了向量的整体符号上。

[note] Note (译者注) —— (其一) 手算奇异值分解的四步施工路径，以及为什么走 $A^T A$ 要付代价

本注的核心：手算奇异值分解有一条固定的施工路径，而这条路径的第三步——对 $A^T A$ 的特征值开方——在数值上是它真正的软肋。

施工路径只有四步：一是算 $A^T A$ ($n \times n$ 、对称、特征值必为非负实数)，二是求它的单位特征向量，按特征值由大到小排成 V 的列，三是把特征值开平方得到 σ_i ，四是用 $u_i = Av_i/\sigma_i$ 反求 U 的列。第四步只对 $i \leq r$ 有效： $i > r$ 时 $\sigma_i = 0$ ，不能作除数，那些 u_i 要在左零空间里另取一组标准正交基补齐。

这条路能走通，靠的是两条性质。第一条： $A^T A$ 对称且半正定，所以它一定有一组标准正交的特征向量基，特征值全是非负实数，第二步因此能直接排出一个正交矩阵 V 。第二条：第四步给出的 u_i 自动正交，因为 $(Av_i)^T(Av_j) = v_i^T A^T Av_j = \sigma_j^2 v_i^T v_j$ ，当 $i \neq j$ 时它等于零，再除以 $\sigma_i \sigma_j$ 就得到 $u_i \cdot u_j = 0$ ，而长度为 1 由除以 $\|Av_i\| = \sigma_i$ 保证。顺带说清一件事： $\lambda_i = \sigma_i^2$ 是单调关系， $A^T A$ 的特征值排序与 σ 的排序完全一致，所以第二步到第三步不会改变次序，可能出问题的地方只有精度。

维数上还有一个容易漏掉的地方： $A^T A$ 是 $n \times n$ 的，即使 A 很扁 ($m < n$)，这一步也要交出 n 个特征向量，其中 $n - r$ 个对应 $\lambda = 0$ ，它们张成零空间；第四步对它们无定义，只能靠补基完成。手算时若只写出 r 个向量， V 就不成方阵，后面 $A = U\Sigma V^T$ 的尺寸立刻对不上。选 $A^T A$ 还是 AA^T 也只是一个便利问题：两者的阶数分别是 $n \times n$ 与 $m \times m$ ，手算时挑小的一边走，另一边的向量再用 $A^T u_i/\sigma_i$ 补出来即可。

为什么说第三步是软肋？软肋的根源是 $A^T A$ 把奇异值「平方」了一遍： $\lambda_i(A^T A) = \sigma_i^2$ ，于是条件数也被平方， $\kappa(A^T A) = \kappa(A)^2$ 。取 $\sigma_1 = 10^4$ 、 $\sigma_2 = 1$ ， $A^T A$ 的特征值就是 10^8 与 1，相差八个数量级；双精度浮点数大约只有 16 位十进制有效数字，把 $A^T A$ 写进内存再求特征值时，小特征值会被大特征值带来的舍入误差淹没，相对误差的量级约为 $\kappa(A)^2 \epsilon \approx 10^8 \cdot 10^{-16} = 10^{-8}$ ，开方之后 σ_2 大约只剩 8 位有效数字。这里并没有算错任何公式，赔掉的是精度：「先平方再开方」把本来可以保住的信息

提前丢了一次；若原矩阵元素很大，平方还可能直接溢出。所以实际软件（例如基于 QR 迭代或 Jacobi 旋转的 SVD 例程）不会真的去构造 $A^T A$ ；教材用 $A^T A$ 引路是为了暴露结构，不是因为那是数值上最好的算法。

与已学课程的关系：CSAPP 第 2 章讲 IEEE 754 时给出的结论——精度有限、小数会被大数吃掉——在这里有了具体的兑现方式：不是「浮点数不准」这种笼统说法，而是「条件数被平方之后，有效位数按平方后的量级损失」。可复用的判断模板：**任何「先平方再开方」的公式，都要先问中间量会不会把条件数平方**，同类情形还有直接用 $\|A\|^2$ 或 $\text{trace}(A^T A)$ 作判别的地方。这也解释了为什么手算练习走 $A^T A$ 完全可以，而工程实现要另找路径。

一句话收束：最短的理解路径是 $A^T A$ ，最稳的计算路径却不是它。

[note] Note (译者注) —— (其二) 算完之后的四项自检，以及一个把四项一次走完的例子

本注的核心：验算分解不需要额外工具，四项形状与代数检查就能把绝大多数错误抓出来；它们分别是正交性、维数记账、标量校验、回收检查。

其一是正交性： U 与 V 的每一列长度是否为 1、任意两列内积是否为 0，等价于 $U^T U = I$ 与 $V^T V = I$ 。若某列长度不是 1，多半是归一化时漏了除以 $\sqrt{2}$ 或 $\sqrt{10}$ ；若两列内积不为零，多半是求特征向量时该正交的一对被配错了。

其二是维数记账： Σ 的形状必须是 $m \times n$ （一般不是方阵），正奇异值的个数必须恰好等于 r ， U 的列数是 m 、 V 的列数是 n 。多算出一个正奇异值意味着秩判错，少算一个意味着漏掉了一个方向；这两条在任何尺寸下都不能凭印象填。

其三是标量校验，包含两条互相独立的恒等式： $\text{trace}(A^T A) = \sum_i \sigma_i^2$ 对任何尺寸都成立； A 为方阵时再加一条 $\det(A^T A) = (\sigma_1 \cdots \sigma_n)^2$ ，即 $|\det A| = \prod_i \sigma_i$ ，这条在 $\det A < 0$ 时同样成立，因为右端全是非负数。 trace 只与 σ^2 的总和有关、与方向无关，所以把 U 、 V 配错时它照样通过，一旦它不通过，问题一定出在奇异值的数目或大小上；行列式那条抓的是「忘记开方」：若把下面例中 $A^T A$ 的特征值 45 与 5 直接当成奇异值，乘积变成 225，立刻与 $|\det A| = 15$ 冲突。

其四是回收检查：把 $U \Sigma V^T$ 乘回去，或把 $\sum \sigma_i u_i v_i^T$ 逐项加起来，应当逐元素复原出 A ；用 $Av_i = \sigma_i u_i$ 逐列抽查更快，而且它是唯一能同时抓住符号错误与排序错误的一项。

一个例子把这四项一次走完。取 $A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ （教材 §1.8 的 Example 1, p.60），得 $A^T A = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}$ ，特征向量 $(1, 1)^T$ 与 $(1, -1)^T$ 已经正交，归一化得 $v_1 = \frac{1}{\sqrt{2}}(1, 1)^T$ 、 $v_2 = \frac{1}{\sqrt{2}}(1, -1)^T$ ；特征值 45 与 5 开方得 $\sigma_1 = 3\sqrt{5}$ 、 $\sigma_2 = \sqrt{5}$ ；再由 $u_i = Av_i/\sigma_i$ 得 $u_1 = \frac{1}{\sqrt{10}}(1, 3)^T$ 、 $u_2 = \frac{1}{\sqrt{10}}(3, -1)^T$ 。四项自检：正交性上 U 两列内积为 $3 - 3 = 0$ 、 V 两列内积为 $1 - 1 = 0$ ，长度都是 1；维数上两个正奇异值对上 $r = 2$ ， Σ 为 2×2 ；标量校验上 $\text{trace}(A^T A) = 50 = 45 + 5$ ，且 $\sigma_1 \sigma_2 = 3\sqrt{5} \cdot \sqrt{5} = 15 = |\det A|$ ，两条路对上；回收验算给出 $A = \frac{3}{2} \begin{bmatrix} 1 & 1 \\ 3 & 3 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 3 & -3 \\ -1 & 1 \end{bmatrix}$ ，逐元素相加正是 $\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 。四项全过也不必强求 u_i 的符号与教材一致：符号本来就不唯一，检查保证的是 A 被复原，不是某一套符号被复现。

与课程主线的连接落在 6.006 上：二分搜索与分治算法训练的是「把问题规模劈成两半、每层付固定代价」的复杂度记账方式，而奇异值分解提供的是另一种排序——把 r 件 rank-one 分量按 σ 从大到小排队，于是「只留前 k 件」在存储上对应「只存 $k(m + n + 1)$ 个数」（ k 个左向量、 k 个右向量、 k 个奇异值），在误差上对应「丢掉的是 $\sigma_{k+1}, \dots, \sigma_r$ 那一截」。区别在于分治的划分由算法结构决定、结果精确；奇异值分解的截断由数据决定、结果近似，它把「近似」量化成一个可以查的数

列。可复用的命名模板：「**正交—维数—trace—行列式—回收**」**自检链**（正交与维数各占一项，标量校验一项里含 trace 与行列式两条，所以链条上一共五个词），在手算任何分解（LU、QR、特征分解、SVD）之后都可以照走一遍。

一句话收束：分解算得对不对，不靠感觉，靠四个彼此独立、各自能单独失效的检查同时点头。

[problem] Problem 1 (问题 1)

教材 §1.8, p.56-61 | Manual, Problem Set 1.8 题 1

一个 symmetric matrix（对称矩阵） $S = S^T$ 有一组 orthonormal eigenvectors（标准正交特征向量） v_1 到 v_n ：它们两两正交，且每个的长度都是 1。于是任何向量 x 都可以写成组合 $x = c_1 v_1 + \cdots + c_n v_n$ 。请解释以下两个公式：

$$x^T x = c_1^2 + \cdots + c_n^2 \qquad x^T S x = \lambda_1 c_1^2 + \cdots + \lambda_n c_n^2$$

Original (英文原题) : A symmetric matrix $S = S^T$ has orthonormal eigenvectors v_1 to v_n . Then any vector x can be written as a combination $x = c_1 v_1 + \cdots + c_n v_n$. Explain these two formulas:

$$x^T x = c_1^2 + \cdots + c_n^2 \qquad x^T S x = \lambda_1 c_1^2 + \cdots + \lambda_n c_n^2$$

[solution] 一、结论

定义核心句：只要基是 orthonormal（标准正交）的，坐标映射 $x \mapsto c$ 就是保长度的；而 symmetric matrix（对称矩阵）的二次型在这组基下变成只含平方项的 weighted sum（加权求和），权就是它的 eigenvalues（特征值）。

两个公式的成立条件是分开的，必须先讲清楚。

第一， $x^T x = c_1^2 + \cdots + c_n^2$ 只需要 $v_1, \dots, v_n$ 是一组 orthonormal basis（标准正交基，简称 ONB），**不需要** S 对称，甚至不需要 S 存在。它的内容是「坐标变换是 isometry（等距变换）」，即 $\|x\|^2 = \|c\|^2$ 。

第二， $x^T S x = \lambda_1 c_1^2 + \cdots + \lambda_n c_n^2$ 同时需要两件事： S 对称（这保证特征值全为 real（实）数、且存在一组完整的 ONB），以及 v_k 恰好是 S 的 orthonormal eigenvectors（正交单位特征向量）。缺任何一条都不成立，后面的常见错误清单会给出反例。

第三，系数不是任意的，它由 x 与基唯一确定： $c_k = v_k^T x$ 。这一点是下面所有证明和验算的支点。

两个公式合起来给出一句可以直接用的结论：

$$\lambda_n \leq x^T S x \leq \lambda_1$$

本稿的编号一律取 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ，所以 λ_1 是**最大**特征值、 λ_n 是**最小**特征值；编号顺序的坑见第五节错误 3。等价的写法是：在单位球 $\|x\| = 1$ 上， $x^T S x$ 的取值范围恰好是 $[\lambda_n, \lambda_1]$ 。

二、方法一：求和的展开视角（定义直推，最不容易记错）

这个方法看到的是「两两配对的账目」：把 n^2 个交叉项全写出来，看谁活下来。

先算第一个式子。记 $x = \sum_j c_j v_j$ 与 $x^T = \sum_k c_k v_k^T$ （行列同一符号，只是转置），于是

$$\begin{aligned} x^T S x &= \left(\sum_k c_k v_k^T \right) \left(\sum_j c_j v_j \right) \\ &= \sum_k \sum_j c_k c_j v_k^T v_j \end{aligned}$$

而 orthonormality（标准正交性）给出的正是

$$v_k^T v_j = \begin{cases} 1, & k=j \\ 0, & k \neq j \end{cases}$$

所以 n^2 项里只有 n 个对角项 c_k^2 存活：

$$x^T S x = \sum_k c_k^2$$

反过来，这也给出系数公式：把 v_k^T 作用在 $x = \sum_j c_j v_j$ 上，得到 $v_k^T x = c_k$ ，因为所有 $j \neq k$ 的项都被内积杀掉了。这一步说明「 c_k 是投影长度」，并且 $x = \sum_k (v_k^T x) v_k$ 对任意 ONB 成立。

再算第二个式子，多出的一步是让 S 作用在组合上：

$$Sx = S \left(\sum_j c_j v_j \right) = \sum_j c_j S v_j = \sum_j c_j \lambda_j v_j$$

这一步用的就是 eigenvector 的定义 $Sv_j = \lambda_j v_j$ (逐项分配, 不需要任何附加条件)。代入:

$$\begin{aligned} x^T S x &= \left(\sum_k c_k v_k^T \right) \left(\sum_j c_j \lambda_j v_j \right) \\ &= \sum_k \sum_j c_k c_j \lambda_j (v_k^T v_j) \\ &= \sum_k \lambda_k c_k^2 \end{aligned}$$

注意这里交叉项消失的机制**比第一个式子多用了一条信息**: 当 $k \neq j$ 时,

$$v_k^T S v_j = v_k^T (\lambda_j v_j) = \lambda_j (v_k^T v_j) = 0$$

先澄清一个容易说错的点: 把 S 夹在两个向量中间写成 $v_k^T S v_j$, 对任何方阵都合法 (它就是一个数), 这一步不需要对称性。对称性真正负责的是另外两件事: 一是保证「实特征值 + 两两正交的单位特征向量」这一整套基确实存在, 二是保证 $v_k^T S v_j = v_j^T S v_k$ 这类对称关系成立。下面这个自治性检查能看清分工: 由 $Sv_j = \lambda_j v_j$ 得 $v_k^T S v_j = \lambda_j (v_k^T v_j)$; 把同一个数取转置, 并用 $S = S^T$, 得 $v_k^T S v_j = v_j^T S v_k = \lambda_k (v_j^T v_k)$; 两式相减得 $(\lambda_j - \lambda_k) v_j^T v_k = 0$, 与「 $v_j \perp v_k$ 」一致。

这一步正是官方 Manual (题解手册) 省略掉的: 正交性负责让 $v_j^T v_k = 0$, $Sv_j = \lambda_j v_j$ 负责把 $v_k^T S v_j$ 改写成 $\lambda_j v_k^T v_j$, 对称性负责保证这组特征基存在。题解手册把中间那一步留成一个待填充格:

$$\begin{aligned} & \left(\sum c_1 v_1^T + \dots + c_n v_n^T \right) S \left(\sum c_1 v_1 + \dots + c_n v_n \right) \\ &= \left(\sum c_1 \lambda_1 v_1^T + \dots + c_n \lambda_n v_n^T \right) \left(\sum c_1 v_1 + \dots + c_n v_n \right) \end{aligned}$$

空格里要填的正是 $S(c_1 v_1 + \dots + c_n v_n)$ 整体, 它等于 $c_1 \lambda_1 v_1 + \dots + c_n \lambda_n v_n$; 这一步单独依赖 $Sv_k = \lambda_k v_k$, 与正交性无关, 正交性是在**最后一步**才被用来消掉交叉项的。把这两件事混成一句「因为正交所以成立」, 就是这道题最常见的偷懒。

适用条件：只要基标准正交、 S 对称，无其他门槛。优势：不依赖任何矩阵记号技巧， n 任意大都成立。劣势：写 $\sum_k \sum_j$ 时要盯住指标归属（ λ_j 跟着 j 不跟着 k ），符号最容易在这里翻车。

三、方法二：矩阵记账视角（ $S = Q\Lambda Q^T$ ，一步到位）

这个方法看到的是「换基」这一动作的矩阵形式： Q 是基变换， Q^T 是反变换， Λ 是 S 在特征基下的坐标表示。

把 $v_1, \dots, v_n$ 作为列排进 Q ，把 λ_k 排进对角矩阵 Λ ；由 spectral theorem（谱定理）的矩阵形式（ S 对称，且 v_k 是一组完整的 ONB）：

$$Q^T Q = Q Q^T = I, \quad S = Q \Lambda Q^T, \quad Q^T x = \begin{bmatrix} v_1^T x \\ \vdots \\ v_n^T x \end{bmatrix} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}$$

于是两个式子变成两行矩阵运算，括号的移动用的是 associativity（结合律）：

$$x^T x = (Qc)^T (Qc) = c^T \underbrace{\big(Q^T Q\big)}_{=I} c = c^T c = c_1^2 + \dots + c_n^2$$

$$x^T S x = (Qc)^T \big(Q \Lambda Q^T\big) (Qc) = c^T \underbrace{\big(Q^T Q\big)}_{=I} \Lambda \underbrace{\big(Q^T Q\big)}_{=I} c = c^T \Lambda c = \sum_k \lambda_k c_k^2$$

适用条件：要求 n 个特征向量**齐全**（ Q 是方阵），否则 $Q Q^T = I$ 不成立。优势：把「换基」讲清楚，而且立刻给出「 S 与 Λ 是 the same linear map（同一个线性映射）在不同基下的两份坐标」，后面做正定性判定、Cholesky decomposition（乔莱斯基分解）时可以直接搬到新基上。劣势：把证明压缩进了三个等号里，如果不解释 $Q^T Q = I$ 与 $S = Q\Lambda Q^T$ 的来源，就变成了「用结论证明结论」。

四、方法三：坐标与二次型配方的视角（几何与能量的读法）

这个方法看到的是「 $x^T S x$ 是什么量」：它是 energy（能量），而第一个公式说的是坐标变换不改变长度的平方。

在特征基下， S 的矩阵表示是 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ，因此 quadratic form（二次型）在这组坐标里没有交叉项：

$$x^T S x = \sum_k \lambda_k c_k^2$$

这是一份「配方好的」表达式：每个方向独立贡献，第 k 个方向的贡献系数就是 λ_k 。几何读法：球面 $\|x\| = 1$ （即 $\sum_k c_k^2 = 1$ ）被 S 映成椭球面，第 k 个半轴沿 v_k 方向、长度为 $|\lambda_k|$ ； $\lambda_k < 0$ 时该半轴反向， $\lambda_k = 0$ 时整条轴被压平成 0。

由此立刻得到 two-sided bounds（双侧夹逼界）：把特征值按 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ 排列，则对每个 k 有 $\lambda_k - \lambda_n \geq 0$ 且 $\lambda_1 - \lambda_k \geq 0$ ，于是

$$\begin{aligned} x^T S x - \lambda_n x^T x &= \sum_k (\lambda_k - \lambda_n) c_k^2 \geq 0, \\ \lambda_1 x^T x - x^T S x &= \sum_k (\lambda_1 - \lambda_k) c_k^2 \geq 0 \end{aligned}$$

两项的「非负」完全来自 $c_k^2 \geq 0$ ，不需要任何估计。若 $x \neq 0$ ，除以 $x^T x > 0$ （由第一个公式， $\sum_k c_k^2 > 0$ ）得 Rayleigh quotient（瑞利商）的取值范围：

$$\lambda_n \leq R(x) = \frac{x^T S x}{x^T x} = \frac{\sum_k \lambda_k c_k^2}{\sum_k c_k^2} \leq \lambda_1$$

也就是说， $R(x)$ 是特征值以权重 $c_k^2 / \|x\|^2$ 作的 weighted average（加权平均），权重非负且总和为 1。取 $x = v_1$ 得 $R = \lambda_1$ ，取 $x = v_n$ 得 $R = \lambda_n$ ，所以这个区间是紧的（端点能取到）。

补充一句适用范围：以上对 indefinite（不定）矩阵同样成立， λ_n 可以是负数，此时下界 $\lambda_n x^T x$ 是负的，夹逼依然有效。

适用条件：只用到「二次型被对化为平方和」这一事实。优势：一句话就把界、极值、正定性判定、 $S \succ 0 \iff$ 所有 $\lambda_k > 0$ 全部串起来。劣势： $R(x)$ 的加权平均读法默认权重和不为零，所以必须排除 $x = 0$ 。

五、常见错误判定（逐条给出错在哪一步）

✗ 错误 1：跳过条件，直接说「因为特征向量正交，所以 $x^T S x = \sum \lambda_k c_k^2$ 」。 错在把两条独立条件缝成一条。 v_k 只正交但不归一（ $\|v_k\|^2 = m_k$ ）时，正确结果是 $x^T x = \sum m_k c_k^2$ 、 $x^T S x = \sum \lambda_k m_k c_k^2$ ，也就是漏掉了因子 m_k 。用 $S = \text{diag}(1, 4)$ 、 $v_1 = (1, 0)$ 、 $v_2 = (0, 2)$ 检查：取 $x = (0, 2) = 1 \cdot v_2$ ，真实值 $x^T S x = 16$ ，而「 $\lambda_2 c_2^2$ 」给 $4 \cdot 1 = 4$ ，差了 $m_2 = 4$ 倍。归一化不是装饰，它是把展开式写成纯系数和 $\sum_k \lambda_k c_k^2$ 的前提。

✗ 错误 2：把交叉项消失归因于「对称矩阵的特征向量正交」一句话了事。 错在没区分两个公式的证法差异。第一个式子里交叉项 $v_k^T v_j$ 的消失只用了正交性；第二个式子里出现的是 $v_k^T S v_j$ ，要先用 $S v_j = \lambda_j v_j$ 把它变成 $\lambda_j v_k^T v_j$ 才能用正交性。若跳过这一步，遇到非对称矩阵就会把公式照搬过去，得出错误结果（见错误 5 的算例）。

✗ **错误 3：编号顺序与界的方向对不上。** 错在把「 λ_1 是最大特征值」这条记忆和「 $\lambda_1 x^T x \leq x^T S x$ 」这条不等式拼在一起用。题面与 Manual 里的 $\lambda_1, \dots, \lambda_n$ 本身只是标号，配上哪条不等式取决于排序方式；本稿统一取降序 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ，于是 λ_1 对应上界、 λ_n 对应下界。一旦沿用旧记忆却把界写成 $\lambda_1 x^T x \leq x^T S x \leq \lambda_n x^T x$ ，方向就反了。检查方法：只代一个 $x = v_1$ ，看 $x^T S x = \lambda_1 x^T x$ 到底撞在上界还是下界。

✗ **错误 4：默认 S 半正定，把 Rayleigh 商的界写成 $0 \leq R(x) \leq \lambda_1$ 。** 错在把 positive semidefinite（半正定，简称 PSD）的特殊情形当成一般情形。取 $S = \text{diag}(-3, 1)$ 、 $x = e_1$ ，得 $R = -3 < 0$ ，下界是最小特征值 $\lambda_n = -3$ 而不是 0。只有当所有 $\lambda_k \geq 0$ 时才有 $R(x) \geq 0$ ；此时 $x^T S x = 0$ 还能反推出 $Sx = 0$ ：由 $\sum_k \lambda_k c_k^2 = 0$ 与 $\lambda_k \geq 0$ 得每个 $\lambda_k c_k^2 = 0$ ，于是 $\lambda_k c_k = 0$ ，即 $\Lambda c = 0$ ，从而 $Sx = Q \Lambda Q^T x = Q \Lambda c = 0$ 。

✗ **错误 5：把 S 的对称性当成「多余条件」，或把公式套到任意可对角化矩阵上。** 错在没做反例检验。取非对称的 $S = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$ ：它的两个特征值都是 0，若公式真与对称性无关，任何 x 都该得到 $x^T S x = 0$ ；逐个代入就崩了—— $x = (0, 1)$ 给 0， $x = (1, 1)$ 给 1。这个例子还叠了第二层故障： S 只有 1 个线性无关的特征向量，展开 $x = \sum_k c_k v_k$ 本身就做不到；要单独隔离「有完整特征基、但特征向量不正交」这一层，见译者注（其一）里 $S = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 的算例。更深一层是连实特征值都没有：旋转矩阵 $\begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ 的特征值是 $\pm i$ ，此时「 $\sum_k \lambda_k c_k^2$ 」里的 λ_k 根本不是实数，整句话失去意义。顺带记一条：二次型本身只「看得见」 S 的对称部分，因为 $x^T S x = x^T \left(\frac{S+S^T}{2} \right) x$ ，反对称部分的贡献恒为零；但把 x 按 S 的特征方向展开、再逐项乘 λ_k 这套写法，仍然要求 S 本身对称。

✗ **错误 6：把 $c_k = v_k^T x$ 当定义硬背，说不出它从哪来（顺手写成 $c_k = x^T v_k / \|v_k\|$ 只是多余，不算错）。** 系数提取的依据是把 v_k^T 作用于展开式后交叉项归零。请注意 $x^T v_k$ 与 $v_k^T x$ 相等（标量的转置是它自己），所以写成 $x^T v_k$ 没问题；但在标准正交基下 $\|v_k\| = 1$ ，再除以 $\|v_k\|$ 是多余的装饰。一旦基不归一， $c_k = (v_k^T x) / \|v_k\|^2$ 才是对的——分母上的平方不能丢。

✗ **错误 7：用 $x^T x = c_1^2 + \dots + c_n^2$ 推出「任意基下 $\|c\| = \|x\|$ 」。** 错在丢掉了「正交」这一条。取基 $v_1 = (1, 0)$ 、 $v_2 = (1, 1)$ （ $v_1^T v_2 = 1 \neq 0$ ）与 $x = (2, 1) = v_1 + v_2$ ，则 $c = (1, 1)$ ， $\|c\|^2 = 2 \neq 5 = \|x\|^2$ 。所以 $\|c\| = \|x\|$ 是 ONB 的特征性质，不是基的普遍性质。

✗ **错误 8：在 $x^T S x = \sum \lambda_k c_k^2$ 上使用 trace/det 校验。** 错在把 $\sum \lambda_k$ 与 $\sum \lambda_k c_k^2$ 混为一谈。前者是 $\text{tr } S$ （与 x 无关），后者依赖 x ；只有当 x 恰好是第 k 个特征向量（ $c_k^2 = 1$ 、其余为 0）时二者才可能有数值上的巧合。正确的 trace/det 校验对象是矩阵本身： $\text{tr } S = \sum_k \lambda_k$ 、 $\det S = \prod_k \lambda_k$ ，见下节。

六、自检

自检 (a) 系数是否算对： 由 $c_k = v_k^T x$ 直接算，检验 $\sum_k c_k^2 = x^T x$ 与 $\sum_k \lambda_k c_k^2 = x^T S x$ 两条同时成立。两条是独立校验，只对一条说明不了问题：若 λ_k 全相等， $\sum_k \lambda_k c_k^2 = \lambda \sum_k c_k^2$ ，第二条就退化成了第一条。

自检 (b) 代入验算（ 2×2 显式算例）： 取 $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ （对称），特征值为 3 与 1，对应

```
v_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix},\quad
v_2=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\end{bmatrix},\quad
```

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad Q^T Q = I$$

校验 $Q^T Q = I$: 两个列内积 $v_1^T v_1 = v_2^T v_2 = \frac{1+1}{2} = 1$, $v_1^T v_2 = \frac{1-1}{2} = 0$, 通过。

取 $x = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ 。系数: $c_1 = v_1^T x = \frac{4}{\sqrt{2}} = 2\sqrt{2}$, $c_2 = v_2^T x = \frac{2}{\sqrt{2}} = \sqrt{2}$ 。于是

$$c_1^2 + c_2^2 = 8 + 2 = 10, \quad x^T x = 3^2 + 1^2 = 10 \quad \checkmark$$

$$\lambda_1 c_1^2 + \lambda_2 c_2^2 = 3 \cdot 8 + 1 \cdot 2 = 26, \quad \checkmark$$

$$x^T S x = \begin{bmatrix} 3 & 1 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = 21 + 5 = 26 \quad \checkmark$$

两个公式都命中。再取 $x = v_1$: $c_1 = 1, c_2 = 0$, 得 $R = \lambda_1 = 3$ (上界取到); 取 $x = v_2$: $R = 1 = \lambda_2$ (下界取到)。夹逼界的端点确实可达。

自检 (c) 维数与形状记账: x 是 $n \times 1$, v_k 是 $n \times 1$, c_k 是 1×1 标量; $x^T x$ 与 $x^T S x$ 都是 1×1 , 所以「等于一串标量平方和」在类型上合法。矩阵形式 $S = Q \Lambda Q^T$ 的形状是 $(n \times n)(n \times n)(n \times n)$, $Q^T x = c$ 是 $(n \times n)(n \times 1) = n \times 1$, 与「 n 个坐标」一致。

自检 (d) trace/det 双锁校验 (对象是 S , 不是二次型): 对上面的 S , $\text{tr } S = 2 + 2 = 4 = 3 + 1 \checkmark$; $\det S = 4 - 1 = 3 = 3 \cdot 1 \checkmark$ 。这两个数是集合层面的锁: 它们只说特征值集合是 $\{3, 1\}$, 不说哪一个是 λ_1 。配对必须靠特征向量: $S v_1 = 3 v_1$ 才允许写 $\lambda_1 = 3$ 。若把标号与向量错配 (让 v_1 配 $\lambda_1 = 1$), 公式立刻自相矛盾——取 $x = v_1$ 时按配对应得 $R = 3$, 按错标号却只得 $R = 1$ 。所以顺序是: 先用 trace/det 锁住特征值集合, 再用 $S v_k = \lambda_k v_k$ 把标号与向量配对, 最后才写界。

自检 (e) 奇异值侧的对照 (Manual 未涉及, 但值得记一笔): 对称矩阵的 singular values (奇异值) 是 $|\lambda_k|$, 于是 $\prod_k \sigma_k = |\det S|$ 。所以对称矩阵的行列式信息由特征值绝对值承载, 符号由负特征值的个数 ((-1) 的幂) 承载; 二次型的正负则由 λ_k 的符号决定。三个量各管一段: tr 锁住 $\sum_k \lambda_k$, $\det$ 锁住 $\prod_k \lambda_k$ (从而锁住负特征值个数的奇偶), 二次型在各方向上的正负锁住正、负特征值各有多少个, 谁也替代不了谁。

自检 (f) 数值自检 (与 CSAPP 的浮点表示对接): 先算 $c = Q^T x$ (n^2 次乘加), 再用 $\sum_k \lambda_k c_k^2$ 反算 $x^T S x$ (再加 n 次), 总代价 $O(n^2)$, 与直接算 $x^T (S x)$ 同阶; 它的价值是**结构性的** (给出界与极值), 不是计算上的。稳定性上要注意: 即使每个 $c_k^2 \geq 0$, λ_k 有正有负时该求和仍在做大小相消, 中间部分和可能远大于最终结果; 若 S 半正定 (所有 $\lambda_k \geq 0$), 则每一项 $\lambda_k c_k^2$ 非负、求和过程无相消, 这条路径比「先乘出 $S x$ 再内积」($S x$ 的分量本身可能相消) 更容易保住相对精度。

七、一句话: 这道题真正训练的是「在一组标准正交基下把二次型对化成平方和」——它把 symmetric matrix 的谱信息 (λ_k)、向量在基下的坐标 (c_k)、以及二次型的取值范围 ($[\lambda_n, \lambda_1]$) 三件事一次性接上, 是后面正定性判定、Rayleigh 商、主成分方向选择与 Cholesky 分解的共同入口。

[note] Note (译者注) ——瑞利商是加权平均: 从平方和形式到 Courant–Fischer 极值原理

把 $x^T S x = \sum_k \lambda_k c_k^2$ 与 $x^T x = \sum_k c_k^2$ 相除，会看到一件很干净的事：分母把权重归一了。令 $w_k = c_k^2 / \|x\|^2$ ，则 $w_k \geq 0$ 且 $\sum_k w_k = 1$ ，而由此得到的 $R(x) = \sum_k w_k \lambda_k$ 恰好是一组非负权重下的加权平均。这就是本题全部「界」的来源：加权平均永远落在最小与最大权值之间，即 $\lambda_n \leq R(x) \leq \lambda_1$ 。取 $x = v_k$ 时权重全部集中在第 k 项，得 $R = \lambda_k$ ，所以每个特征值都是某个方向上的瑞利商值；反过来，若某个 $R(x)$ 落在所有 λ_k 之外，那一定意味着某步代数出了错——这条不等式同时是结论也是排错工具。

第一性原理上，求极值的动作是「让权重尽量集中」。因为权重受约束 $\sum_k w_k = 1$ 且 $w_k \geq 0$ ，要让 $\sum_k w_k \lambda_k$ 最大，就把全部质量压到最大权值对应的方向，即 x 取 v_1 （最大特征值方向）；要做最小，就取 v_n 。教材在 Problem Set 1.8 题 2-5 里走的就是这条路：用同一个展开证明最大值 λ_1 在 $x = v_1$ 取到。这个「把质量集中到一个方向」的想法还能推广成一套更强的工具：最大值先在某个子空间上取，再在与其正交的补空间上取另一个极值——这正是 Courant–Fischer（库朗–费舍尔）min–max（极小–极大）刻画的思想来源，它把两端的 λ_1 与 λ_n 之外的中间特征值也用优化语言写出来：在按 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ 编号时，中间特征值 λ_k 就是在与 $v_1, \dots, v_{k-1}$ 都正交的剩余方向上所能取得的最大瑞利商。这里只指出机制，不展开证明：中间特征值对应「逐次扣除已经取到的极值方向」。

用一个具体例子验证加权平均的读法。取 $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ ， $\lambda_1 = 3, \lambda_2 = 1$ ， $v_1 = (1, 1)/\sqrt{2}$ ， $v_2 = (1, -1)/\sqrt{2}$ 。取 $x = (1, 0)$ ： $c_1 = c_2 = 1/\sqrt{2}$ ，于是 $x^T S x = 2$ ， $x^T x = 1$ ， $R = 2$ ；加权平均写法给 $w_1 = w_2 = 1/2$ ， $\frac{1}{2} \cdot 3 + \frac{1}{2} \cdot 1 = 2$ ，一致，这个 2 夹在 1 与 3 之间，符合预期。再取 $x = (2, 1)$ ： $c_1 = 3/\sqrt{2}$ ， $c_2 = 1/\sqrt{2}$ ， $\|x\|^2 = 5$ ，权重 $w_1 = 9/10$ 、 $w_2 = 1/10$ ，加权平均给 $R = \frac{9}{10} \cdot 3 + \frac{1}{10} \cdot 1 = 2.8$ ；直接代入也算一遍， $Sx = (5, 4)$ ， $x^T S x = 2 \cdot 5 + 1 \cdot 4 = 14$ ， $R = 14/5 = 2.8$ ，两条路完全一致。这正说明权重必须是 c_k^2 ：若误写成 $\sum_k \lambda_k c_k$ ，指数位置错一次，结果就垮了。由于 $x = (2, 1)$ 与 v_1 不同向， $R = 2.8$ 严格落在 1 与 3 之间，只有 x 落在特征方向上时端点才会被撞上。

跨课程连接可以锚在三处。其一，18.065 教材 §1.8 讲 SVD 时， $A^T A$ 与 $A A^T$ 的最大特征值给出 σ_1^2 ，而 σ_1 就是 $\|A\|_2$ ：这是「把瑞利商的极值当成算子范数」的直接推论，2 范数衡量最坏放大率，瑞利商衡量某个方向上的放大率；对称矩阵 A 有 $\|A\|_2 = \max_k |\lambda_k|$ ，它与瑞利商的最大值 λ_1 只在 $\lambda_1 \geq |\lambda_n|$ （例如 A 半正定）时重合，若最负的那个特征值绝对值更大， $\|A\|_2 = |\lambda_n|$ 对应的是瑞利商最小的方向。其二，与 6.006 的二分搜索形成对照：瑞利商极值是连续优化，梯度为零给出 $(S - RI)x = 0$ ，即特征方程；二分搜索是离散搜索，靠单调性收缩区间。一个是解方程找驻点，一个是靠序关系砍半区间，不要因为都叫「找极值」而混用。其三，与 100B 实分析相接：夹逼界 $\lambda_n \leq R(x) \leq \lambda_1$ 的证明只用到「有限个非负数之和非负」这一条，因此不依赖任何拓扑或紧性论证；这也是为什么它是纯代数结论，可以放心在有限维里用而不必谈连续性。

命名模板：「平方和 + 权重归一 = 范围即 $[\lambda_n, \lambda_1]$ 」。以后遇到任何形如「某二次量除以某长度平方」的比值，先把它写成加权平均，界就免费掉出来。一句话收束：瑞利商之所以好算，是因为在标准正交基下它退化成一串非负权重的加权平均，而加权平均的取值范围不需要任何估计技巧。

[note] Note (译者注) —— (其一) 为什么必须「正交 + 归一 + 对称」三条齐备：逐条拆掉条件的代价

本注要做的事很具体：把题面里 orthonormal（标准正交）与 symmetric（对称）这两组词逐个拿掉，看公式坏成什么样，从而确定每条假设到底在替我们挡住什么。先给结论：**正交**负责杀掉内积层面的交叉项，**归一**负责让系数不带长度因子，**对称**负责保证特征基存在且二次型的交叉项可被消去；三条中任何一条缺失，两个公式至少有一个失效。

先看「归一」。假设 v_1, v_2 正交但长度为 $\|v_1\|^2 = m_1$ 、 $\|v_2\|^2 = m_2$ ，则 $x^T x = m_1 c_1^2 + m_2 c_2^2$ ：交叉项确实消失了（这一步只需正交），但系数不是 1 而是 m_k 。所以「正交」与「归一」是两项独立工作：正交消交叉项，归一清系数。第一个公式写成 $\|x\|^2 = \|c\|^2$ ，隐含的前提正是后者。检验方法很机械：写下基向量，逐个算 $\|v_k\|^2$ ，只要有一个不是 1，公式就要加因子。

反过来也要小心：归一不能替代正交。取两个长度都是 1 但不正交的向量 $v_1 = (1, 0)$ 、 $v_2 = (3/5, 4/5)$ ($v_1^T v_2 = 3/5$)，以及 $x = v_1 + v_2 = (8/5, 4/5)$ ：此时 $\|x\|^2 = 3.2$ ，而「平方和」给出 $\|c\|^2 = 1^2 + 1^2 = 2$ ，差的 1.2 恰好是交叉项 $2c_1 c_2 v_1^T v_2 = 2 \cdot 1 \cdot 1 \cdot \frac{3}{5}$ 。所以正交与归一各自挡一类故障：正交管交叉项，归一管长度因子，两个都做齐， $\|x\|^2 = \|c\|^2$ 才成立。把两件事写在一起就是一般公式：只要基正交（不必归一），就有 $x^T x = \sum_k \|v_k\|^2 c_k^2$ 与 $x^T S x = \sum_k \lambda_k \|v_k\|^2 c_k^2$ ，两式只差一个 λ_k ；一旦基连正交都不满足，右边还要多出 $\sum_{k \neq j} c_k c_j v_k^T v_j$ 这一整块交叉项，逐项相加不再等于原来的二次型。

再看「对称」，这一步更关键。对一般矩阵，即使有实特征值和线性无关的特征向量，交叉项 $v_k^T S v_j$ 也未必为零。用非对称的 $S = \begin{bmatrix} 1 & 1 \\ 0 & 2 \end{bmatrix}$ 算一遍：它的特征值是 2 与 1，特征向量可取 $v_1 = (1, 1)$ （对应 2）与 $v_2 = (1, 0)$ （对应 1），两者内积 $v_1^T v_2 = 1 \neq 0$ ，于是 $v_1^T S v_2 = 1$ 、 $v_2^T S v_1 = 2$ ，展开式 $x^T S x = \sum_k \sum_j c_k c_j v_k^T S v_j$ 里 $k \neq j$ 的两项合计 $c_1 c_2 (v_1^T S v_2 + v_2^T S v_1) = 3c_1 c_2$ ，不会消失，二次型写不成只含平方项的形式。代入 $c_1 = c_2 = 1$ （即 $x = (2, 1)$ ）验证： $Sx = (3, 2)$ ， $x^T S x = 8$ ；而只留对角项是 $v_1^T S v_1 c_1^2 + v_2^T S v_2 c_2^2 = 4 + 1 = 5$ ，缺掉的 3 正是交叉项。

对照之下，对称矩阵不会出现这一幕： $S = S^T$ 时 $v_k^T S v_j = v_j^T S v_k$ ，再用 $S v_j = \lambda_j v_j$ 把两边都化成 $\lambda_j v_k^T v_j$ 与 $\lambda_k v_k^T v_j$ ，相减得 $(\lambda_j - \lambda_k) v_k^T v_j = 0$ ，所以不同特征值给出的特征向量自动正交；同一个特征值对应的多个特征向量，还可以在特征子空间内再做一次正交化并归一。这两条合起来，才保证整组基是 ONB——也就是题面那句「 $S = S^T$ 拥有 orthonormal eigenvectors」的全部内容。更极端的例子是 $S = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$ ：它的特征值是 $\pm i$ ，根本没有实特征值与实特征向量，「 $\lambda_k c_k^2$ 」里的 λ_k 已经不是实数。于是题面强调 $S = S^T$ 并不是客套：对称性同时供给了实特征值、正交特征向量与「二次型可对化」三件事，缺了它， λ_k 与 c_k 都会失去意义。本讲开篇就把这个对比说得很直白：

🔧 [00:01:35] Strang 说明非对称矩阵的两种失效方式：either the eigenvectors are complex, eigenvalues are complex, or the eigenvectors are not orthogonal. (翻译：要么特征向量是复数 (complex)，特征值是复数，要么特征向量不正交 (not orthogonal)。)

🔧 [00:02:53] Strang 把两类数彻底分开：And numbers in between are not eigenvalues, but singular values. (翻译：介于其中的数字并非 eigenvalues (特征值)，而是 singular values (奇异值)。)

这两句在本题语境下的用处是**定边界**：第二句提醒我们，处理非对称或矩形矩阵时登场的是 σ_k 而不是 λ_k ，而「 $\sum_k \lambda_k c_k^2$ 」这套写法只在对称世界里合法。官方 Manual（题解手册）的标准答案只写了「because the v's are orthonormal」，这在「为什么交叉项消失」上省略了 $v_k^T S v_j = \lambda_j v_k^T v_j$ 这一步，也完全没提对称性在第二条公式中的位置；补足的版本应当写成：「由 $S v_j = \lambda_j v_j$ 得 $v_k^T S v_j = \lambda_j (v_k^T v_j)$ ，再由标准正交性得 $k \neq j$ 时为 0；而保证这组实标准正交特征基存在的，正是 $S = S^T$ 。」

[note] Note (译者注) —— (其二) 从正交分解到跨课程连接：划分、投影与 P_k 的三条性质

其一留下的结论可以继续往下用，这里补两处跨课程连接和一个模板。

第一处连接是 6.042J 的「划分」。标准正交分解 $x = \sum_k (v_k^T x) v_k$ 把整个 $\mathbb{R}^n$ 拆成 n 个一维子空间的直和：每个向量都恰好落进每一维一次，各维互不重叠、并起来是整个空间——结构上就是按等价类分好的一个划分。区别在于划分的**来源**。等价类的划法只要满足自反、对称、传递就可以任意指定；而这里的划法被 inner product（内积）唯一钉死，你必须用 v_k 的方向做投影，换成别的方向， $\sum_k c_k^2$ 就不再等于 $\|x\|^2$ 。用一句话概括：等价关系给出「可以怎么划」，内积给出「唯一正确的划法」。

这套划分还能写成矩阵形式。记 $P_k = v_k v_k^T$ ，它就是 orthogonal projection（正交投影）到第 k 个方向上的矩阵，并且满足三条： $P_k^2 = P_k$ （投影两次等于投影一次）、 $P_k P_j = 0$ ($k \neq j$ ，某一维上的分量被其他维完全忽略)、 $\sum_k P_k = I$ （把所有维加回来就还原出原向量）。这三条正是「互不相交、并为全集」的矩阵版本，而 $\|x\|^2 = \sum_k \|P_k x\|^2$ 就是勾股定理在 n 维下的写法：每一维只贡献自己那一份 c_k^2 ，互不干扰。

第二处连接是 CSAPP 的浮点。投影系数 $c_k = v_k^T x$ 是一个内积， n 维下要做 n 次乘加，它的误差有一条容易被忽略的性质。取 $v_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 、 $v_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 与 $x = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 + \delta \\ 1 \end{bmatrix}$ ($\delta = 10^{-8}$)：此时 $c_1 = 1 + \delta/2$ ， $c_2 = \delta/2 = 5 \times 10^{-9}$ ，而 $\sum_k c_k^2$ 仍然等于 $1 + \delta + \delta^2/2$ ，与 $\|x\|^2$ 完全一致。 c_2 是两个几乎相等的数相减再除以 2 得到的：这台减法本身在二进制浮点下可以算得精确，两个如此接近的数相减不会引入新的舍入；但 $x_1 = 1 + \delta$ 这个分量在存储时已经被舍入，绝对误差约 10^{-16} ，于是 c_2 的相对误差被放大到约 $10^{-16}/10^{-8} = 10^{-8}$ ，它只剩 8 位有效数字。 $\sum_k c_k^2$ 的值仍由 $c_1^2 \approx 1$ 主导，看上去没有任何毛病。所以「算 $\|x\|^2$ 与 $\|c\|^2$ 再比对」只能发现总量层面的误差，发现不了某个小系数已经失真；要盯住小系数，得直接估计对应内积的绝对误差，而不是看总量是否守恒。这在 CSAPP 里有现成的名字：catastrophic cancellation（灾难性相消）——变差的是**相对精度**，绝对误差并没有变大，所以「总量守恒」这类检查抓不到它。

命名模板：**「三条假设对应三件事：正交消交叉项、归一清系数、对称保存在」**，配合上一条注的**「平方和 + 权重归一 = 范围即 $[\lambda_n, \lambda_1]$ 」**一起用。拿到任何形如「二次型除以长度平方」的式子，先问三条假设是否齐备，再写成加权平均，界与极值就同时到手。模板可以直接套到 $x^T A^T A x$ 上： $A^T A$ 对称半正定，瑞利商因此落在 $[\sigma_{\min}^2, \sigma_1^2]$ 内，最小值在 A 有零空间时为 0——这正是 SVD 里「 $\|A\|_2 = \sigma_1$ 」与「零空间方向让 $\|Ax\|$ 最小」两句话的共同来源。再往前一步就是主成分分析：把去均值数据矩阵的协方差矩阵 C 拿来，第一主方向就是让瑞利商 $w^T C w / w^T w$ 取最大值的那个 $w = v_1$ ，它能解释的方差恰好是 λ_1 ——同一个模板换了个名字继续用。一句话收束：题解手册用一句 orthonormal 带过了整段论证，而这段论证的真正内容是三个假设各挡一类故障——把故障一个个造出来，才知道哪条假设在替我们干活。

[problem] Problem 6 (问题 6)

教材 §1.8, p.60 | Manual, Problem Set 1.8 题 6

求矩阵 $A = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix}$ 的 singular value decomposition（奇异值分解，SVD）中的 σ 's、 v 's 与 u 's，按 equation (12)（方程 (12)）的做法计算。追加两问：把 A 中最大的 rank one piece（秩一部分）去掉之后，reduced matrix（缩减矩阵）的 norm（范数） $\|A\|$ 是多少？这个缩减矩阵的 singular values（奇异值）与

rank (秩) 各是什么?

Original (英文原题) : Find the σ 's and v 's and u 's in the SVD for $A = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix}$. Use equation (12). What is the norm $\|A\|$ when that largest rank one piece of A is removed? What are the singular values of this reduced matrix, and its rank?

[solution] 一、结论

先给全部答案。矩阵 A 与教材 §1.8 例 1 中的 $A_0 = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 互为 transpose (转置) : $A = A_0^T$, 因此奇异值不变, 而左、右奇异向量互换角色。

$$A = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} = U \Sigma V^T, \quad U = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{bmatrix}, \quad V = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix}$$

逐个列出题目点名要的三组量:

$$\sigma_1 = 3\sqrt{5} = \sqrt{45}, \quad \sigma_2 = \sqrt{5}; \quad v_1 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \quad v_2 = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ -1 \end{bmatrix}; \quad u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad u_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

拆成两个秩一项 (rank-one term) 的写法是

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T = \frac{3}{2} \begin{bmatrix} 1 & 3 \\ 1 & 3 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix}$$

注意这两块正是例 1 中 A_0 的两块各自转置后的结果, 这不是巧合, 而是 $A = A_0^T$ 强制出来的。

追加两问的答案: 去掉最大秩一部分 $\sigma_1 u_1 v_1^T$ 后,

$$A_1 = A - \sigma_1 u_1 v_1^T = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix}$$

该缩减矩阵的谱范数 (spectral norm, 即 $\|\cdot\|_2$) 为 $\|A_1\|_2 = \sigma_2 = \sqrt{5}$, Frobenius norm (Frobenius 范数) 为 $\|A_1\|_F = \sqrt{\sigma_2^2} = \sqrt{5}$, 秩为 1。作为对照, 原矩阵 $\|A\|_2 = \sigma_1 = 3\sqrt{5} \approx 6.708$, $\|A\|_F = \sqrt{45+5} = 5\sqrt{2} \approx 7.071$ 。本题中缩减矩阵只剩一个非零奇异值, 所以两种范数数值恰好相同, 这个巧合不能推广到 $r \geq 3$ 的情形。

定义核心句: 奇异值分解把线性映射拆成标量序列 σ_k 加两组标准正交方向 u_k, v_k , 其中 σ_k 为拉伸倍率, u_k 为输出方向, v_k 为输入方向。

二、方法一: 走 equation (12) 的原路, 从 $A^T A$ 出发

这条路给出的是分解可以被算出来这一构造性事实: 右奇异向量是 $A^T A$ 的特征向量 (eigenvector), 左奇异向量由 $u_k = A v_k / \sigma_k$ 直接得到。它对任意 $m \times n$ 实矩阵都成立, 不需要任何附加假设。

先算两个对称矩阵:

$$> A^T A = \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} = \begin{bmatrix} 9 & 12 \\ 12 & 41 \end{bmatrix}, \quad A A^T = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix} = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}$$

矩阵 $A^T A$ 的 trace (迹) 为 $9 + 41 = 50$, determinant (行列式) 为 $9 \cdot 41 - 12^2 = 369 - 144 = 225$ 。于是特征值 (eigenvalue) 满足 $\lambda^2 - 50\lambda + 225 = 0$, 即 $(\lambda - 45)(\lambda - 5) = 0$, 得 $\lambda_1 = 45, \lambda_2 = 5$, 开平方得 $\sigma_1 = 3\sqrt{5}, \sigma_2 = \sqrt{5}$ 。

再解齐次方程组求特征向量:

$$> \lambda = 45: \begin{bmatrix} -36 & 12 \\ 12 & -4 \end{bmatrix} \sim \begin{bmatrix} 3 & -1 \\ 0 & 0 \end{bmatrix} \Rightarrow 3x_1 = x_2 \Rightarrow v_1 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

$$> \lambda = 5: \begin{bmatrix} 4 & 12 \\ 12 & 36 \end{bmatrix} \sim \begin{bmatrix} 1 & 3 \\ 0 & 0 \end{bmatrix} \Rightarrow x_1 = -3x_2 \Rightarrow v_2 = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ -1 \end{bmatrix}$$

归一化因子来自 $\|(1, 3)\| = \|(3, -1)\| = \sqrt{10}$, 而正交性来自 $(1, 3) \cdot (3, -1) = 3 - 3 = 0$ 。

第三步, 用 $u_k = Av_k / \sigma_k$ 求左奇异向量:

$$> u_1 = \frac{Av_1}{\sigma_1} = \frac{1}{3\sqrt{5}} \cdot \frac{1}{\sqrt{10}} \begin{bmatrix} 15 \\ 15 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad u_2 = \frac{Av_2}{\sigma_2} = \frac{1}{\sqrt{5}} \cdot \frac{1}{\sqrt{10}} \begin{bmatrix} 5 \\ -5 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

这一步的合法性需要证明, 而不是当技巧接受: 设 $A^T Av_j = \sigma_j^2 v_j$, 则

$$> u_i^T u_j = \frac{v_i^T A^T Av_j}{\sigma_i \sigma_j} = \frac{\sigma_j^2 v_i^T v_j}{\sigma_i \sigma_j} = \frac{\sigma_j}{\sigma_i} \delta_{ij} = \delta_{ij}$$

所以只要 v 们标准正交 (orthonormal), u 们自动标准正交, 除以 σ_k 这一步恰好把长度调成 1。适用条件: $\sigma_k > 0$, 即只对 $k \leq r$ 使用。优劣: 这是最有教学价值、最可复现的路线, 代价是显式形成 $A^T A$ 会放大误差 (见译者注: 为什么要绕道 $A^T A$)。

三、方法二: 转置对偶——把例 1 的整体结果翻过来

这条路利用的是转置不改变奇异值、只交换左右向量这一结构对称性。它给出的是 Manual 的那句答案, 也因为如此, 它最省算力: 例 1 已经做过的特征值计算可以整块复用。

从 $A = A_0^T$ 出发, 对 equation (12) 两边取转置:

$$> A = A_0^T = (U_0 \Sigma_0 V_0^T)^T = V_0 \Sigma_0^T U_0^T$$

矩阵 Σ_0 是 2×2 对角矩阵, 故 $\Sigma_0^T = \Sigma_0$, 于是本题取

$$> U = V_0 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad V = U_0 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix}, \quad \Sigma = \Sigma_0$$

与方法一逐元素一致。适用条件: 需要已知 A^T 的完整 SVD, 或 A 本身就是某个已解矩阵的转置。劣势: 它把「为什么成立」外包给了例 1, 且矩形情形必须小心形状记账。

奇异值为何对转置不变，这里给出一个不依赖任何定理的证明：若 $A^T Av = \lambda v$ 且 $\lambda \neq 0$ ，则 $\|Av\|^2 = v^T A^T Av = \lambda \|v\|^2 \neq 0$ ，故 $Av \neq 0$ ，并且

$$> AA^T(Av) = A(A^T Av) = \lambda(Av)$$

所以 λ 同时是 $A^T A$ 与 AA^T 的特征值，对应的左奇异向量就是归一化的 Av 。对 A^T 重复同一论证即得两边非零谱完全一致。

Manual 标准答案原文与严谨性核验。 Manual 的 PS 1.8 题 6 写作：Exchange u 's and v 's (and keep $\sigma_1 = \sqrt{45}$ and $\sigma_2 = \sqrt{5}$) in equation (12) = the SVD of $\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$. (译文：把 equation (12) 中的 u 与 v 互换， $\sigma_1 = \sqrt{45}$ 与 $\sigma_2 = \sqrt{5}$ 保持不变，就得到 $\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$ 的 SVD。))

独立核验结论：这句话的数学内容是**正确的**，且与本文方法二完全同源。但它作为标准答案有三处不够严格或信息不全，须补足：

其一，它只给了操作指令，没给任何向量或矩阵的显式值，读者无法用它自检；至少要补上 $U = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ 、 $V = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix}$ 。其二，交换 u 与 v 这条规则在矩形情形下会变形：一般地 $(U\Sigma V^T)^T = V\Sigma^T U^T$ ，其中 Σ^T 是 $n \times m$ 的对角矩阵，形状从 $m \times n$ 变成 $n \times m$ ，只有方阵时才可以直接写 $\Sigma^T = \Sigma$ ；本题恰是方阵，指令才成立。其三，它没有交代唯一性：SVD 从来不是唯一的，允许同时翻转一对 (u_k, v_k) 的符号，也允许在奇异值重复时在对应特征空间内做正交旋转。本题 $\sigma_1 \neq \sigma_2$ ，所以只剩四种成对翻号的自由，Manual 给出的只是其中一种。

四、方法三：对称分块矩阵 $S = \begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix}$ 的特征向量

这条路把任意矩阵的 SVD 归约成某个对称矩阵的谱分解，并且它把两套正交基这一结论从附加证明变成自动推论。

$$> S = \begin{bmatrix} 0 & A \\ A^T & 0 \end{bmatrix} \in \mathbb{R}^{4 \times 4}, \quad S \begin{bmatrix} u_k \\ v_k \end{bmatrix} = \begin{bmatrix} Av_k \\ A^T u_k \end{bmatrix} = \begin{bmatrix} \sigma_k u_k \\ \sigma_k v_k \end{bmatrix} = \sigma_k \begin{bmatrix} u_k \\ v_k \end{bmatrix}, \quad S \begin{bmatrix} u_k \\ -v_k \end{bmatrix} = -\sigma_k \begin{bmatrix} u_k \\ -v_k \end{bmatrix}$$

代入本题的数值验证一组：取 $u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 、 $v_1 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ ，则 $Av_1 = \frac{15}{\sqrt{10}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{3\sqrt{5}}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \sigma_1 u_1$ ，同时 $A^T u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 9 \end{bmatrix} = \frac{3}{\sqrt{2}} \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \sigma_1 v_1$ ，两边都对上。矩阵 S 的 trace 为 0，与它的四个特征值 $3\sqrt{5}, \sqrt{5}, -\sqrt{5}, -3\sqrt{5}$ 成对反号、和为 0 一致。

这条路的独有收益有两项：第一， S 对称，而对称矩阵不同特征值的特征向量自动正交，因此 u 之间、 v 之间的正交性无需再算；第二，它解释了剥掉最大项后剩 σ_2 为什么自然——剥掉的部分正是 S 的最大特征对，剩下的极值就是次大特征值。适用条件：任何 $m \times n$ 矩阵都行，不要求方阵。劣势：把问题规模从 $m \times n$ 抬到 $(m+n) \times (m+n)$ ，是概念工具而非高效算法。

五、追加两问：剥掉最大秩一部分之后

先算被剥掉的那一块：

$$> \sigma_1 u_1 v_1^T = 3\sqrt{5} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \cdot \frac{1}{\sqrt{10}} \begin{bmatrix} 1 & 3 \end{bmatrix} = \frac{3\sqrt{5}}{2\sqrt{5}} \begin{bmatrix} 1 & 3 \\ 1 & 3 \end{bmatrix} = \frac{3}{2} \begin{bmatrix} 1 & 3 \\ 1 & 3 \end{bmatrix}$$

相减得缩减矩阵

$$> A_1 = A - \sigma_1 u_1 v_1^T = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix} = \sigma_2 u_2 v_2^T$$

其奇异值为 $\sqrt{5}$ 与 0, 秩为 1 (第二行等于第一行的相反数, 行空间只有一维)。范数上, $\|A_1\|_2 = \sigma_2 = \sqrt{5} \approx 2.236$, $\|A_1\|_F = \sqrt{(\sqrt{5})^2} = \sqrt{5}$ 。

这一问的完整理论依据是 Eckart-Young 定理 (教材紧接着的低秩逼近一节的中心定理), 这里给出两个范数版本的完整证明骨架, 比 Manual 只列结论要更严谨。

谱范数版本 (下界): 设 B 是任意秩不超过 k 的矩阵, $A = \sum_{i=1}^r \sigma_i u_i v_i^T$ 。由 rank-nullity (秩—零化度守恒), $\dim N(B) = n - \text{rank}(B) \geq n - k$; 而 $\text{span}\{v_1, \dots, v_{k+1}\}$ 的维数是 $k+1$ 。两者维数之和超过 n , 故交集中存在单位向量 w , 它同时满足 $Bw = 0$ 与 $w = \sum_{i \leq k+1} c_i v_i$ 。于是

$$> \|A - B\|_2 \geq \|(A - B)w\| = \|Aw\| = \left\| \sum_{i \leq k+1} \sigma_i c_i u_i \right\| = \left(\sum_{i \leq k+1} \sigma_i^2 c_i^2 \right)^{1/2} \geq \sigma_{k+1} \left(\sum_{i \leq k+1} c_i^2 \right)^{1/2} = \sigma_{k+1}$$

上界由 $B^* = \sum_{i \leq k} \sigma_i u_i v_i^T$ 达到: 此时 $A - B^* = \sum_{i > k} \sigma_i u_i v_i^T$, 其最大奇异值就是 σ_{k+1} 。取 $k = 1$ 即得 $\min_{\text{rank } B \leq 1} \|A - B\|_2 = \sigma_2 = \sqrt{5}$, 所以剥掉最大块之后不能再剥得更好。

Frobenius 范数版本: 由正交不变性 $\|A - B\|_F = \|\Sigma - P\|_F$, 其中 $P = U^T B V$ 仍满足 $\text{rank}(P) \leq k$ 。取 $N(P)$ 的一组标准正交基做成矩阵 $W \in \mathbb{R}^{n \times (n-k)}$, 则 $PW = 0$, 于是

$$> \|\Sigma - P\|_F^2 \geq \|(\Sigma - P)W\|_F^2 = \|\Sigma W\|_F^2 = \sum_i \sigma_i^2 s_i, \quad s_i = \sum_j w_{ij}^2$$

权重满足 $0 \leq s_i \leq 1$ 与 $\sum_i s_i = \text{trace}(W^T W) = n - k$ 。在这个可行域上最小化 $\sum_i \sigma_i^2 s_i$, 把单位权重优先分给最小的那些 σ_i^2 最优, 得下界 $\sum_{i > k} \sigma_i^2$; 上界同样由 $\sum_{i \leq k} \sigma_i u_i v_i^T$ 达到。取 $k = 1, r = 2$ 即 $\|A_1\|_F = \sqrt{\sigma_2^2} = \sqrt{5}$ 。

需要点明 Manual PS I.8 题 7 的一般说法 (用 $\|A\| = \sigma_1$ 则剩 σ_2 ; 用 Frobenius 则剩 $(\sigma_2^2 + \dots + \sigma_r^2)^{1/2}$) 正确但留了三个缺口: 它没有说明最大秩一部分指的是 $\sigma_1 u_1 v_1^T$ 而不是任意秩一矩阵; 没有说明本书默认的 $\|A\|$ 就是谱范数 σ_1 , 因此两种范数答案只有在 $r = 2$ 时才数值重合; 也没有说明缩减矩阵的秩一般是 $r - 1$, 本题即 1。

六、常见错误判定

✗ 把 $A^T A$ 的特征向量当 u 、把 $A A^T$ 的特征向量当 v (左右颠倒)。 错在把 $A v_k = \sigma_k u_k$ 的方向读反了: 定义域一侧的向量必须来自 $A^T A$ 。数值反证: 按错的取法装配 $U \Sigma V^T$ 得到 $\begin{bmatrix} 3 & 0 \\ 4 & 5 \end{bmatrix}$, 那是 A^T 而不是 A 。

✗ 忘记归一化, 取 $v_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ 。 错在把特征向量这一等价类 (任意非零倍数都满足 $A^T A v = \lambda v$) 当成了唯一的向量; $V^T V = I$ 只能靠长度 1 来兑现。数值反证: 若只让 V 的列不归一化而 U 保持正确, 装配结果是 $\sqrt{10}A \approx \begin{bmatrix} 9.49 & 12.65 \\ 0 & 15.81 \end{bmatrix}$; 若 u 也由同一个未归一化的 v 生成, 误差还会自乘, 装配结果变成 $10A = \begin{bmatrix} 30 & 40 \\ 0 & 50 \end{bmatrix}$ 。

✗ 把 A 的 eigenvalues (特征值) 3 与 5 当成奇异值。 错在混淆了两个不同的谱问题: A 是三角矩阵, $\det(A - \lambda I)$ 的根确实是对角元 3, 5, 但奇异值是 $A^T A$ 的特征值的平方根。数值反证: $3^2 + 5^2 = 34$, 而 $\|A\|_F^2 = 9 + 16 + 0 + 25 = 50 = 45 + 5$, 只有后者对得上; 且 $|\lambda|_{\max} = 5 \leq \sigma_1 = 3\sqrt{5}$, 说明这是两套不同的量。

✗ **忘记开方，写 $\sigma_1 = 45, \sigma_2 = 5$ 。** 错在把 $A^T A$ 的谱直接搬进 Σ 。数值反证： $\sigma_1^2 + \sigma_2^2$ 应等于 $\|A\|_F^2 = 50$ ，而 $45^2 + 5^2 = 2050$ 。

✗ **只翻一个符号，例如只取 $u_1 \rightarrow -u_1$ 而 v_1 不动。** 错在每个秩一项 $\sigma_k u_k v_k^T$ 是一个不可分割的乘积，符号必须成对翻转。数值反证：只翻 u_1 得到 $\begin{bmatrix} 0 & -5 \\ -3 & -4 \end{bmatrix} \neq A$ ；而 $(U, V) \rightarrow (-U, -V)$ ，或把某一对 (u_k, v_k) 同时翻号，都不改变乘积。

✗ **按升序排列奇异值。** 错在 $\|A\|_2 = \sigma_1$ 、剥掉最大块、Eckart-Young 的全部表述都以 $\sigma_1 \geq \sigma_2 \geq \dots$ 为前提。数值反证：若把 $\sqrt{5}$ 排在首位，被剥掉的最大块会变成 $\frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix}$ ，剥完剩下的范数将是 $3\sqrt{5}$ ，与题目意图正好相反。

✗ **在追加问里用 $\|A\| - \sigma_1$ 或 $3\sqrt{5} - \sqrt{5}$ 当剩余范数。** 错在把范数当成了可减的长度量，而范数只满足三角不等式。数值反证： $3\sqrt{5} - \sqrt{5} = 2\sqrt{5} \approx 4.472$ ，而正确答案是 $\sqrt{5} \approx 2.236$ 。

✗ **说缩减矩阵的秩是 0（最大块一去就空了）。** 错在把去掉一项读成去掉全部。数值反证： $\frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix}$ 的第二行是第一行的相反数，非零，秩恰为 $1 = r - 1$ 。

✗ **断言 SVD 唯一，或断言答案必须与 Manual 逐字相同。** 错在忽略了符号自由度：本题 $\sigma_1 \neq \sigma_2$ 时有四种成对翻号的选择，四种都满足 $A = U\Sigma V^T$ ；Manual 的交换只锁定了其中一种。

七、自检

代入验算：直接做乘法 $U\Sigma V^T$ ，

$$> \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 3\sqrt{5} & 9\sqrt{5} \\ 3\sqrt{5} & -\sqrt{5} \end{bmatrix} \frac{1}{\sqrt{10}} = \frac{1}{2\sqrt{5}} \begin{bmatrix} 6\sqrt{5} & 8\sqrt{5} \\ 0 & 10\sqrt{5} \end{bmatrix} = \begin{bmatrix} 3 & 4 \\ 0 & 5 \end{bmatrix}$$

逐元素复原，通过。另外 $Av_1 = \sigma_1 u_1$ 、 $A^T u_1 = \sigma_1 v_1$ 均已单独验算。

形状与维数记账： U 是 $m \times m = 2 \times 2$ ， Σ 是 $m \times n = 2 \times 2$ ， V^T 是 $n \times n = 2 \times 2$ ，乘积回到 2×2 ； $u_k \in \mathbb{R}^2$ 取 m 维， $v_k \in \mathbb{R}^2$ 取 n 维；非零奇异值的个数等于秩 $r = 2$ 。

trace 与 det 双锁： $\text{trace}(A^T A) = \text{trace}(AA^T) = 50 = \sigma_1^2 + \sigma_2^2 = 45 + 5$ ； $\det(AA^T) = 25 \cdot 25 - 20^2 = 225 = (\sigma_1 \sigma_2)^2$ ，故 $\sigma_1 \sigma_2 = 15 = |\det A|$ 。符号也对得上：

$\det U = \frac{1}{2}(-1 - 1) = -1$ ， $\det V = \frac{1}{10}(-1 - 9) = -1$ ，于是 $\det U \det \Sigma \det V^T = (-1)(15)(-1) = 15 = \det A$ 。

配方法与能量校验： $x^T A^T A x = 9x_1^2 + 24x_1 x_2 + 41x_2^2 = 9(x_1 + \frac{4}{3}x_2)^2 + 25x_2^2$ ，两个主元 9, 25 均为正，说明 $A^T A$ 是 positive definite（正定）的（等价于 $\det A \neq 0$ ），且主元之积 $9 \cdot 25 = 225$ 再次给出上面用到的行列式。代入两个单位方向： v_1 方向给出 $9 \cdot \frac{1}{10} + 24 \cdot \frac{3}{10} + 41 \cdot \frac{9}{10} = 0.9 + 7.2 + 36.9 = 45$ ， v_2 方向给出 $8.1 - 7.2 + 4.1 = 5$ ，与特征值 45 与 5 对得上。

秩与范数的上界校验： $6.708 = \sigma_1 \leq \|A\|_F = 7.071 \leq \sqrt{2}\sigma_1 = 9.487$ ；缩减矩阵 $\|A_1\|_F^2 = 5$ 与 $\sigma_2^2 = 5$ 一致。

数值条件数旁注： $\kappa_2(A) = \sigma_1/\sigma_2 = 3$ ，本题极其良态，手工计算不会暴露误差问题；这说明上一条显式形成 $A^T A$ 的风险在本题里被掩盖了，见译者注。

八、一句话

这道题真正训练的是：把矩阵在单位球上的最大拉伸这一几何事实，翻译成对称矩阵 $A^T A$ 的谱问题，并用转置对偶与秩一剥离这两把尺子检查自己对 U, Σ, V 三者分工的理解。

[note] Note (译者注) ——为什么要绕道 $A^T A$ ：能量、配方法与迹—行列式双锁

本注回答一个设计问题：奇异值既然是 A 自身的几何量（单位球被拉伸的倍率），为什么教材偏要先造 $A^T A$ ，再取它的特征值？原因是最小化或最大化 $\|Ax\|$ 这件事本身无从下手： x 一动， Ax 的方向和长度同时变，而 $A^T A$ 把这句话翻译成一个 quadratic form（二次型）的极值问题。代价是引入了 A 的平方，收益是问题变成对称矩阵的谱问题，可以正交对角化， σ_k 因此有了可计算的来源。

机制展开只有三行代数。第一行是能量恒等式 $\|Ax\|^2 = (Ax)^T(Ax) = x^T A^T A x$ ，把输出长度搬成输入的二次型。第二行是非负性：对一切 x 有 $x^T A^T A x = \|Ax\|^2 \geq 0$ ，所以 $A^T A$ 是 positive semidefinite（半正定）的，特征值必为非负实数、特征向量可以选成正交的——这正是 $\sigma = \sqrt{\lambda}$ 有意义的唯一理由。第三行是极值刻画：在单位球上最大化 $x^T A^T A x$ 得到的最大值就是 $\lambda_1 = \sigma_1^2$ ，取到最大值的方向就是 v_1 。把 x 用 V 的列展开， $x = \sum_k c_k v_k$ ，则 $\|Ax\|^2 = \sum_k \sigma_k^2 c_k^2$ 而 $\|x\|^2 = \sum_k c_k^2$ ，于是最大化退化成把全部权重压到最大的那个系数上，顺带也说明每个 σ_k 都是驻值。这三行合起来把范数等式变成推论而不是规定： $\|A\|_2 = \max_{\|x\|=1} \|Ax\| = \sqrt{\lambda_1} = \sigma_1$ 。

具体到本题， $A^T A = \begin{bmatrix} 9 & 12 \\ 12 & 41 \end{bmatrix}$ 对应的二次型是 $9x_1^2 + 24x_1x_2 + 41x_2^2$ ，用配方法（completing the square）写成

$$> 9x_1^2 + 24x_1x_2 + 41x_2^2 = 9 \left(x_1 + \frac{4}{3}x_2 \right)^2 + 25x_2^2$$

右边两个系数 9 与 25 正是 $A^T A$ 做 LDL^T 分解的两个主元，都为正，这既是正定性的 Sylvester 判据，也给出 $\det(A^T A) = 9 \cdot 25 = 225$ 这条独立校验。取两组单位方向代入： $(1, 3)/\sqrt{10}$ 得 45， $(3, -1)/\sqrt{10}$ 得 5。两个中间方向还能报出上下界： $x = (1, 0)$ 时二次型值为 9， $x = (1, 1)/\sqrt{2}$ 时值为 $(9 + 24 + 41)/2 = 37$ ，都落在 5 与 45 之间，与 $\lambda_2 \leq x^T A^T A x / \|x\|^2 \leq \lambda_1$ 这条夹逼关系一致。此时再用迹与行列式双锁： $\lambda_1 + \lambda_2 = 50$ 与 $\lambda_1 \lambda_2 = 225$ 同时成立，45 与 5 是唯一解，无需展开特征多项式就完成了闭环。同一台机器还免费给出 $\text{trace}(A^T A) = \sigma_1^2 + \sigma_2^2$ ：正交对角化后取迹，对角线上的特征值之和就是奇异值平方和，这正是自检一节里范数那一锁的来源。

跨课程连接有两条。其一，100B 实分析里那条紧集上的连续函数取到最大值，在本题是隐式的存在性保证：单位球 $\{x : \|x\| = 1\}$ 是有界闭集也就是紧集， $x \mapsto \|Ax\|$ 连续，所以 $\sup_{\|x\|=1} \|Ax\|$ 其实是 $\max$ ，最大值点真实存在， v_1 不是凭空假设出来的。区别在于：实分析只保证存在一个取到最值的方向，不告诉你它在哪，也不保证唯一；SVD 的构造性内容（ $A^T A$ 的特征向量、排序、正交性）把这份存在性升级成一张可计算、可排序的完整清单，还顺带给出了次大值、第三大值。其二，CSAPP 里的 floating point（浮点）表示提供了一个现实警告：显式形成 $A^T A$ 会把条件数（condition number）平方， $\kappa_2(A^T A) = \kappa_2(A)^2$ ，计算 $\lambda_k = \sigma_k^2$ 的相对误差被放大到约 $\epsilon_{\text{mach}} \kappa_2(A)^2$ 的量级；一旦 σ_2^2 小到与 $\epsilon_{\text{mach}} \sigma_1^2$ 同量级， σ_2 的信息会被完全吞掉。本题 $\kappa_2(A) = 3$ ，手工计算看不到这个问题；工程实现因此不显式造 $A^T A$ ，而是先双对角化再迭代（Golub–Kahan 型算法）。请把这条经验命名成模板：**能量配方法** → **主元定号** → **迹—行列式双锁**，它适用于任何求对称矩阵谱、又不想展开高阶行列式的场合。

🧩 *Strang* 在课上[讲解]：And numbers in between are not eigenvalues, but singular values.（翻译：介于其中的数字并非 eigenvalues（特征值），而是 singular values（奇异值）。）

回到正文：方法一之所以成立，不是因为它算得快，而是因为 $\|Ax\|$ 这个几何量在 $A^T A$ 里被写成了可正交对角化的能量形式。

[note] Note (译者注) ——转置对偶与剥秩一：贪心为什么在这里天然最优

本注回答另一个设计问题：把最大的一块剥掉之后，为什么剩下的范数恰好是 σ_2 ，而不是某个需要重新计算的复杂表达式？关键在于两个秩一项在 Frobenius 内积下互相正交，于是误差能量像勾股定理那样逐项相加，贪心剥离不需要任何 exchange argument（交换论证）就被迫最优。

先看代数机制。正交性的计算只用到一个恒等式： $\text{trace}(v_1 u_1^T u_2 v_2^T) = (u_1^T u_2)(v_1^T v_2)$ ，因为 u 之间正交、 v 之间正交，两个因子都是 0，所以 $\langle u_1 v_1^T, u_2 v_2^T \rangle = 0$ 。于是 $\|A\|_F^2 = \|\sigma_1 u_1 v_1^T\|_F^2 + \|\sigma_2 u_2 v_2^T\|_F^2 = \sigma_1^2 + \sigma_2^2$ ，剥掉第一项后剩下 σ_2^2 开根号。谱范数的下界需要一步维数论证：秩不超过 1 的矩阵 B 的零空间至少一维，而 $\text{span}\{v_1, v_2\}$ 已经是整个 $\mathbb{R}^2$ ，两个子空间维数之和超过 n ，必有非零交向量 w ；沿 w 方向 B 完全不起作用，于是 $\|A - B\|_2 \geq \|(A - B)w\| = \|Aw\| \geq \sigma_2$ 。这个「维数之和超过 n 则必有交」的论证，正是你在 6.042J 里用过的数数法（鸽笼原理的线性代数版本），而零空间至少一维这一句就是 rank-nullity 守恒 $\dim N(B) = n - \text{rank}(B)$ 。本题 $n = 2$ 、 $k = 1$ ，两个维数 1 与 2 之和为 $3 > 2$ ，交向量必然存在，论证一步到位。

具体数值验证：本题 $A_1 = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -3 & 1 \end{bmatrix}$ ，它的 Frobenius 范数平方是 $\frac{1}{4}(9 + 1 + 9 + 1) = 5$ ；谱范数平方同样来自 $A_1^T A_1 = \frac{1}{2} \begin{bmatrix} 9 & -3 \\ -3 & 1 \end{bmatrix}$ 的最大特征值 5（迹为 5、行列式为 0，故特征值是 5 与 0）。顺带一个配方法观察： $A_1^T A_1$ 的二次型是 $\frac{(3x_1 - x_2)^2}{2}$ ，完全平方，这正是它秩为 1 的解析证据——半正定二次型若是一个完全平方，对应的矩阵秩就是 1；把单位方向 $(3, -1)/\sqrt{10}$ 代进这个完全平方，得 $\frac{(9+1)^2}{2 \cdot 10} = 5$ ，正好取到最大值， $\|A_1\|_2 = \sqrt{5}$ 也顺手验完。

跨课程连接有两条。其一，6.006（CLRS 教材）里的贪心算法：区间调度按结束时间最早贪心、Huffman 编码按频率最低合并，这些贪心都需要交换论证或拟阵结构才能证明最优，而且在一般问题里贪心经常不是最优的。这里每次剥掉当前最大奇异值项的贪心天然最优，区别在于正交性把问题解耦（decoupled）：每个坐标 c_k 的贡献 $\sigma_k^2 c_k^2$ 只与 σ_k 有关，互不干扰，误差能量可加，因此把最大的一项拿走就是把可控误差压到最低的唯一选择，交换论证退化为恒等式。其二，6.042J 的等价关系与划分：矩阵 A 的每根纤维 $A^{-1}(b) = \{x : Ax = b\}$ 正是零空间 $N(A)$ 的一个陪集，也就是像相同这个等价关系下的等价类；SVD 的 V 给整个输入空间配了一组适配这个划分的标准正交基，而 pseudoinverse（伪逆） $x^+ = V \Sigma^{-1} U^T b$ 在每个等价类里挑出最小范数的那一个代表元。区别在于：6.042J 的等价类是离散、无结构的集合，计数就是全部内容；这里的纤维是仿射子空间，维数由 rank-nullity 守恒固定为 $n - r$ ，选代表元要用到正交投影，而投影矩阵 UU^T 与 VV^T 恰好由 SVD 提供。把这条经验命名成模板：**转置对偶交换律 + 剥秩一能量勾股**——前者处理换个方向看同一个映射，后者处理删掉哪些方向代价最小。秩 $r \geq 3$ 时 Frobenius 口径的剩余量是 $(\sigma_2^2 + \dots + \sigma_r^2)^{1/2}$ ，与 σ_2 不再重合，本题 $r = 2$ 才让两个口径数值相等。

🧩 *Strang* 在课上[讲解]：are orthogonal, which I can do. And then they have to be in the SVD.（翻译：是正交的，这我能做到。并且然后它们必须位于 SVD（奇异值分解）中。）

回到正文：转置对偶解释了本题为什么可以零成本复用例 1 的结果，剥秩一逻辑则解释了追加两问的答案为什么必须落在 σ_2 上。

附：两题合观——把两道题折叠成一个设计问题

这两道题回答同一个设计问题：**一个矩阵的信息里，哪些可以被压缩成几个标量，哪些必须以向量的形式整个保留下来？** 题 1 从坐标系这一侧逼近它，题 6 从计算与验证这一侧逼近它。

题 1 压住的是坐标系这一层，它要建立的是一个记账格式：把向量写进一组标准正交基之后，所有需要相加的量都变成平方和，交叉项一律消失。长度是这样： $x = \sum_k c_k v_k$ 时 $\|x\|^2 = \sum_k c_k^2$ ，而不是某个带 $c_i c_j$ 的展开式，因为 $v_i^T v_j = 0$ ($i \neq j$) 把交叉项全部清零。二次型也是这样： $x^T A x$ 在 A 的特征向量基下退化成 $\sum_k \lambda_k c_k^2$ ，同一个正交性把 $c_i c_j$ 项一次清干净。这两件事是同一个机制的两面：正交性负责消灭交叉项，交叉项消失之后每个坐标独立记账，谁大谁小一眼可见。题 1 的真正产出不是某个数值答案，而是一种纪律——**先把向量放进一组正交方向，再逐坐标读数和**；没有这条纪律，拉伸倍率、投影、配方法都只是图像上的说法，落不成可算的量。

题 6 压住的是计算与验证这一层，它把题 1 的记账格式用到底。它不从 A 本身出发而从 $A^T A$ 出发，理由是奇异值藏在 $A^T A$ 的谱里： $A^T A$ 对称半正定，谱是实的非负数，开方得 σ ，特征向量给出 v ，再用回代关系 $u = Av/\sigma$ 把左向量补齐。三步——求谱、开方、回代——各自都能被独立检查，这正是它值得手算一遍的原因。更值得记住的是其中的对偶性： A 与 A^T 的奇异值一字不差，区别只是 u 与 v 互换。这条对偶性有两种用法，缺一不可：省力的用法是把它当捷径，已经算过一个方向的分解，整体转置即可；费力的用法是自己从头重算另一个方向，再回头核对两条路给出的是同一组数。只做前者，你得到一个结论；只做后者，你得到一堆数。两样都做，你才看清这个结论不是巧合，而是转置只是换了个方向看同一个映射这件事的必然结果。

两题咬合的位置在**正交性**。题 1 证明了正交基下交叉项为零，题 6 则把矩阵本身拆成两条互不干扰的通道： $A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T$ ，两个秩一项彼此正交，于是误差能量可以像勾股定理那样逐项相加。没有这层正交性，剥掉最大一项之后剩下的范数就不是干净的 σ_2 ，能量会在通道之间串味，贪心剥离也失去最优性。所以题 6 的第一段产出其实是矩阵等于一组独立通道之和这个权利，剥秩一只是行使权利后兑现的第一笔账；而这项权利正是题 1 花整道题建立的记账格式。顺序不能颠倒：先谈舍弃再找方向，只会得到一个能近似、不能解释的分解。

把两道题放在一起，训练的是一条固定动作：**先问这个线性映射在哪些方向上只是被拉伸，再把拉伸倍率排序，最后才谈舍弃**。题 1 交出前半句所需的坐标系与长度公式，题 6 交出后半句所需的算法与验证手段（求谱、开方、回代，以及迹—行列式双锁这样的独立校验）。两题合起来给出的不只是 2×2 矩阵的一组数字，而是一套可以搬到任意矩阵上的工作顺序。